

Universidad Nacional de Ingeniería
Facultad de Ingeniería Geológica Minera y Metalúrgica



TESIS

**Delimitación de los dominios geológicos de alteración desde
firmas espectrales y geoquímica mediante el empleo de machine
learning**

Para obtener el título profesional de Ingeniero Geólogo

Elaborado por

Jhonatan Paul Mallma Espinoza

 [0009-0007-5912-5915](https://orcid.org/0009-0007-5912-5915)

Asesor

MSc. César Augusto Mendoza Tarazona

 [0009-0009-5452-3636](https://orcid.org/0009-0009-5452-3636)

LIMA – PERÚ

2026

Citar/How to cite	Mallma Espinoza [1]
Referencia/Reference	[1] J. Mallma Espinoza, " <i>Delimitación de los dominios geológicos de alteración desde firmas espectrales y geoquímica mediante el empleo de machine learning</i> " [Tesis de pregrado]. Lima (Perú): Universidad Nacional de Ingeniería, 2026.
Estilo/Style: IEEE (2020)	

Citar/How to cite	(Mallma, 2026)
Referencia/Reference	Mallma, J. (2026). <i>Delimitación de los dominios geológicos de alteración desde firmas espectrales y geoquímica mediante el empleo de machine learning</i> . [Tesis de pregrado, Universidad Nacional de Ingeniería]. Repositorio institucional Cybertesis UNI.
Estilo/Style: APA (7ma ed.)	

Dedicatoria

A Dios.

A mis padres José y Norma.

*Porque creyeron en mí y por haberme apoyado
en todo momento, dándome consejos de superación y
entrega,
valores y por la motivación constante que me
ha permitido completar esta etapa profesional.*

Resumen

La industria minera actual dispone de una gran capacidad para adquirir datos geológicos, geoquímicos, espectrales y geofísicos, tanto recientes como históricos; sin embargo, la integración e interpretación conjunta de estos datos continúa siendo un desafío relevante. En este contexto, el uso de técnicas de Machine Learning (ML) permite identificar patrones complejos y relaciones no evidentes, contribuyendo a la generación de conocimiento a partir de grandes volúmenes de información.

El presente estudio tiene como objetivo desarrollar una metodología que garantice la vinculación sistemática de anomalías espectrales en modelos de estimación de recursos, integrando datos de espectrometría (TerraSpec), registros geológicos y químicos en el yacimiento Au–Cu Tantahuatay, ubicado en el norte del Perú. La definición de dominios se realizó a partir del análisis de datos espectrales provenientes de sondajes, empleando técnicas de aprendizaje no supervisado como análisis jerárquico, técnicas de clustering (K-Means) y Análisis de Componentes Principales (PCA), lo que permitió identificar y caracterizar seis dominios de alteración principales.

Posteriormente, mediante análisis exploratorio de datos, se seleccionaron variables y tramos representativos para el entrenamiento de modelos predictivos. Se evaluaron distintos algoritmos de aprendizaje supervisado como máquinas de vectores de soporte (SVM), k-vecinos más cercanos (k-NN), bosques aleatorios (RF) y redes neuronales (NN), obteniendo los mejores resultados con el algoritmo Random Forest.

Los resultados del estudio demuestran que el algoritmo Random Forest (RF) ofrece el mejor desempeño predictivo, alcanzando los niveles más altos de precisión y robustez en la clasificación automatizada de alteraciones. Los resultados concluyen que la integración sistemática de variables mediante Machine Learning supera los sesgos de la interpretación visual clásica, mejorando significativamente la delimitación de las zonas de alteración hidrotermal. Asimismo, el uso complementario de herramientas de modelamiento geométrico tridimensional permitió validar la continuidad espacial y la zonación

mineralógica del yacimiento. Esto mejora la caracterización de la delimitación de minerales económicos, demostrando un impacto directo para las fases de estimación de recursos.

Palabras clave — Machine learning, asociaciones mineralógicas, alteración hidrotermal, dominios geológicos, Random Forest, espectrometría.

Abstract

The current mining industry has a high capacity to acquire geological, geochemical, spectral, and geophysical data, both recent and historical; however, the joint integration and interpretation of these data remain a relevant challenge. In this context, the use of Machine Learning (ML) techniques allows the identification of complex patterns and non-obvious relationships, contributing to the generation of knowledge from large volumes of information.

The objective of this study is to develop a methodology that ensures the systematic linking of spectral anomalies in resource estimation models, integrating spectrometry (TerraSpec), geological, and chemical logs in the Au–Cu Tantahuatay deposit, located in northern Peru. The definition of domains was carried out from the analysis of spectral data from drill holes, employing unsupervised learning techniques such as hierarchical analysis, clustering techniques (K-Means), and Principal Component Analysis (PCA), which allowed the identification and characterization of six main alteration domains.

Subsequently, through exploratory data analysis, representative variables and intervals were selected for the training of predictive models. Different supervised learning algorithms were evaluated, such as support vector machines (SVM), k-nearest neighbors (k-NN), random forests (RF), and neural networks (NN), obtaining the best results with the Random Forest algorithm.

The results of the study demonstrate that the Random Forest (RF) algorithm offers the best predictive performance, achieving the highest levels of accuracy and robustness in the automated classification of alterations. The results conclude that the systematic integration of variables through Machine Learning overcomes the biases of classical visual interpretation, significantly improving the delimitation of hydrothermal alteration zones. Likewise, the complementary use of three-dimensional geometric modeling tools allowed validating the spatial continuity and mineralogical zoning of the deposit. This improves the

characterization of the delimitation of economic minerals, demonstrating a direct impact for the resource estimation phases.

Keywords — Machine learning, mineral associations, hydrothermal alteration, geological domains, Random Forest, spectrometry.

Tabla de Contenido

	Pág.
Resumen	iv
Abstract	vi
Introducción	xvii
Capítulo I. Parte introductoria del trabajo	1
1.1 Generalidades	1
1.2 Descripción del problema	2
1.3 Objetivo del estudio	4
1.3.1 Objetivo general	4
1.3.2 Objetivos específicos	5
1.4 Antecedentes	5
1.5 Hipótesis	8
1.5.1 Hipótesis general	8
1.5.2 Hipótesis específicas	8
Capítulo II. Marcos teórico y conceptual	9
2.1 Asociaciones mineralógicas en yacimientos epitermales	9
2.1.1 Asociaciones mineralógicas favorables a la mineralización	10
2.1.2 Equipos para caracterización mineralógica	11
2.1.3 Interpretación geológica de los ensambles de alteración.	15
2.2 Machine learning	16
2.2.1 Aprendizaje supervisado	17
2.2.2 Aprendizaje no supervisado	17
2.2.3 Algoritmos de clasificación y regresión	17
2.2.4 Matriz de confusión	25
2.2.5 Métrica de Rendimiento ROC	27
Capítulo III. Desarrollo del trabajo de investigación	31
3.1 Ubicación	31

3.2	Geología local	32
3.3	Alteración hidrotermal	35
3.3.1	Alteración hipógena epitermal de alta sulfuración	37
3.3.2	Alteración hipógena relacionada a la mineralización del tipo skarn/pórfido	38
3.4	Tipo y diseño de la investigación.....	39
3.4.1	Según su enfoque	39
3.4.2	Según su alcance.....	39
3.4.3	Diseño de investigación	40
3.5	Variables e indicadores	40
3.5.1	Variables independientes (VI)	40
3.5.2	Variable dependiente (VD)	40
3.5.3	Indicadores	40
3.6	Matriz de consistencia.....	40
3.7	Flujograma metodológico	41
3.8	Recolección y preparación de datos.....	46
3.8.1	Procedimiento de muestreo químico y espectral estandarizado	47
3.8.2	Procedimiento de captura espectral estandarizado con el equipo de TerraSpec..	50
3.9	Procesamiento de datos espectrales.....	56
3.9.1	Descripción de la base de datos	56
3.9.2	Variables categóricas	61
3.9.3	Variables numéricas.....	64
3.10	Procesamiento de los datos químicos	70
3.10.1	Tratamiento de datos faltantes	71
3.10.2	Detección de valores atípicos.....	72
3.10.3	Normalización y escalamiento.....	73
3.11	Aprendizaje automático no supervisado.....	73
3.11.1	Análisis de componentes principales (PCA)	74
3.11.2	Clustering jerárquico	74

3.11.3 K-Means.....	75
3.12 Aprendizaje automático supervisado.....	76
3.12.1 Preparación de los datos.....	77
3.12.2 Definición variables y asignación de dominios.....	77
3.12.3 División de datos para entrenamiento y validación.....	81
3.12.4 Selección de variables y configuración de hiperparámetros para el entrenamiento	85
3.12.5 Evaluación de los algoritmos entrenados con la geoquímica.....	92
3.12.6 Métricas de evaluación.....	93
Capítulo IV. Análisis e interpretación de resultados	95
4.1 Resultados del análisis exploratorio de datos.....	95
4.1.1 Variables categóricas	95
4.1.2 Variables numéricas.....	97
4.1.3. Correlaciones entre variables.....	100
4.2 Resultados del aprendizaje automático no supervisado	101
4.2.1 Análisis de componentes principales.....	102
4.2.2 Agrupamiento jerárquico (Hierarchical Clustering)	104
4.2.3 Agrupamiento mediante K-Means	106
4.3 Resultados del aprendizaje automático supervisado	108
4.3.1 Resultados del rendimiento del entrenamiento de los modelos	108
4.3.2 Resultados de la matriz de confusión por modelo	110
4.3.3 Curvas ROC y evaluación del rendimiento	111
4.3.4 Comparación de desempeño de los algoritmos para los ensambles	114
4.4 Clasificación de los minerales de alteración	116
4.5 Sobreajuste y desempeño de los modelos	117
4.6 Modelamiento 3D de los dominios de alteración	119
4.7 Zonamiento hidrotermal y vectorización hacia mineralización	121
4.8 Limitaciones del estudio	124
Conclusiones	126

Recomendaciones	128
Referencias bibliográficas	129
Anexos	132

Lista de Tablas

	Pág.
Tabla 1 : Principales instrumentos para caracterizar asociaciones mineralógicas.....	13
Tabla 2 : Comparativa de fortalezas y limitaciones de los algoritmos de aprendizaje automático	15
Tabla 3 : Matriz de confusión	26
Tabla 4 : Resumen de estudios previos que aplican algoritmos de aprendizaje automático en exploración minera	30
Tabla 5 : Matriz de consistencia.....	41
Tabla 6 : Tabla de longitudes de onda principales	52
Tabla 7 : Firmas espectrales de los principales minerales de alteración	52
Tabla 8 : Lista de minerales identificados por Ausspec.....	56
Tabla 9 : Descripción del tipo de datos para las 69 columnas entregadas por Ausspec.	57
Tabla 10: Tabla con las columnas de los resultados espectrales del SWIR y VNIR.....	60
Tabla 11: Resultados de las mezclas más abundantes en el rango del SWIR	63
Tabla 12: Resultados obtenidos por espectrometría en el rango del VNIR	64
Tabla 13: Resultados de las abundancias relativas para cada mineral de los rangos del SWIR	65
Tabla 14: Medidas estadísticas por mineral de los resultados de los rangos del SWIR ..	66
Tabla 15: Tabla resumen con la eliminación de minerales con media de cero	69
Tabla 16: Tabla resumen de los datos químicos	70
Tabla 17: Tabla resumen con los dominios seleccionados para el entrenamiento	80
Tabla 18: Tabla merge con las asignaciones de los dominios de alteración y muestras químicas	84
Tabla 19: Tabla con los parámetros para el modelo Random Forest	88
Tabla 20: Tabla con los parámetros para el modelo kNN.....	89
Tabla 21: Tabla con los parámetros para el modelo Neural Network	90
Tabla 22: Tabla con los parámetros para el modelo SVM.....	92

Tabla 23: Matriz de Correlación Pearson	101
Tabla 24: Matriz de Correlación Spearman	101
Tabla 25: Tabla de evaluación de parámetros de calidad	109
Tabla 26: Métricas de desempeño obtenidas durante la fase de validación de los cuatro modelos predictivos	115

Lista de Figuras

	Pág.
Figura 1 : Línea de tiempo del Machine Learning	1
Figura 2 : Trabajos con Machine Learning en Geociencias.....	3
Figura 3 : Diagrama de clasificación para el algoritmo Random Forest.....	7
Figura 4 : Algoritmo K-NN mostrando 2 clases	18
Figura 5 : Algoritmo Maquinas Soporte Vector.....	20
Figura 6 : Algoritmo Árbol de Decisión	21
Figura 7 : Grafica de la lógica del árbol de decisión	23
Figura 8 : Grafica de Redes Neuronales.....	25
Figura 9 : Grafica de la curva ROC	29
Figura 10: Mapa de localización de la unidad Tantahuatay.....	31
Figura 11: Columna estratigráfica distrital de Tantahuatay	34
Figura 12: Mapeo litológico superficial de Tantahuatay.....	35
Figura 13: Mapeo superficial de alteraciones de Tantahuatay	37
Figura 14: Flujo general para la predicción de dominios de alteración	42
Figura 15: Flujo en detalle para las muestras espectrales y químicas.....	44
Figura 16: Recolección de muestras espectrales y su posterior ploteo en 3D.....	47
Figura 17: Equipo Terraspec4, identificación de componentes	50
Figura 18: Principales rasgos de la zona del SWIR para identificar minerales	51
Figura 19: Firmas espectrales de referencia de minerales de alteración.....	53
Figura 20: Histograma de cantidad de muestras por minerales del SWIR, VNIR y mezclas	62
Figura 21: Distribución de los datos espectrales (por abundancia de minerales)	68
Figura 22: Distribución de los datos químicos	71
Figura 23: Variables seleccionadas para el entrenamiento y la predicción de dominios de alteración	72
Figura 24: Asignación de los dominios de alteración (ArgAvd-Fill-Sk).....	78
Figura 25: Asignación de los dominios de alteración (ArgAv y ArgAvd_2)	78

Figura 26: Asignación de los dominios de alteración (Pro).....	79
Figura 27: Resumen de los clústeres y la definición de los 6 dominios de alteración	80
Figura 28: Flujo de trabajo para las predicciones en base a los tramos seleccionados ...	81
Figura 29: Sección conceptual de los tramos para el entrenamiento y los tramos para testeo	82
Figura 30: Selección en Orange de las variables de entrada y la variable objetivo	85
Figura 31: Flujo de trabajo en Orange para el entrenamiento de los 04 algoritmos predictivos	86
Figura 32: Flujo de trabajo para el entrenamiento en Orange, mostrando el test and score, ROC y matriz de confusión	93
Figura 33: Secciones que muestran los minerales por abundancia de la zona del SWIR y VNIR.....	96
Figura 34: Secciones que muestran las mezclas de los minerales en de la zona del SWIR	97
Figura 35a: Ploteo en planta de los minerales para Argílica Avanzada	98
Figura 35b: Ploteo en planta de los minerales para Argílica Intermedia y Fillica	99
Figura 36: Ploteo en planta de los minerales para Argílica / Propílica	100
Figura 37: Diagrama PCA mostrando la distribución de los cinco grupos identificados.	103
Figura 38: Análisis Hierarchical Clustering	105
Figura 39: Visualización en sección SW-NE de los 05 clustering	106
Figura 40: Visualización en de 3D de la distribución de los 05 clustering	108
Figura 41: Sección mostrando los resultados de los 4 algoritmos usados para las predicciones de los dominios de alteración	109
Figura 42: Matriz de confusión del testeo para los 4 modelos	110
Figura 43: Resultados de ROC del testeo para los 4 modelos y por cada dominio	112
Figura 44: Sección parte superior e inferior	116
Figura 45: Curva de aprendizaje para los 4 modelos	118

Figura 46: Modelamiento dinámico en leapfrog usando la predicción de tramos Random Forest.....	121
Figura 47: Secciones transversales que muestran la zonación de los minerales de alteración dentro de los dominios de alteración predichos.....	123

Introducción

El avance de las geociencias en el siglo XXI está estrechamente ligado a la capacidad de la industria minera para transformar grandes volúmenes de datos en conocimiento geológico preciso y oportuno. Durante décadas, la interpretación de alteración hidrotermal y la delimitación de dominios geológicos han realizado predominantemente con criterios cualitativos y en la observación visual de logueo. Si bien esta aproximación tradicional ha sido la base de la exploración, la complejidad intrínseca de los sistemas minerales modernos exige incorporar herramientas analíticas más rigurosas, objetivas y reproducibles.

El presente trabajo de investigación nace de la necesidad de tender un puente entre la geología y las nuevas herramientas de la ciencia de datos. Centrado en la unidad minera Tantahuatay un depósito epitermal de Au–Cu de alta sulfuración a la vez que migra a un sistema porfirítico que lo hace complejo, este estudio aborda uno de los desafíos más persistentes en la estimación de recursos: la incertidumbre asociada a contornos y transiciones difusas entre dominios de alteración.

Mediante el uso de algoritmos de Machine Learning y el procesamiento sistemático de firmas espectrales (SWIR-VNIR) y datos geoquímicos, esta investigación propone un flujo de trabajo cuantitativo capaz de optimizar la clasificación mineralógica. Más allá de la precisión algorítmica, el verdadero valor de esta contribución radica en su aplicabilidad práctica: proporcionar al profesional geólogo un criterio técnico estandarizado que reduzca el sesgo interpretativo, fortalezca la confiabilidad del modelo de bloques y, en última instancia, optimice las decisiones en la planificación minera.

Presentar esta tesis ante la Facultad de Ingeniería Geológica, Minera y Metalúrgica de la Universidad Nacional de Ingeniería no solo representa la culminación de una etapa de formación académica y profesional, sino también el compromiso continuado con la innovación técnica y la excelencia en el ejercicio de la ingeniería geológica en el Perú.


Capítulo I. Parte introductoria del trabajo

1.1 Generalidades

El Machine Learning es una herramienta que es aplicada en diferentes áreas, teniendo una mayor tendencia en la última década gracias al desarrollo de más algoritmos desarrollados en lenguajes de programación más sencillos como Python. La historia nos muestra la evolución que ha tenido los diferentes algoritmos a lo largo de los años, como se aprecia en la Figura 1, en el caso de la estimación de recursos el más importante es el Kriging. En el caso de la geología esta herramienta viene siendo aplicada gracias a los últimos avances en los softwares, como Orange que es un software que usa un entorno de objetos para desarrollar la programación y ejecutar las librerías de Python.

Figura 1

Línea de tiempo del Machine Learning



Nota: Fuente adaptado de Dramsch (2019).

La gran densidad de datos que se generan a largo del registro de logueo de un proyecto, provoca la necesidad de reconocer patrones que puedan correlacionar y generar un modelo más robusto de mejor presión.

Al desarrollar una metodología de aprendizaje basado en algoritmos de Machine Learning para predecir características litológicas de sondajes empleando resultados

geoquímicos se obtendrá un modelo más eficiente, de esta manera se contribuye en aumentar precisión y disminuir tiempos en la interpretación geológica.

1.2 Descripción del problema


En la actualidad, faltan procesos estandarizados que permitan uniformizar criterios que sean empleados en las descripciones geológicas y la falta de herramientas que permiten identificar patrones en grandes conjuntos de datos de multivariantes en la geología, tienen una solución en las técnicas de minería de datos y machine learning recientemente aplicadas en geología, permitiendo al mismo tiempo realizar predicciones que ayudan a la estandarización como lo menciona Hill et al. (2014) en su trabajo “Using geochemical proxies to model nuggety gold deposits: An example from Sunrise Dam”.

A nivel mundial la poca difusión del machine learning en la geociencia motiva a la investigación, como lo hace notar Dransch en su trabajo del (2020) “70 Years of Machine Learning in Geoscience in Review”, donde revisa el desarrollo learning en las geociencias a lo largo de los últimos 70 años, poniendo énfasis en la geofísica, pero remarcando la falta de difusión en los campos de la geoquímica, geoestadística y geología, la revisión incluye varios métodos de aprendizaje automático superficiales, por ejemplo; árboles de decisión, bosques aleatorios, máquinas de vectores de soporte y procesos gaussianos, así como redes neuronales profundas, incluidas las redes neuronales de alimentación hacia adelante, las redes neuronales convolucionales, las redes neuronales recurrentes y redes generativas de confrontación.

Además del desarrollo de hardware y software que permiten la aplicación exitosa. En la Figura 2 se observa la evolución e incremento de los artículos en del Machine Learning en las geociencias.

Figura 2

Trabajos con Machine Learning en Geociencias



Nota: Fuente adaptado de Dramsch (2019).

El autor Shi-hong Zhanga, et al. (2019). “Development and future prospects of quantitative mineral assessment in China”, describe y resumen el desarrollo de teorías, métodos, tecnologías y software para la evaluación de los recursos minerales de China, entre ellos la anomalía geológica, método de predicción cuantitativa de tres componentes, área de búsqueda de minerales 5P, método de información integrada, modelado de procesos no lineales y fractales, mapeo de potencial mineral tridimensional, etc.

Fraser, et al (2019) “A New Method for Data Integration and Integrated Data Interpretation: Self-Organising Maps”; concluye que el análisis y la interpretación integral de los datos obtenidos hoy en día por los exploradores sigue siendo un desafío importante y propone un enfoque computacional basado en mapas auto organizados Self Organising Maps (SOM). Este mapa es una representación bidimensional ordenada del conjunto de datos de entrada multidimensional, que muestra las relaciones entre las muestras de entrada, puede ayudar a comprender y sintetizar dichos datos.

En Latinoamérica el alto gasto económico que se generan en las operaciones, como es el caso de procesamiento del mineral, genera la necesidad de plantear una metodología aprendizaje supervisado en el control de los ensayos geometalúrgicos; como

lo describe Carrillo et al. 2019 en su tesis “Modelamiento de variables geometalúrgicas basado en ciencia de datos utilizando interpretación geológica, análisis químico y mineralógico de sondajes”.

A nivel nacional, la integración de metodologías basadas en machine learning dentro de la industria minera representa un campo con amplias oportunidades de desarrollo, dado que su aplicación sistemática aún no se ha consolidado. En este contexto, la presente investigación propone el diseño de modelos predictivos para la caracterización mineralógica, fundamentados en datos de alta confiabilidad derivados de protocolos de control de calidad existentes.

El empleo de la metodología de machine learning requiere de una amplia cantidad de datos, tales como los obtenidos con el equipo TerraSpec 4. Esta herramienta facilita la obtención de firmas espectrales asociadas a la mineralogía de interés económico, fundamentales para la caracterización del yacimiento.

La determinación de las asociaciones mineralógicas permite definir dominios, los cuales tienen relación directa con los cluster económicos.

Por lo expuesto, se plantea la pregunta general del trabajo de investigación:

¿Cómo la imprecisión de la delimitación de los dominios mineralógicos de las alteraciones impacta en el modelo de estimación del recurso mineral?

Y preguntas específicas:

- ¿Ausencia de vinculación sistemática de la anomalía espectral al modelo de estimación de recursos?
- ¿Débil definición de clusters económicos del modelo de estimación de recursos?
- ¿Indefinición en la elección de un algoritmo con el mejor rendimiento para la delimitación de los dominios mineralógicos de las alteraciones?

1.3 Objetivo del estudio

1.3.1 Objetivo general

Mejorar la precisión en la delimitación de los dominios mineralógicos de las alteraciones que impacta en el modelo de estimación del recurso mineral.

1.3.2 Objetivos específicos

- Desarrollar una metodología que garantice la vinculación sistemática de la anomalía espectral al modelo para la estimación de recursos, asegurando la integración de los datos de la operación.
- Definición de clusters económicos relacionados entre la mineralogía de alteración hidrotermal y el modelo de estimación de recursos.
- Elección del algoritmo con el mejor rendimiento para la delimitación de los dominios mineralógicos, el cuál proporciona los mejores resultados en términos de precisión y aplicabilidad en la estimación de recursos.

1.4 Antecedentes

En el ámbito internacional se han realizado algunos trabajos de investigación que desarrollaron aplicaciones de machine learning en geología.

El uso de técnicas y herramientas que ayudan a mejorar la interpretación como el machine learning están siendo usadas en minería para el área de operaciones. Siendo pocos los trabajos del uso de machine learning en geología, a pesar de que se dispone de grandes densidades de datos estos no son usados adecuadamente, uno de los trabajos que usa aprendizaje automatizado es el de Cate, Antoine et al. (2018) "Machine learning as a tool for geologists" que describe un flujo de trabajo que usa las propiedades físicas de la roca y el aprendizaje automático para predecir la presencia de oro en el núcleo de perforación, lo que ayudaría a los geólogos a optimizar el muestreo para el análisis en laboratorio.

Otro trabajo de Cate, Antonie et al. (2018) es "Classification of lithostratigraphic and alteration 1 units from drillhole lithogeochemical data using machine learning: a case study from the Lalor volcanogenic massive sulphide deposit, Snow Lake, Manitoba, Canada" donde discrimina las unidades litológicas volcánicas y los tipos de alteración presentes en el depósito de sulfuros masivos volcanogenicos de Lalor Zn-Cu-Au. Contrastando los métodos de Support Vector Machine y Ensemble en base a diferentes conjuntos de

variables derivadas de la litogeoquímica. Obteniendo resultados con altas tasas de coincidencia.

Kobussen, Alan et al. (2017) "Aplicación of Machine Learning Techniques to Exploration: An Example Using Self-Organising Maps for Granite Data" muestra la aplicación de aprendizaje automático para ello genera un mapa auto organizado para caracterizar e identificar la composición de los Granitos, en base a las variables de ocho elementos principales para la serie del granito (SiO_2 , TiO_2 , Al_2O_3 , Cr_2O_3 , FeO , MnO , MgO , CaO).

El autor Yongliang Chen et al. (2017). "Application of one-class support vector machine to quickly identify multivariate anomalies from geochemical exploration data", estudio los sedimentos de arroyos del distrito de Lalingzaohuo en la provincia de Qinghai, China. En base al algoritmo de aprendizaje One-Class Support Vector Machine (OCSVM) y comparándolo con el algoritmo Continuous Restricted Boltzmann Machine (CRBM), obteniendo buenos resultados para identificar las anomalías geoquímicas multivariadas en los sedimentos, siendo las anomalías identificadas por el modelo OCSVM ocupan el 19% del área de estudio y contienen el 82% de los yacimientos mineros conocidos; y las anomalías identificadas por el modelo CRBM ocupan el 35% del área de estudio y contienen 88% de los depósitos de mineral.

El autor Saeid Esmaeiloghli, et al. (2019). "Optimizing grade classification model of mineralized zones using a learning method based on harmony search algorithm", utilizó el algoritmo Harmony Search Learning (HSL), que es un algoritmo de aprendizaje automático metaheurístico, buscando clasificar el conjunto de datos de cuadrícula de Cu y Mo del prospecto mineral Kooh-Panj. para obtener un modelo adecuado para la distribución espacial de las clases de ley. Una comparación de los resultados del enfoque propuesto con los del agrupamiento convencional de K-Medias, sugirió que el uso del método HSL tiene un rendimiento superior del 25 %.


El autor Tao Sun, et al. (2019). "GIS-based mineral prospectivity mapping using machine learning methods: A case study from Tongling ore district, eastern China",

compara los métodos de aprendizaje automático, support vector machine (SVM) artificial neural networks (ANN) y random forest (RF), para realizar el mapeo prospectivo del distrito minero de Tongling al este de china, que dieron como resultado 12 mapas predictivos, siendo el modelo Random Forest el que tuvo mejor resultados de precesión y exactitud.

En la Figura 3 se muestra el modelo Random Fores usado por el autor para mostrar el aprendizaje supervisado.

Figura 3

Diagrama de clasificación para el algoritmo Random Forest



Nota: Fuente Tao Suna, (2019).

El autor Christopher, at el. (2020). “A machine learning approach to tungsten prospectivity modelling using knowledge-driven feature extraction and model confidence”, propone un modelo prospectivo de aprendizaje automático basado en datos para la mineralización de tungsteno, además de darle importancia a una evaluación apropiada y desarrolla una nueva métrica de confianza (CM, Confidence Metric) para generar objetivos de exploración refinados y robustos. Usando para ello el algoritmo Random Forest que emplea para modelar datos de evidencia geológica geoquímica y geofísica.

1.5 Hipótesis

1.5.1 Hipótesis general

La correcta delimitación de los Dominios Geológicos impacta favorablemente en el modelo geológico de estimación.

1.5.2 Hipótesis específicas

- Existe impacto favorable con la implementación de la metodología que vincula sistemáticamente la anomalía espectral al modelo de estimación de recurso.
- El fortalecimiento del clúster económico con la identificación de las relaciones entre la mineralogía de interés reduce la incertidumbre en el modelo de estimación de recursos.
- La elección de un algoritmo adecuado impactara favorablemente para la delimitación de los Dominios Geológicos.

Capítulo II. Marcos teórico y conceptual

2.1 Asociaciones mineralógicas en yacimientos epitermales

Los yacimientos epitermales de alta sulfuración (HS, por sus siglas en inglés) son sistemas hidrotermales someros (<1.5 km de profundidad) asociados a magmatismo calc-alcalino, donde los fluidos que lo generan son extremadamente ácidos, oxidantes y ricos en volátiles (principalmente SO₂). Suelen contener mineralización aurífera en forma de Au refractario y sulfuros de alta sulfuración como enargita–luzonita, además de pirita masiva y, en menor medida, covelina y digenita.

Estos sistemas son caracterizados por el desarrollo de una “lithocap” o domo de alteración ácida, donde dominan minerales como alunita, caolinita, dickita, pirofilita y sílice vuggy, como lo indica Sillitoe, R. H. (1993). En su trabajo *Epithermal models: Genetic types, geometrical controls and shallow features*

Los ambientes de formación para los epitermales HS se desarrollan por encima o alrededor de intrusivos someros asociados a arcos volcánicos. Los procesos clave incluyen:

El ascenso de fluidos magmáticos ricos en SO₂, permite la formación de soluciones extremadamente ácidas por la reacción: $\text{SO}_2 + \text{H}_2\text{O} \rightarrow \text{H}_2\text{SO}_4$ que genera ambientes ácido-sulfato capaces de lixiviar intensamente las rocas huésped.

Condensación y mezcla de vapores con aguas meteóricas produciendo zonaciones verticales distintivas de alteración

Brechamiento y un control estructural, las brechas hidrotermales, freatomagmáticas o de explosión son comunes y actúan como conductos preferenciales para la mineralización.

Las alteraciones se presentan de manera zonificada, como se menciona en el trabajo de Corbett, G. J., & Leach, T. M. (1998). *Southwest Pacific Rim gold–copper systems: Structure, alteration, and mineralization*. Society of Economic Geologists y están dispuestas por:

- Zona superficial (lithocap), compuestas por Silice Vuggy (silicificación residual), alunita (blanca o rosada), caolinita, dickita, pirofilita (en zonas intermedias y profundas).
- Zona intermedia, compuesta por illita-smectita, dickita + cuarzo y transiciones a sericita en sistemas porfíricos subyacentes.
- Zona profunda, relación con sistemas porfíricos Cu–Au, Stockworks de cuarzo–sericita–pirita, presencia de sulfuros de alta sulfuración como enargita y luzonita.

La importancia económica de los epitermales HS son importantes productores de Oro, Cobre (subordinado o profundo), y Plata (localmente).

2.1.1 Asociaciones mineralógicas favorables a la mineralización

- Asociación Supergénica (oxidación) – zona de óxidos de Au, en la zona norte del Perú muchas operaciones comienzan explotando óxidos auríferos superficiales. Entre los minerales clave se tienen la goethita, hematita, jarosita, alunita secundaria y restos de sílice vuggy, estos tienen la ventaja de tener una buena recuperación metalúrgica (lixiviación más eficiente), gran parte del Au económico superficial se sitúa en esta zona.
- Asociación Alunita–Dickita–Caolinita (zona de litocap aurífero), Algunas mineralizaciones económicas de Au se alojan justo en la transición entre alunitización y sílice residual. Entre los minerales se tiene alunita primaria (K-alunita), dickita / caolinita, sílice fina microcristalina y pirita fina, se define como la zona argílica avanzada, indican cambio brusco de arcillas → sílice más masiva y la presencia de alunita con alto contenido de K (esto indica origen magmático y cercanía al centro del sistema).
- Asociación Sílice Vuggy (silicificación residual) + Pirita Aurífera (núcleo de alta ley), pirita muy fina, oro finamente diseminado y ocasionalmente hematita residual (producto de oxidación); favorable ya que representa la zona de mayor lixiviación ácida → enriquecimiento relativo de Au, el Au se aloja principalmente en pirita (framboidal o muy fina) o en poros residuales.

- Asociación de Brechas Hidrotermales con Sílice + Pirita (conductos mineralizados), las brechas hidrotermales suelen concentrar Au por su alta permeabilidad, presentan una matriz de sílice fina, pirita sobrecrecida, oro visible en oxidación (localmente), jarosita/Fe-oxihidróxidos en zonas meteorizadas, estos representan los conductos por donde circularon fluidos más reactivos → sitios de enriquecimiento.
- Asociación Enargita–Luzonita ± Covellina (transición profunda), son más profunda que la zona vuggy silica. Puede ser económica cuando hay Au asociado a sulfuros de alta sulfuración, entre los minerales se tiene enargita, luzonita, covellina / digenita, pirita y menos frecuentemente tenantita–tetraedrita, y es asociada a la raíz del sistema HS, a veces conectada a un porfido Cu–Au profundo

2.1.2 Equipos para caracterización mineralógica

Entre las herramientas que te permiten caracterizar mineralógicamente las zonas de exploración se tienen XRF portátil, Espectrómetro Raman, Cámara hiperespectral VNIR–SWIR y Fotografía de alta resolución, GPS y dron. Como lo indica el trabajo de Tolentino, V. et al. (2025). Drone-based VNIR–SWIR hyperspectral imaging applications.

- El XRF portátil analiza elementos como Al, Si, Fe, S, As, Cu, Au “limitado”, Ag, Pb, Zn, REE según modelo en roca, sondaje y suelo para guía de muestreo, con mediciones rápidas sin preparación extensa; útil para delimitar zonación de alteración, una delimitación es la identificación de Au.
- Los Espectrómetros Raman portátiles identificación mineralógica no destructiva de fases relícticas, arcillas, sulfuros y silicatos en superficie o muestras frescas, identifica de forma directa la estructura molecular, útil para distinguir silicificación vuggy, alunita vs jarosita, carbonatos, etc.
- Las cámaras hiperespectrales VNIR–SWIR montada en dron, se usan para el mapeo de alteración superficial (alunita, clorita, sericita, jarosita, sílice) a escala de área; ideal para zonación litocap y detección de halos de alteración como lo indica Tolentino, V. et al. (2025). Drone-based VNIR–SWIR hyperspectral imaging

aplications, su ventaja es la rápida cobertura de áreas extensas; identifica minerales de alteración según firmas espectrales, pero la afectan la vegetación y polvo.

Entre los equipos portátiles más avanzados se tiene Difractómetro de rayos X portátil y el XRD de seibremesa (en laboratorio móvil o campamento), la ventaja del primero es la identificación de la mineralogía cristalográfica en campo y la del segundo una mejor sensibilidad y cuantificación.

Entre los equipos de laboratorio se tienen:

- **SEM-EDS / QEMSCAN / MLA (Mineral Liberation Analyzer)**

Define mineralogía cuantitativa, texturas y reportamiento del Au (si está en sulfuros), tamaño de partícula, asociación mineralógica, su ventaja es la determinación en qué fases está el Au (p. ej. pirita framboidal, enargita, etc.), útil para geometalurgia y decisiones metalúrgicas, pero tiene un alto costo de preparación por muestra.

- **Microsonda electrónica (EPMA) / EMPA & SEM-BSE**

Para análisis puntual de sulfuros y minerales menores para composiciones precisas (p. ej. enargita composition). Complementa SEM-EDS.

- **XRD**

Para confirmación y cuantificación de fases minerales con mayor resolución

- **Análisis geoquímico de referencia: fire assay (Au) + ICP-MS / ICP-OES (multi-elemento)**

Para obtener leyes verdaderas y trazadores (As, Sb, Hg...); imprescindible para validación de XRF y estudios de dispersión.

A continuación, se muestra la Tabla 1 que es el resumen de la comparativa entre las técnicas para investigaciones en alteración hidrotermal de alta sulfuración, incluyendo sensores espectrales, técnicas mineralógicas y herramientas geoquímicas. Esta tabla está optimizada para trabajos en ambientes HS.

Tabla 1*Principales instrumentos para caracterizar asociaciones mineralógicas*

INSTRUMENTO/TÉCNICA	TIPO DE DATOS	MINERALES QUE IDENTIFICA MEJOR	RESOLUCIÓN
Espectrometro portátil SWIR (ASD TerraSpec, oreXplorer, Halo, etc.)	Firma espectral VNIR-SWIR	Arcillas (illita, caolinita, dickita, alunita, jarosita, pirofilita, cloritas, sílice amorfa)	Alta (espectral) puntual
Hiperepectral de dron/terrestre (HySpex, Specim AisaFenix)	Cubo hiperespectral	Igual que SWIR, pero en área	Muy alta (spatial 5-20 cm)
XRD de laboratorio (Difracción de rayos X)	Fases cristalinas	Todos los minerales cristalinos (cuarzo, alunita, dickita, caolinita, pirofilita, illita, jarosita, etc.)	Muy alta
QEMSCAN / MLA (SEM-Automated Mineralogy)	Mapeo modal textural	Sulfuros (pirita, enargita, covelina), óxidos y minerales de ganga	Muy alta, textual
SEM-EDS (microscopio electrónico de barrido+espectros)	Imágenes BSE + química puntual	Sulfuros, sulfatados, óxidos, textura	Alta
Microsonda electrónica (EPMA)	Composición química precisa	Sulfuros, silicatos, sulfatados	Muy alta
XRF portátil	Geoquímica elemental	Fe, As, Cu, Zn, Pb, Mo, S (aprox)	Media
ICP-MS / ICP-OES de laboratorio	Geoquímica de roca total	Elementos traza y mayoritarios	Muy alta
Petrografía óptica (lámina delgada)	Texturas, paragénesis	Sílice, arcillas, óxidos	Media
Espectroscopía Raman	Fases minerales puntuales	Sulfatados, silicatos, carbonatos	Alta
LIBS (Laser-Induced Breakdown Spectroscopy)	Composición química puntual	Elementos mayoritarios y traza	Meda
Drill-core Hyperspectral scanning (p. ej. Corescan, HyLogger)	Firma espectral+imágenes	Arcillas, alunita, pirofilita, sílice	Muy alta

Nota: Fuente elaboración propia

Existen estudios recientes que combinan firmas espectrales (hiperespectral / SWIR / VNIR) con caracterización mineralógica en contextos de alteración hidrotermal, y en algunos casos relacionados con mineralización).

Aguilera, F., Layana, S., Rodríguez-Díaz, A., González, C., & Cortés, J. (2016). Hydrothermal alteration, fumarolic deposits and fluids from Lastarria Volcanic Complex. *Andean Geology*, este trabajo integra análisis de alteración hidrotermal, mineralogía de minerales secundarios (sílice, alunita, sulfuros, sulfatados) y evaluación del entorno fisicoquímico lo cual puede ser relevante como analogía al estudiar zonas de alta sulfuración.

Géring, L., Kirsch, M., Thiele, S., De Lima Ribeiro, A., Gloaguen, R., & Gutzmer, J. (2023). Spectral characterisation of hydrothermal alteration associated with sediment-hosted Cu–Ag mineralisation in the central European Kupferschiefer. *Solid Earth*. Este estudio demuestra cómo técnicas de “hyperspectral imaging” permiten identificar, mapear y caracterizar minerales de alteración (óxidos de Fe, filosilicatos, sulfatos, carbonatos) asociados con mineralización. Muestra bien la utilidad de imágenes espectrales para delinear zonas de alteración vinculadas a sistemas sulfuro-metálicos.

Montesinos, R. (2024). Geology, alteration, and mineralization of the La Virgen high-sulfidation epithermal–porphyry district, northern Peru, Este trabajo utiliza análisis espectral SWIR + geología de campo + geoquímica para caracterizar alteraciones (alunita, dickita, cuarzo, pirofilita, arcillas) en un distrito de alta sulfuración. Es muy útil como caso local (Perú), y demuestra que la espectroscopía puede ser aplicada en ambientes silicoclásticos y volcanoclásticos.

Estos trabajos nos permiten confirmar que las técnicas espectrales (VNIR / SWIR / hiperespectral) permiten identificar minerales de alteración típicos de sistemas hidrotermales, arcillas (illita, dickita, caolinita), sílice vuggy o masiva, sulfatados como alunita, óxidos, incluso cuando la roca parece “fresca” a simple vista.

Además, la integración de firmas y sus índices espectrales derivados, más geoquímica resulta muy adecuada para identificar alteraciones favorables a mineralización (sílice, arcillas ácidas, sulfatados, sulfuros), incluso en entornos complejos. En la siguiente Tabla 2 se muestra una comparación de fortalezas y limitaciones de las herramientas.

Tabla 2

Comparativa de fortalezas y limitaciones de los algoritmos de aprendizaje automático

COMPONENTE INTEGRADO	TIPO DE DATO	MINERALES / VARIABLES CLAVE	FORTALEZA PRINCIPAL	LIMITACIONES	VALOR PARA ML Y POTENCIAL ECONÓMICO
Firmas espectrales (VNIR-SWIR)	Continuo (reflectancia)	Alunita, pirofilita, dickita, caolinita, illita, clorita, jarosita, óxidos Fe	Alta sensibilidad a minerales de alteración; detección rápida y no destructiva	No identifica suluros; afectada por superficie	Variables de alto peso en RF y ANN; excelente para zonación y clasificación
Geoquímica ICP-MS / ICP-OES	Cuantitativo	Au, Cu, As, Sb, Mo, Hg, Ag, S	Define halos y vectores geoquímicos	Coste y tiempo de laboratorio	Variables predictivas clave; alto impacto en ROC
Índices espectrales derivados	Derivado (features)	Profundidad de absorción OH ⁻ , Al-OH, Fe-OH	Reduce ruido; mejora separabilidad	Requiere calibración	Incrementa estabilidad de RF y SVM
Integración espectral + geoquímica	Multivariado	Espectro + As-S-Cu	Captura zonación hidrotermal	Requiere normalización	Mejora precisión y reduce overfitting

Nota: Fuente elaboración propia

2.1.3 Interpretación geológica de los ensambles de alteración.

La interpretación geológica de los ensambles de alteración implica analizar y comprender las características y patrones de alteración presentes en las perforaciones. La alteración geológica se refiere a cambios en la mineralogía, textura o composición química de las rocas debido a procesos geológicos, como la actividad hidrotermal, metamorfismo o meteorización, y es aquí donde el uso de machine learning como una herramienta puede disminuir tiempos y mejorar interpretaciones.

Algunos pasos y consideraciones comunes en la interpretación geológica de los ensambles de alteración son los siguientes:

- **Recopilación de Datos Geológicos:** Recolectar datos geológicos, como muestreos de rocas, información estructural y datos geofísicos. Además, datos espectrales provenientes de imágenes satelitales o sensores remotos pueden ser útiles para identificar patrones de alteración.
- **Identificación de Minerales de Alteración:** Identificar los minerales asociados con la alteración. Diferentes minerales de alteración pueden indicar diferentes procesos

geológicos. Por ejemplo, la presencia de arcillas puede sugerir alteración hidrotermal.

- **Análisis Espectral:** Utilizar técnicas espectrales para analizar firmas espectrales de las rocas. Esto implica el uso de datos espectrales para identificar patrones de absorción y reflexión que son indicativos de ciertos minerales o tipos de alteración.
- **Ensamblajes de Alteración:** Agrupar y categorizar diferentes tipos de alteración en ensambles. Los ensambles de alteración son conjuntos específicos de minerales de alteración que ocurren juntos y pueden indicar un cierto ambiente geológico.
- **Contexto Geológico:** Considerar el contexto geológico más amplio. Las alteraciones pueden estar asociadas con sistemas hidrotermales, zonas de falla, intrusiones magmáticas u otros procesos geológicos específicos.

2.2 Machine learning

Smola, Alex at el. 2008 "Introduction to Machine Learning", con la cantidad cada vez mayor de datos disponibles, hay buenas razones para creer que el análisis de datos inteligente se volverá aún más omnipresente como ingrediente necesario para el progreso tecnológico. Cuando se utilizan métodos y tecnologías para detectar tendencias y patrones en los datos recopilados de diversas fuentes, las empresas pueden responder a ellos e identificar nuevas oportunidades, tanto los datos estructurados como los no estructurados.

La construcción de un modelo predictivo permite también proponer una metodología, y es esta una de las razones por las que resulta ser una solución práctica al problema que se desarrollara en este trabajo.

En 1959, Arthur Samuel definió el aprendizaje automático como un "campo de estudio que brinda a las computadoras la capacidad de aprender sin estar programadas explícitamente". Tom M. Mitchell proporcionó una definición más formal y ampliamente citada: "Se dice que un programa de computadora aprende de la experiencia E con respecto a alguna clase de tareas T y medida de desempeño P , si su desempeño en las tareas de T , medido por P , mejora con la experiencia E "

Los dos principales enfoques del Machine Learning se clasifican en aprendizaje supervisado y aprendizaje no supervisado.

2.2.1 Aprendizaje supervisado

Paredes Daniel, 2020, en su libro “Data Science con R” define el aprendizaje supervisado, como conjunto de variables que usamos para predecir una determinada clase de salida, que tiene una data de entrenamiento y data de testeo que nos permitía validar la efectividad del modelo.

El aprendizaje supervisado se usa en problemas de clasificación y regresión, en el primer caso corresponde a variables de tipo categórico y el segundo a variables de tipo numérico.

2.2.2 Aprendizaje no supervisado

Paredes Daniel, 2020, en su libro “Data Science con R” menciona, el aprendizaje no supervisado tiene lugar cuando no se dispone de datos variables para el entrenamiento. Sólo se conocen los datos de entrada, pero no existen datos de salida output que correspondan a un determinado input. Por ello, tienen un carácter exploratorio.

Los tipos de algoritmo más habituales en aprendizaje no supervisado son: algoritmos de clustering y análisis de componentes principales (PCA).

2.2.3 Algoritmos de clasificación y regresión


Se revisarán 04 algoritmos de aprendizaje supervisado, y la diferencia entre ellos depende de la variable, en el caso de variables discretas son de clasificación y variables continuas serán de regresión.

2.2.3.1 Método K- Vecinos más cercanos (K-NN). Es un método de clasificación supervisada, que estima el valor de la probabilidad a posteriori de que un elemento x pertenezca a una clase en particular a partir de la información proporcionada por el conjunto de prototipos. La regresión K-NN se calcula simplemente tomando el promedio del punto k más cercano al punto que se está probando. En la siguiente Figura 4 se muestran 12 muestras pertenecientes a 02 clases distintas, y una muestra x , la

muestra x se ubicará dentro de la clase 1 o la clase 2, dependiendo esto de la menor distancia a obtener, Parra, Francisco (2019).

Figura 4

Algoritmo K-NN mostrando 2 clases



Nota: Fuente Parra Francisco, (2019) "Estadística y Machine Learning con R"

Para calcular las distancias generalmente se usa la distancia Euclidiana, que mide la distancia "recta" entre dos puntos en el espacio n -dimensional, cuya formulación se muestra en la siguiente ecuación (1):

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

Donde:

d = Distancia Euclidiana

x_i, x_j = Valores de posición

Adicional hay otras ecuaciones como la Manhattan, ecuación (2) que es la suma de las distancias absolutas entre las coordenadas. Útil cuando los datos tienen estructuras lineales o ejes preferidos

$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2)$$

Donde:

d = Distancia Euclidiana

X_i, X_j = Valores de posición

Y la ecuación (3) de Minkowski, que es una generalización de las distancias Euclidiana y Manhattan.

$$d(x, y) = (\sum_{i=1}^n |x_i - y_i|^p)^{1/p} \quad (3)$$

Donde:

d = Distancia Euclidiana

X_i, X_j = Valores de posición

$p = 1$ es la distancia Manhattan y $p = 2$ es la distancia Euclidiana. Este valor de p es un hiperparámetro que también puede ser ajustado.


El algoritmo K-Nearest Neighbors (K-NN), aunque conceptualmente más simple, ha sido utilizado como herramienta exploratoria y como modelo base para evaluar la separabilidad natural de los ensamblajes mineralógicos en el espacio de atributos. Su aplicación permite una primera aproximación a la estructura de los datos y a la coherencia interna de las asociaciones mineralógicas; sin embargo, su desempeño se ve limitado en datasets de alta dimensionalidad y con ruido, condiciones típicas de los estudios espectrales y geoquímicos avanzados (Hastie et al., 2017).

2.2.3.2 Máquina de vectores de soporte (MVS). Vapnik (1963, 1995, 1998) introdujo y desarrolló el aprendizaje de la máquina de vectores de soporte (SVM) a partir de la teoría del aprendizaje estadístico. Hay dos tipos de máquinas de vectores de soporte; máquinas de clase vectorial para problemas de clasificación y máquinas de regresión vectorial para resolver problemas de regresión. El problema de clasificación de SVM se configura como un problema de optimización cuadrática con restricciones lineales que se puede resolver utilizando un Lagrangiano.

Para ilustrar este comportamiento geométrico, en la Figura 5 se presenta de manera esquemática cómo el algoritmo busca maximizar el margen de separación entre clases distintas mediante un hiperplano óptimo respaldado por los vectores de soporte.

Figura 5

Algoritmo Maquinas Soporte Vector



Nota: Fuente Parra Francisco, (2019) "Estadística y Machine Learning con R"

Las Máquinas de Soporte Vectorial (SVM) han sido ampliamente aplicadas en la clasificación de datos espectrales e hiperespectrales debido a su elevada capacidad de generalización y su eficiencia en la delimitación de fronteras no lineales entre clases. Mediante el uso de kernels no lineales, como el de base radial (RBF), las SVM permiten discriminar ensamblajes mineralógicos con respuestas espectrales muy similares, por ejemplo, alunita versus jarosita o dickita versus caolinita, lo cual resulta crítico para diferenciar zonas de alteración argílica avanzada asociadas a mineralización primaria frente a dominios supergénicos o estériles (Cracknell & Reading, 2014; van der Meer et al., 2012).

2.2.3.3 Modelo Árbol de Decisión (Tree). Los árboles de decisión son algoritmos utilizados en aprendizaje supervisado para realizar tareas de clasificación y regresión. Estos árboles son estructuras de tipo árbol donde cada nodo interno representa una decisión basada en una característica específica, cada rama representa el resultado de esa decisión, y cada hoja del árbol representa la etiqueta de clasificación (en el caso de clasificación) o el valor predicho (en el caso de regresión), este esquema se muestra en la Figura 6.

Los conceptos clave relacionados con los árboles de decisión son los siguientes:

- **Nodo Raíz:**

Este es el primer nodo del árbol y representa la característica que mejor separa los datos de entrenamiento en términos de la tarea que se está abordando.

- **Nodos Internos:**

Representan decisiones basadas en características específicas. Cada nodo interno tiene ramas que representan los posibles resultados de la prueba de esa característica.

- **Ramificaciones (o Ramas):**


Representan los resultados posibles de la prueba realizada en un nodo interno. Cada rama lleva a un nodo hijo o a una hoja.

- **Hojas (o Nodos Hoja):**

Representan las etiquetas de clasificación o los valores predichos. Cuando se llega a una hoja, se ha tomado una serie de decisiones y se ha llegado a una conclusión.

Figura 6

Algoritmo Árbol de Decisión



Nota: Fuente Parra Francisco, (2019) "Estadística y Machine Learning con R"

El proceso de construcción de un árbol de decisión implica seleccionar la mejor característica para dividir los datos en cada nodo, de manera que la información se distribuya de manera eficiente entre las ramas. Los algoritmos de construcción de árboles de decisión buscan maximizar la homogeneidad de las clases (en el caso de clasificación) o minimizar la varianza (en el caso de regresión) en cada nodo.

Algunos algoritmos populares para la construcción de árboles de decisión incluyen CART (Classification and Regression Trees) y ID3 (Iterative Dichotomiser 3). Además, existen variaciones y mejoras, como Random Forests y Gradient Boosted Trees, que combinan múltiples árboles para mejorar la precisión y robustez del modelo.


2.2.3.4 Modelo de bosque aleatorios (Random Forest). El bosque aleatorio es un método de aprendizaje conjunto utilizado para clasificación, regresión y otras tareas. Fue propuesto inicialmente por Tin Kam Ho y desarrollado por Leo Breiman (Breiman, 2001) y Adele Cutler.

Los árboles de decisión son diagramas con construcciones lógicas, muy similares a los sistemas de predicción basados en reglas, que sirven para representar y categorizar una serie de condiciones que ocurren de forma sucesiva, para la resolución de un problema. Los árboles de decisión están compuestos por nodos ($x_1 < c$) interiores, nodos terminales ($X_1 < b$) y ramas que emanan de los nodos interiores. Cada nodo interior en el árbol contiene una prueba de un atributo, y cada rama representa un valor distinto del atributo. Siguiendo las ramas desde el nodo raíz hacia abajo, cada ruta finalmente termina en un nodo terminal creando una segmentación de los datos, Parra, Francisco (2019).

En la Figura 7 se muestra en un plano cartesiano con 02 características, a partir de los valores a , b y c , se puede definir una frontera de decisión, los que queden por dentro serán rojo y los que caen fuera será celeste. La desventaja de los arbores de decisión es la alta varianza, por lo que el método complementario a usar son los bosques aleatorios.

Figura 7

Grafica de la lógica del árbol de decisión



Nota: Fuente Parra Francisco, (2019) "Estadística y Machine Learning con R"

Todos los algoritmos se pueden ajustar con una serie de varios parámetros específicos de algoritmos que contribuyen significativamente a la solidez, la varianza y el sesgo de la clasificación. La elección de los mejores parámetros se realiza mediante el proceso de formación / validación. Como referencia se toma el trabajo de Cate et al., 2018 con Orange.

También Random Forest (RF) destaca por su capacidad para manejar datos ruidosos, correlacionados y de alta dimensionalidad, características frecuentes en datasets mineralógicos y espectrales. Este método ha demostrado un alto desempeño en la clasificación de ensamblajes mineralógicos tales como sílice residual (vuggy silica), asociaciones pirofilita-alunita y dickita-caolinita, empleando como variables de entrada firmas espectrales VNIR-SWIR y concentraciones geoquímicas de elementos trazadores como As, S, Cu y Mo. La estructura de ensamble del RF reduce significativamente el riesgo de sobreajuste y permite evaluar la importancia relativa de las variables, facilitando la identificación de minerales indicadores del potencial económico (Breiman, 2001; Carranza, 2008).

2.2.3.5 Redes neuronales. Las redes neuronales artificiales (Neuronal Network), también conocidas como sistemas conexionistas, constituyen un modelo

computacional inspirado en el funcionamiento del cerebro humano. Estas redes se desarrollaron a partir de múltiples avances científicos a lo largo del tiempo, y actualmente son una herramienta fundamental en el campo del aprendizaje automático (LeCun, Bengio & Hinton, 2015; Schmidhuber, 2015).

En esencia, una red neuronal está compuesta por un conjunto de unidades denominadas neuronas artificiales, las cuales se encuentran interconectadas mediante enlaces que permiten la transmisión de señales entre ellas. Cuando se introduce información en la red, esta atraviesa diferentes capas de procesamiento, en las que se llevan a cabo operaciones matemáticas que transforman dicha información hasta generar una salida (Goodfellow, Bengio & Courville, 2016).


Cada conexión entre neuronas está asociada a un valor numérico llamado peso sináptico, que determina la influencia de una neurona sobre otra. Estos pesos pueden potenciar o inhibir la activación de las neuronas conectadas, y son ajustados durante el proceso de entrenamiento de la red para optimizar su rendimiento. Además, al final de cada neurona suele aplicarse una función matemática denominada función de activación, la cual permite introducir no linealidades y controlar el paso de la señal hacia la siguiente capa. Esta función actúa como un umbral que regula si la señal se transmite o no, siendo clave para la capacidad de la red de modelar relaciones complejas en los datos.

Las redes neuronales han demostrado una gran eficacia en tareas como clasificación, regresión y reconocimiento de patrones en datos multidimensionales, incluyendo datos geocientíficos complejos.

La arquitectura típica de estos modelos se fundamenta en una organización multicapa. Como se ilustra de manera esquemática en la Figura 8, el flujo de la información se propaga desde una capa de entrada (donde ingresan los atributos espectrales o geoquímicos), pasa a través de una o más capas ocultas encargadas de la extracción de patrones abstractos no lineales, y culmina en una capa de salida que define la clasificación final.

Figura 8

Grafica de Redes Neuronales



Nota: Fuente adaptado de LeCun, Bengio & Hinton, 2015

Las arquitecturas profundas (deep learning) de las Redes Neuronales, han demostrado un desempeño superior en escenarios donde se dispone de grandes volúmenes de datos, tales como imágenes hiperespectrales, escaneos automatizados de testigos de perforación y mapas mineralógicos de alta resolución. Estos modelos son capaces de capturar relaciones jerárquicas complejas entre firmas espectrales, asociaciones mineralógicas y variaciones geoquímicas, permitiendo la identificación de patrones sutiles vinculados a la presencia de mineralización aurífera y cuprífera en sistemas epitermales de alta sulfuración. No obstante, su aplicación requiere un control riguroso del sobreajuste mediante técnicas de regularización y validación cruzada, especialmente en contextos geológicos altamente heterogéneos (Bishop, 2006; Hastie et al., 2017).

2.2.4 Matriz de confusión

Una matriz de confusión, también conocida como matriz de error, nos permite la visualización del rendimiento de un algoritmo, generalmente uno de aprendizaje

supervisado (en el aprendizaje no supervisado generalmente se denomina matriz coincidente). Cada fila de la matriz representa las instancias en una clase predicha, mientras que cada columna representa las instancias en una clase real (o viceversa). El nombre se deriva del hecho de que hace que sea fácil notar si el sistema confunde dos clases, Parra, Francisco (2019).

Para comprender la distribución de las clasificaciones, en la Tabla 3 se detalla la estructura matriz, organizando los aciertos y fallos del modelo a través de los cuadrantes de verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos.

Tabla 3

Matriz de confusión

PREDICCIÓN \ REALIDAD	REALMENTE ES POSITIVO	REALMENTE ES NEGATIVO
Predicho como positivo	Verdaderos Positivos (VP)	Falsos Positivos (FP)
Predicho como negativo	Falsos Negativos (FN)	Verdaderos Negativos (VN)

Nota: Fuente adaptado de Parra Francisco, (2019) "Estadística y Machine Learning con R"

Para poder analizar el rendimiento de los clasificadores se tienen los parámetros de exactitud, sensibilidad y especificidad que evaluarán los resultados de los algoritmos en función de la cantidad de verdaderos y falsos de la matriz de confusión.

2.2.4.1 Exactitud. La exactitud del modelo (Accuracy en inglés), representa la proporción de veces que el algoritmo predijo correctamente respecto al total de datos evaluados. Esta métrica se calcula a partir de los componentes de la matriz de confusión mediante la ecuación (4):

$$Exactitud = \frac{VP+VN}{VP+VN+FP+FN} \quad (4)$$

Donde:

VP = Verdaderos positivos

VN = Verdaderos negativos

FP = Falso positivos

FN = Falso negativos

El accuracy del modelo es la proporción de veces que el algoritmo predijo correctamente, respecto al total de datos evaluados.

2.2.4.2 Precisión. Mide la calidad de las predicciones positivas del modelo. Responde a la pregunta: De todas las muestras que el algoritmo etiquetó como un dominio de alteración específico como ejemplo. Argílica Avanzada, son realmente correctos. Matemáticamente este indicador se define mediante la ecuación (5):

$$Precisión = \frac{VP}{VP+FP} \quad (5)$$

Donde:

VP = Verdaderos positivos

FP = Falso positivos

2.2.4.3 Exhaustividad. Conocida también por Recall, Sensibilidad o True Positive Rate, mide la proporción de casos reales positivos que el algoritmo es capaz de identificar correctamente. Para efectos de esta investigación, un ejemplo representativo consiste en la capacidad del modelo para detectar correctamente zonas con alteración

Esta métrica se calcula a partir de los componentes de la matriz de error mediante la ecuación (6):

$$Exhaustividad = \frac{VP}{VP+FN} \quad (6)$$

Donde:

VP = Verdaderos positivos

FN = Falso negativos

2.2.5 Métrica de Rendimiento ROC

La curva ROC (Receiver Operating Characteristic) es una herramienta muy útil para evaluar el rendimiento de los modelos de clasificación, especialmente cuando trabajamos con problemas de clasificación binaria. Aunque sus orígenes se encuentran en estudios sobre detección de señales durante la Segunda Guerra Mundial, hoy en día se ha

convertido en un estándar en campos tan diversos como la medicina, la estadística y el aprendizaje automático (Fawcett, 2006).

Esta curva permite visualizar de forma clara cómo se comporta un modelo al distinguir entre clases positivas y negativas.

Lo hace al graficar dos métricas fundamentales:

- **La tasa de verdaderos positivos (TVP)**

Que indica cuántos casos positivos fueron correctamente identificados, y

- **La tasa de falsos positivos (TFP)**

Que muestra cuántos casos negativos fueron erróneamente clasificados como positivos (Hanley & McNeil, 1982).

En el contexto de la presente investigación, esta métrica permite evaluar la capacidad de los algoritmos para discriminar entre ensambles de alteración con firmas espectrales o geoquímicas de transición.


Por ejemplo, si definimos el dominio de alteración Argílica como la clase positiva y el dominio de alteración Fílica como la clase negativa, la tasa de verdaderos positivos (TVP) medirá la fracción de muestras de alteración Argílica correctamente clasificadas por el modelo.

Por otro lado, la tasa de falsos positivos (TFP) registrará aquellas muestras que, siendo en realidad de alteración Fílica (sericita/cuarzo), fueron erróneamente clasificadas como Argílica (caolinita/esmectita) debido al solapamiento de ciertos elementos guía.

Como se ilustra en la Figura 9, un modelo predictivo óptimo proyectará su curva hacia el vértice superior izquierdo, alejándose de la diagonal de clasificación aleatoria y maximizando el Área Bajo la Curva (AUC), donde un valor de 0.93 denota una alta eficiencia en la zonación automatizada de estos dominios hidrotermales.

Figura 9

Grafica de la curva ROC



Nota: Fuente adaptado de Fawcett, 2006

Una de las principales ventajas de usar la curva ROC es que nos permite evaluar el modelo más allá de una única medida como la exactitud, que puede ser engañosa en conjuntos de datos desbalanceados. Además, nos da la posibilidad de analizar el rendimiento del modelo en diferentes umbrales de decisión, lo cual es muy útil cuando los errores tienen distintos costos

Una forma común de resumir la información que proporciona la curva ROC es mediante el área bajo la curva (AUC, por sus siglas en inglés). Esta métrica nos dice, en términos generales, qué tan bien puede el modelo distinguir entre clases. Un AUC cercano a 1 indica un modelo excelente, mientras que un valor cercano a 0.5 sugiere un rendimiento similar al azar (Bradley, 1997).

En resumen, la curva ROC es una herramienta poderosa para entender cómo funciona un modelo de clasificación y para compararlo con otros. Su uso complementario con otras métricas permite tomar decisiones más informadas, especialmente en contextos donde la precisión del modelo es crítica.

La evaluación comparativa del desempeño de estos algoritmos mediante métricas como precisión, sensibilidad, F1-score y curvas ROC–AUC ha evidenciado que los métodos basados en ensambles, como Random Forest, y los modelos de aprendizaje

profundo presentan los mejores resultados en la predicción de ensamblajes mineralógicos de potencial económico. Valores elevados de AUC reflejan una alta capacidad discriminatoria entre dominios mineralizados y no mineralizados, reforzando la utilidad del machine learning como herramienta predictiva en exploración minera (Carranza, 2008; Cracknell & Reading, 2014).

En la siguiente Tabla 4 se muestra la comparativa evaluando los modelos Random Forest, SVM, Redes Neuronales (MLP/Deep Learning) y K-NN bajo criterios clave: eficiencia, precisión, rendimiento computacional, comportamiento en ROC-AUC y riesgo de overfitting.

Tabla 4

Resumen de estudios previos que aplican algoritmos de aprendizaje automático en exploración minera

ALGORITMO	EFICIENCIA GENERAL	PRECISION TIPICA	RENDIMIENTO COMPUTACIONAL	ROC-AUC	RIESGO DE OVERFITTING
Random Forest (RF)	Alta	80%-95%	Medio (entrenamiento moderado, inferencia rápida)	0.85-0.95	Bajo-Medio (la aleatoriedad lo controla)
Support Vector Machine (SVM)	Alta (si se tunea bien)	80%-96%	Medio-alto (depende del kernel)	Excelente con kernels RBF	Medio (si C es muy alto)
Redes Neuronales (ANN/MLP/Deep Learning)	Muy alta	-85%-98%	Alto (entrenamiento costoso)	- (si se optimiza)	Alto (si no se regula)
K-Nearest Neighbors (K-NN)	Media	-70-88%	Bajo en entrenamiento, alto en inferencia	0.75-0.90	Bajo (modelo no para métrico)

Nota: Fuente elaboración propia

En conjunto, la integración de técnicas de machine learning con la caracterización mineralógica y espectral permite no solo optimizar la identificación de ensamblajes favorables, sino también mejorar la comprensión de la zonación hidrotermal y de los procesos génicos que controlan la formación de depósitos epitermales de alta sulfuración.

Este enfoque representa un avance significativo hacia modelos de exploración más cuantitativos, reproducibles y orientados a la reducción del riesgo geológico, particularmente en distritos complejos como los del norte del Perú (Richards, 2011; Pontual et al., 2012).

Capítulo III. Desarrollo del trabajo de investigación


El alisáis se realizará en la unidad minera de Tantahuatay, que es una unidad minería de tajo abierto operado por Cía. Minera Coimolache S. A. Tantahuatay es yacimiento epitermal de alta sulfuración Au-Ag que profundiza a un pórfido con sulfuros Cu-Au, que se encuentra en un campo volcánico situado en el sector nor-oeste del Distrito de Hualgayoc. El trabajo se enfocará en obtener un modelo de alteración hidrotermal a partir de los datos obtenidos con el equipo de espectrometría, mediante el testeo de los algoritmos de Machine Learning.

3.1 Ubicación

La unidad minera Tantahuatay, se encuentra ubicada al norte del Perú en los distritos de Chugur y Hualgayoc, perteneciente a la provincia de Hualgayoc, departamento de Cajamarca, a una altura promedio de 4000 m.s.n.m., como se ve en la Figura 10. La ruta es accesible desde Cajamarca por carretera asfaltada/afirmada de 85 km para un tiempo promedio de dos horas. La concesión minera de Cía. Minera Coimolache S. A., está conformado por 21,445 ha en 27 concesiones. La participación societaria incluye a las empresas Southern Perú (44 %), Buenaventura SAA. (40 %) y Espro SAC. (16 %).

Figura 10

Mapa de localización de la unidad Tantahuatay



Nota: Fuente Buenaventura, equipo de geología mina (2019).

La unidad minera Tantahuatay, abarca 6 depósitos cuyas reservas y recursos han sido estimados:

- Tantahuatay-2,
- Tantahuatay-4 (Extensión NO),
- Tantahuatay-5,
- Mirador Norte,
- Mirador Sur y
- Ciénaga Norte.

Adicionalmente existen otros depósitos en actual exploración. El primer depósito empezó su producción de oro a mediados del 2011 hasta la fecha. El minado en el depósito Tantahuatay-2 es mecanizado, en bancos que al inicio en la fase 1 tuvieron 6 metros de altura y luego en la fase 2 de minado fue incrementado a 8 metros que es el que usa hasta la fecha. El mineral se explota con excavadora y volquetes, los que son enviados al pad de lixiviación.

3.2 Geología local

En cuanto a la geología local, el basamento cretácico, que abarca desde aproximadamente 135 a 91 millones de años (Ma), consiste en una secuencia de rocas que incluye 300 metros de areniscas cuarzosas y lutitas de la Formación Farrat. Esta secuencia está en discordancia con horizontes delgados de lutitas y limonitas de la Formación Inca. Luego, se encuentran 300 metros de calizas nodulares y margas de la Formación Chulec, seguidas de calizas bituminosas y lutitas negras de la Formación Pariatambo. Finalmente, se depositaron capas de calizas grises y niveles delgados de lutitas de la Formación Yumagual, con un espesor que varía entre 200 y 400 metros.

Las rocas sedimentarias del Cretácico en esta región están plegadas y orientadas predominantemente en dirección NO-SE a E-O, lo cual se debe a las fases de deformación Inca I y II, es decir, al cinturón de pliegues Inca y las fallas inversas asociadas a estas fases. En relación con la mineralización de exoskarn en Tantahuatay y Antakori, se encuentra alojada en las Formaciones Pariatambo y Chulec.

El marco geológico del campo volcánico de Tantahuatay pertenece al Grupo Calipuy, que constituye la parte noroeste del distrito Hualgayoc-Tantahuatay. Este grupo está caracterizado por erupciones piroclásticas de pequeño volumen, con composición que varía de andesítica a dacítica. Estas erupciones precedieron y acompañaron el emplazamiento de una serie de domos volcánicos. Los domos presentan una composición calco-alcalina y contienen minerales como clinopiroxeno, hornblenda de grano fino y plagioclasas, que tienen una composición andesítica. Las relaciones estratigráficas sugieren un crecimiento del complejo de domos desde el suroeste hacia el noreste, y la forma erosionada del complejo indica que su emplazamiento estuvo influenciado por estructuras de tendencia NO (noroeste) y NE (noreste).

Las unidades volcánicas en la región se depositaron en secuencia de abajo hacia arriba y se componen de diferentes facies:

- **Facies Volcanoclásticas (VC):**

Estas facies consisten en materiales volcánicos clásticos depositados durante eventos eruptivos. Están compuestas por fragmentos de roca y ceniza volcánica.

- **Facies de Piroclásticas de Tobas de Cristales y Cristalolítica de Composición Andesítica (TCL):**

Estas facies están formadas por material piroclástico, que incluye fragmentos de cristales y cenizas, y tienen una composición andesítica.


- **Lavas Coherentes de Composición Andesítica (AND):**

Estas unidades consisten en flujos de lava de composición andesítica que se enfriaron y solidificaron.

La secuencia vertical de estas unidades volcánicas y su interrelación cronológica con los pulsos intrusivos porfídicos tempranos y tardíos del distrito se detallan e ilustran de manera integral en la columna estratigráfica distrital de la Figura 11.

Figura 11

Columna estratigráfica distrital de Tantahuatay



Nota: Fuente Buenaventura, equipo de geología mina (2019).


Estas unidades volcanoclásticas y piroclásticas están atravesadas por domos y cuerpos subvolcánicos de grano fino, tanto intra-minerales (PITAs) como tardíos (PTEe). Posteriormente, se produjo el emplazamiento de brechas freáticas, freatomagmáticas y polifásicas, con un desarrollo final de brechas hidrotermales relacionadas con la mineralización epitermal de alta sulfuración.

La distribución espacial de estos cuerpos subvolcánicos, los complejos de domos y las estructuras de brechas mapeadas en los sectores de Mirador Norte, Mirador Sur,

Ciénaga Norte y Tantauatay se pueden apreciar en el mapeo litológico superficial presentado en la Figura 12.

Figura 12

Mapeo litológico superficial de Tantauatay



Nota: Fuente Buenaventura, equipo de geología mina (2019).

3.3 Alteración hidrotermal

Tantauatay presenta cuatro de los ensamblajes de alteración de sistemas epitermales típicos de alta sulfuración definidos por los geólogos de la unidad, incluyendo un aumento en el orden de intensidad, propilítica, cuarzo - caolín (argílica), cuarzo - alunita - pirofilita (argílica avanzada) y sílice vuggy, figura 13. Las áreas de anomalías de Au en C° Tantauatay, C° Mirador, C° Ciénega y C° Peña de las Águilas están asociadas con alteración de sílice vuggy y brechas hidrotermales tempranas. Las brechas hidrotermales de varios tipos son comunes y se forman a lo largo de la vida del sistema hidrotermal. La etapa tardía dominada por la fase de vapor y la oxidación supergénica postmineral se ha superpuesto a los ensamblajes hipógenos (Tosdal, 1996).

En el yacimiento de Tantahuatay, se han identificado cuatro ensamblajes de alteración que son característicos de sistemas epitermales de alta sulfuración. Estos ensamblajes de alteración se presentan en orden de intensidad creciente:

- **Propilítica:**

Este es el primer ensamblaje de alteración y suele ser menos intenso. Se caracteriza por la presencia de minerales como clorita y epidota, que se forman en respuesta a la alteración hidrotermal.

- **Cuarzo - Caolín (Argílica):**

El segundo ensamblaje de alteración implica la presencia de minerales como la caolinita y el cuarzo. Esta etapa indica una mayor intensidad en la alteración hidrotermal.

- **Cuarzo - Alunita - Pirofilita (Argílica Avanzada):**

Este tercer ensamblaje de alteración refleja una intensidad aún mayor en el proceso de alteración hidrotermal. En esta etapa, se encuentran minerales como la alunita y la pirofilita, que son indicativos de condiciones hidrotermales avanzadas.


- **Sílice Vuggy:**

El último ensamblaje de alteración es la sílice vuggy, que representa la etapa de mayor intensidad en la alteración hidrotermal. En esta etapa, se forman cavidades o vugs en las rocas llenas de sílice. Esta alteración a menudo está asociada con la presencia de minerales hidrotermales valiosos.

La distribución espacial de estas alteraciones en los sectores de Mirador Norte, Mirador Sur, Ciénaga Norte y Tantahuatay se pueden apreciar en el mapeo litológico superficial presentado en la Figura 13.

Figura 13

Mapeo superficial de alteraciones de Tantahuatay



Nota: Fuente Buenaventura, equipo de geología mina (2019).

Las áreas donde se han detectado anomalías de oro (Au) en Tantahuatay, están relacionadas con la alteración de sílice vuggy y las brechas hidrotermales tempranas. Estas brechas hidrotermales pueden formarse en diferentes etapas de la evolución del sistema hidrotermal.

Es importante señalar que la etapa tardía del sistema hidrotermal está dominada por la fase de vapor y la oxidación supergena postmineral, que se superpone a los ensamblajes hipógenos. Esto significa que hubo una evolución continua del sistema geotérmico a lo largo del tiempo, con diferentes fases de alteración y mineralización.

3.3.1 Alteración hipógena epitermal de alta sulfuración

Los geólogos de la unidad indican que la alteración hipógena en el depósito Tantahuatay es representativa de un sistema de alta sulfuración (HS). Esta alteración es de alta intensidad y los límites del depósito están determinados por la extensión de las rocas que han experimentado alteración hidrotermal. Se observa un patrón zonal en la distribución de la alteración, que se puede describir de la siguiente manera:

- **Sílice Granular-Vuggy y Sílice Masiva (Silicificación):**

En la parte central del sistema, se encuentra una zona de silicificación intensa, caracterizada por la presencia de sílice granular-vuggy y sílice masiva. Esta área central es rica en sílice y a menudo alberga mineralización de oro.

- **Sílice - Alunita ± Pirofilita (Argílica Avanzada):**

A medida que nos alejamos del centro del sistema, encontramos una zona con sílice, alunita y, a veces, pirofilita. Esta etapa representa una alteración argílica avanzada y también puede estar asociada con mineralización de oro.

- **Alteración Caolinita - Illita ± Dickita ± Pirita (Argílica):**

Más lejos del centro, se desarrolla un conjunto de alteración que incluye minerales como caolinita, illita, dickita y pirita. Esta es una etapa de alteración argílica y puede variar en intensidad según el grado de conservación de la textura original de la roca. Se pueden distinguir tres tipos de alteración argílica según su grado de conservación.

- **Alteración Epidota, Clorita y Pirita (Propilitica):**

La zona más periférica del sistema muestra una alteración caracterizada por minerales como epidota, clorita y pirita. Esta etapa se conoce como alteración propilitica y, en este caso, es completamente estéril en términos de mineralización valiosa. Esta zona también está asociada a diques tardíos que atraviesan el sistema hidrotermal.

En términos de volumen, la alteración argílica es la más abundante en el sistema. Sin embargo, las zonas de alteración silícica y argílica avanzada son las más relevantes en términos de mineralización de oro. Estas áreas son de particular interés en la exploración y explotación del depósito de Tantahuatay debido a su asociación con la mineralización aurífera.

3.3.2 Alteración hipógena relacionada a la mineralización del tipo skarn/pórfido

Los pórfidos Sinchao, Las Gradas y Auroras son intrusiones que precedieron a las actividades volcánicas y la formación de domos en la región. Estos pórfidos tienen una

composición básicamente diorítica a tonalítica y están asociados con la formación de skarns y pórfidos que contienen oro (Au) y cobre (Cu). Estas intrusiones también muestran evidencia de alteración hidrotermal intermedia, filica y, en algunas áreas, alteración biotítica.

Los skarns, que son depósitos minerales formados por la interacción de fluidos hidrotermales con rocas sedimentarias encajantes, están espacialmente relacionados con los pórfidos dioríticos de grano medio a fino, como Sinchao, Las Gradass y Auroras. La mineralización de los skarns de endo/exo (es decir, mineralización que se encuentra tanto dentro de las rocas ígneas como en las rocas encajantes) de oro (Au) y cobre (Cu) está relacionada con las fases retrogradadas del proceso de alteración hidrotermal.

Con base en los modelos e informes técnicos internos de la unidad, se ha determinado que la mayor concentración de mineralización está restringida a los mantos y cuerpos de skarn de \$Au\$, \$Cu\$ y \$Zn\$. Estos depósitos se generaron mediante el reemplazamiento metasomático de las calizas, mudstone y packstone de la Formación Chulec; debido a su alta ley y continuidad, representan el principal objetivo económico para los planes actuales de exploración y explotación en la región.

3.4 Tipo y diseño de la investigación.

A continuación, se detalla el tipo de la investigación desde tres puntos vista:

3.4.1 Según su enfoque

Desde el punto de vista del enfoque es cuantitativo, ya que la finalidad es la comprobación de características de las alteraciones hidrotermales por medio de modelos predictivos. Usando algoritmos de aprendizaje supervisado que miden su nivel de confianza y exactitud.

3.4.2 Según su alcance

El estudio de investigación es de tipo descriptivo, correlacional y predictiva, es descriptiva debido a que caracteriza los patrones mineralógicos y geoquímicos asociados a los dominios de alteración hidrotermal identificados en los sondeos, es correlacional porque evalúa la relación entre las variables espectrales, geoquímicas y mineralógicas

obtenidas mediante espectrometría de reflectancia y análisis geoquímicos. y es predictiva debido a que emplea algoritmos de aprendizaje automático para clasificar y predecir dominios de alteración hidrotermal, determinando el desempeño y eficiencia de distintos modelos aplicados a datos espectrales y geoquímicos.

3.4.3 Diseño de investigación

El tipo de diseño es no experimental de tipo analítico-computacional, ya que la investigación basada en aprendizaje automático supervisado y no supervisado, y requiere de registros de datos de ensayos de espectrometría históricos, y no se está generando información extra.

3.5 Variables e indicadores

3.5.1 Variables independientes (VI)

- Leyes de muestras de las muestras de perforación
- Firma espectral de ensambles mineralógicos de interés
- Distribución espacial
- Parámetros de los algoritmos

3.5.2 Variable dependiente (VD)

Dominio Geológico de Alteración

3.5.3 Indicadores

- Nro. de Muestras
- Porcentaje abundancia
- Localización
- Porcentaje de precisión de los modelos predictivos
 - Exactitud
 - Precisión
 - Exhaustividad
 - Curva ROC

3.6 Matriz de consistencia

Tabla 5

Matriz de consistencia

PROBLEMAS	OBJETIVOS	HIPOTESIS	OPERACIONES DE VARIABLES
Problema General	Objetivo General	Hipótesis General	Variable independiente (VI)
¿Cómo la imprecisión de la delimitación de los dominios mineralógicos de las alteraciones impacta en el modelo de estimación del recurso mineral?	Mejorar la precisión en la delimitación de los dominios mineralógicos de las alteraciones que impacta en el modelo de estimación del recurso mineral.	La correcta delimitación de los Dominios Geológicos impacta favorablemente en el modelo geológico de estimación.	■ Leyes de muestras de las muestras de perforación ■ Firma espectral de ensambles mineralógicos de interés ■ Muestras Geoquímicas ■ Densidad muestral ■ Parámetros de los algoritmos
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas	Variable dependiente (VD)
■ ¿Ausencia de vinculación sistemática de la anomalía espectral al modelo de estimación de recursos? ■ ¿Débil definición de clusters económicos del modelo de estimación de recursos? ■ ¿Indefinición en la elección de un algoritmo con el mejor rendimiento para la delimitación de los dominios mineralógicos de las alteraciones?	■ Desarrollar una metodología que garantice la vinculación sistemática de la anomalía espectral al modelo para la estimación de recursos, asegurando la integración de los datos de la operación. ■ Definición de clusters económicos relacionados entre la mineralogía de alteración hidrotermal y el modelo de estimación de recursos. ■ Elección del algoritmo con el mejor rendimiento para la delimitación de los dominios mineralógicos, el cuál proporciona los mejores resultados en términos de precisión y aplicabilidad en la estimación de recursos.	■ Existe impacto favorable con la implementación de la metodología que vincula sistemáticamente la anomalía espectral al modelo de estimación de recurso. ■ El fortalecimiento del cluster económico con la identificación de las relaciones entre la mineralogía de interés reduce la incertidumbre en el modelo de estimación de recursos. ■ La elección de un algoritmo adecuado impactara favorablemente para la delimitación de los Dominios Geológicos.	■ Dominio Geológico ■ Indicadores ■ Valor de la ley ■ Ratio de abundancia ■ Nro. de Muestras ■ Porcentaje abundancia ■ Localización ■ Parámetros de precisión de los modelos predictivos: exactitud, precisión, exhaustividad y curva ROC

Nota: Fuente elaboración propia

3.7 Flujograma metodológico


Muchos de los algoritmos de Machine Learning son capaces de aprender automáticamente asignaciones complejas arbitrarias de datos de entrada y salida, al mismo tiempo de poder admitir entradas multivalentes y pronósticos de varios pasos. Dentro de esta rama de la inteligencia artificial, existen diversos algoritmos que pueden ser utilizados para un sin fin de objetivos, como los mencionados en el marco teórico. Por ello, es clave reconocer el flujo de trabajo que se debe llevar a cabo con el fin de elegir los ajustes de manera óptima. En la siguiente Figura 14 se muestra las 6 etapas de manera

general que involucran los procesos para la predicción de la alteración, es importante mencionar, que este flujo contempla los datos de terraspec y datos geoquímicos de sondajes.

Para el desarrollo de la investigación se usará el Software Orange, software de programación gráfica desarrollado por la Universidad de Ljubljana, con más de 24 años desarrollo y de código abierto, que cuenta con una interfaz de programación visual, Orange usa bibliotecas comunes de código abierto de Python como numpy, scipy y scikit-learn.

Figura 14

Flujo general para la predicción de dominios de alteración



Nota: Fuente elaboración propia

Etapa 1. Recolección de Datos:

Cosiste en la colección sistemática de la información a lo largo de los sondajes, para su posterior centralización en una base de datos a su vez que debe cumplir criterios de validación.

Etapa 2. Análisis Exploratorio de Datos:

Evaluar la estructura de los datos recolectados, identificar la importancia de las variables categóricas y numéricas, realizar el pre-procesamiento adecuado y reorganizar la data si fuera necesario. Abarca desde la transformación de los datos (en caso sea necesario estandarizar la data, o convertirla a algún formato específico)

Etapla 3. Aprendizaje Automático no Supervisado:

En esta etapa se busca las correlaciones existentes entre los datos que no son evidentes en un análisis estadístico, para ello se utilizan modelos que identifican cluster sumados a visualizaciones de los componentes principales que nos permitan correlacionarlos con sus variables y encontrar un patrón para una adecuada segmentación.

Etapla 4. Segmentación:

Corresponde a seleccionar los tramos de los minerales espectrales para definir con ellos los dominios de alteración que se procederán a predecir y se validarán con los geólogos y registros de logueo.

Etapla 5. Aprendizaje Automático Supervisado:

Con los tramos de alteración definidos en la segmentación, definen los objetivos a predecir, con estos targets se procederá a evaluar los algoritmos de predicción en base los datos geoquímicos, en esta etapa se hace la división correspondiente de la data set en entrenamiento y validación. Para la optimización de los hiper parámetros se debe ir al paso 4 incrementando los tramos seleccionados, hasta que la optimización del modelo mejore en base a prueba y error con el set de entrenamiento.


Etapla 6. Modelamiento 3D:

En esta última etapa se emplea el modelo con la mejor eficiencia y se realiza la predicción en base a la data de testeo para pronosticar la variable target. Finalmente, con estos tramos se construirá un modelo 3D con los dominios de alteración predicha.

Para tener un mayor detalle del paso a paso a seguir durante el desarrollo del trabajo de investigación, y entender la data a usar y las validaciones en las etapas del aprendizaje no supervisado y supervisado del Machine Learning se ha construido el siguiente flujo de trabajo que se muestra en la Figura 15, que diferencia en fases el flujo de los datos espectrales y químicos.

Figura 15

Flujo en detalle para las muestras espectrales y químicas



Nota: Fuente elaboración propia

A continuación, se describe de manera detallada y secuencial cada una de las fases operativas e introducidas en el diseño experimental de la presente investigación:

▪ **Recolección de muestras bajo protocolo estándar**

Se inicia con la toma de muestras en campo (muestras de sondaje), las cuales se utilizan para dos tipos de análisis:

- TerraSpec: instrumento que analiza espectros de minerales.
- Laboratorio: análisis químico multielemental.

▪ **Procesamiento espectral mediante aprendizaje no supervisado**

Los datos de TerraSpec se procesan mediante algoritmos de machine learning no supervisado, lo que significa que no se tiene una etiqueta o clasificación previa.

- **Fase de aprendizaje no supervisado**

Se aplica PCA (Análisis de Componentes Principales) para reducir la dimensionalidad de los datos.

Complementando con un análisis jerárquico (Dendrogramas) para clasificar las muestras que representan posibles ensambles de alteración hidrotermal.

Luego se utiliza K-Means, un algoritmo de clustering, para agrupar los datos en posibles zonas de alteración similares.

Esto lleva a una selección de tramos de alteración (zonas afectadas por procesos hidrotermales).

- **Validación geológica y control**

Las agrupaciones pasan a una validación litológica y mineralógica por parte del equipo geológico experto. Si las agrupaciones matemáticas no muestran coherencia con las observaciones de campo, el proceso es retroalimentado y reajustado, de ser validadas y confirmadas como consistentes, se procede a la siguiente etapa.

- NO son coherentes, se ajusta el proceso o hiperparametro de K-Means.
- Sí, se continúa.

- **Aprendizaje supervisado**

Una vez validados los grupos, las muestras adquieren una etiqueta formal de dominio geológico (alteraciones). Esta base de datos calibrada constituye el núcleo para el entrenamiento de los algoritmos de aprendizaje supervisado, orientados a la predicción automatizada de dominios con nuevos datos.

- **Separación de datos**

La base de datos química y espectral consolidada se particiona de la siguiente manera:

- Datos Etiquetados: Corresponden a los tramos con alteración plenamente identificada y validada. Este conjunto se subdivide a su vez en:
 - Entrenamiento (Training Data) para la calibración del modelo.

- Testeo (Validation Data) para la evaluación de su capacidad predictiva.
- Nuevos Datos (Sin Asignar): Muestras que carecen de una interpretación física y que serán clasificadas de forma automatizada por el modelo final.

▪ **Algoritmos de clasificación**

Se entrenan los siguientes 4 modelos y se seleccionara el de mejor rendimiento:

- Bosques Aleatorios (Random Forest).
- Redes Neuronales (Neural Networks).
- Máquinas de Vectores de Soporte (SVM).
- K-Vecinos más Cercanos (K-NN).

▪ **Test de rendimiento**

Se evalúa qué tan bien predicen los modelos en base a exactitud, sensibilidad, especificidad y curvas ROC

Si el rendimiento es bajo, se ajustan y optimizaran los parámetros para mejorar la precisión.

Si el rendimiento es aceptable, se continúa.

▪ **Predicción + Modelamiento**

Se usa el mejor modelo para aplicar predicciones a la nueva data sin asignación.

Esto genera una predicción de dominios de alteración con la nueva data.

Finalmente, los resultados se plotean y se utiliza el software de modelado 3D como Leapfrog de modelamiento implícito para la generación de un modelo de las alteraciones del yacimiento.


3.8 Recolección y preparación de datos

A partir de las campañas de perforación ejecutadas en la unidad Tantahuatay, se recopiló un total de 234,358 muestras químicas, distribuidas entre muestreos sistemáticos y selectivos, las cuales provienen de 221 sondajes que representan un acumulado de 80,620.03 metros lineales de perforación, a su vez se han recolectado 44,152 muestras espectrales, el proceso de recolección se muestra en la Figura 16, así como el ploteo en

3D que muestra un contraste para las micas blancas que van de 0% a 100% de abundancia.

Figura 16

Recolección de muestras espectrales y su posterior ploteo en 3D



Nota: Fuente elaboración Propia

3.8.1 Procedimiento de muestreo químico y espectral estandarizado

Se ejecuto un muestreo selectivo y sistemático correspondiente a diferentes campañas de perforación, en la que se tomaron en cuenta para el muestreo zonas de mineralización cambios litológicos y alteración.

A continuación, se detalla el procedimiento de muestreo químico y espectral:

La recolección de las muestras para química sigue los siguientes pasos:

▪ Recepción y acondicionamiento del testigo

- Los testigos de perforación son recepcionados, verificados y organizados en cajas debidamente rotuladas.
- Se comprueba la continuidad del testigo y la recuperación (% de recuperación).

▪ Registro geológico

- Se realiza el registro geológico detallado, incluyendo litología, alteración, estructuras y mineralización.
- Se delimitan dominios geológicos preliminares en función de estos criterios.

▪ **Definición de intervalos de muestreo**

- Los intervalos se definen en base a criterios geológicos: cambios litológicos, contactos, estructuras y presencia de mineralización.
- Se respetan estrictamente los contactos geológicos.
- Longitudes de muestra:
 - Mínimo: 0.30 m
 - Máximo: 2.00 m
- En zonas mineralizadas o de interés se utilizan intervalos más cortos.

▪ **Marcado del testigo**

- Se marcan los intervalos de muestreo sobre el testigo utilizando lápiz o plumón indeleble.
- Se asigna un código único a cada muestra.

▪ **Corte del testigo**

- El testigo es cortado longitudinalmente utilizando una sierra diamantada.
- Se obtiene típicamente media muestra ($\frac{1}{2}$ testigo):
 - Una mitad se envía a laboratorio.
 - La otra mitad se conserva como testigo de referencia.

▪ **Embolsado y etiquetado**

- Las muestras son colocadas en bolsas con su respectiva etiqueta interna y externa.
- Se asegura la correcta correspondencia entre muestra e identificación, se sugiere tomar fotografías que sustenten el correcto etiquetado.

▪ **Control de calidad (QA/QC)**

- Se insertan muestras de control de manera sistemática:
 - Blancos (control de contaminación)
 - Estándares certificados (CRM) (control de exactitud)
 - Duplicados (control de precisión)

- La frecuencia típica es de 1 control cada 20 a 25 muestras
- **Registro y base de datos**
 - Toda la información de muestreo es registrada en una base de datos estructurada, siendo la base de datos para la unidad el Acquire.
 - Se validan los datos para evitar errores de digitación o inconsistencias.
- **Cadena de custodia**
 - Las muestras son selladas y transportadas al laboratorio bajo protocolos de seguridad.
 - Se mantiene registro de envío, recepción y análisis.
- **Almacenamiento**
 - Los testigos remanentes son almacenados en racks o instalaciones adecuadas para futuras revisiones o auditorías.

La recolección de las muestras para espectrometría sigue los siguientes pasos:

- **Selección y preparación de muestras**
 - Las muestras deben ser representativas del tipo de alteración dominante, con un tamaño aproximado de 5 cm, asegurando cubrir adecuadamente el área de medición.
 - En muestras de sondajes, estas deben ser representativas del intervalo FROM–TO, manteniendo consistencia con el muestreo geológico y geoquímico.
 - El código de muestra debe coincidir con el asignado en la base de datos geoquímica, garantizando trazabilidad.
 - No se deben seleccionar muestras con alteración reciente por exposición a agua superficial.
 - En caso de humedad, secar las muestras a temperatura ambiente (no usar calor artificial).
 - Remover cualquier material orgánico o contaminante superficial.


- Procurar superficies planas, limpias y homogéneas para optimizar la calidad de lectura espectral.
- Toda muestra analizada químicamente debe contar con su correspondiente análisis espectral.

3.8.2 Procedimiento de captura espectral estandarizado con el equipo de TerraSpec

Para la adquisición de las firmas espectrales de reflectancia se utilizó un espectrómetro TerraSpec 4. Este equipo integra tres sensores ópticos optimizados para operar de forma continua en las regiones del espectro visible (VIS, va de 400-700 nm) y de infrarrojo de onda corta (SWIR 1, va de 700-1300 nm y SWIR 2, va de 1300-2500 nm), los cuales se acoplan mediante un cable de fibra óptica para transferir los valores de reflectancia digitalizados para cada una de las longitudes de onda correspondientes. La arquitectura interna, los componentes y la configuración física del instrumental óptico utilizado se describen formalmente en la Figura 17.

Figura 17

Equipo Terraspec4, identificación de componentes



Nota: Fuente adaptado de los procedimientos de Buenaventura (2020).


Una vez capturado la muestra espectral el archivo de extensión ASD es enviado a la plataforma de Ausspec (empresa especializada en análisis espectral) para su respectivo procesamiento y validación técnica. Dicha entidad realiza el control de calidad espectral y

la corrección de empalmes (splice correction), retornando una matriz de datos estructurada en formato csv. Este archivo consolidado, que compila las firmas validadas limpias de ruido analítico, será el dataset de entrada fundamental para la ejecución de los análisis posteriores.

Para la identificación de los minerales de alteración nos basamos en los índices de absorción, los cuales son las longitudes promedias de absorción para la zona del SWIR donde se tiene los rasgos los iones OH, agua, AlOH, FeOH, MgOH y CO₃ como se muestran en la Figura 18 las bandas amarillas, según Dr. Sasha Pontual, 2013.

Figura 18

Principales rasgos de la zona del SWIR para identificar minerales



Nota: Fuente Spectral Geology Workshop (Dr. Sasha Pontual, 2013).

Las posiciones en las longitudes de onda de estas absorciones y las razones de reflectancia nos entregan la información de cristalinidad y composición del mineral, en particular las de los iones AlOH, FeOH, MgOH y CO₃. Los rangos e valores se muestran en la Tabla 6.

Tabla 6

Tabla de longitudes de onda principales

GRUPO / ENLACE	LONGITUDES DE ONDA CARACTERÍSTICAS (nm)
OH	~1400, (~1550), (~1750–1850)
Agua (H ₂ O)	~1400, ~1900
Al–OH	~2160 – 2220
Fe–OH	~2230 – 2295
Mg–OH	~2300 – 2360
CO ₃ (carbonatos)	~2300 – 2350, (también en ~1870, ~1990, ~2155)

Nota: Fuente adaptado de Spectral Geology Workshop , Dr. Sasha Pontual, 2013

A fin de sintetizar y estandarizar los criterios de reconocimiento espectral utilizados en la etapa de preprocesamiento, se consolidaron los parámetros ópticos de las principales especies mineralógicas presentes en el depósito. En la Tabla 7 se detallan de forma sistemática los rasgos de absorción críticos (diagnósticos) y secundarios en la región del SWIR, correlacionando cada firma con su ensamble de alteración hidrotermal de referencia e interpretación geológica

Tabla 7

Firmas espectrales de los principales minerales de alteración


MINERAL DE ALTERACIÓN	ENSAMBLE DE REFERENCIA	RASGO DIAGNÓSTICO CRÍTICO (nm)	RASGOS SECUNDARIOS (nm)
Alunita	Argílica Avanzada	~2160	~1480, ~2320
Pirofilita	Argílica Avanzada / Semicristalina	~2166	~1390 (Agudo), ~2070, ~2320
Caolinita	Argílica Avanzada / Intermedia	~2208	~1400, ~2162
Illita	Sericítica / Filica	~2200	~1400 (OH), ~1900 (H ₂ O)
Clorita	Propilítica	~2250	~2350 (Mg–OH)
Epidota	Propilítica	~2330 – 2340	~2160

Nota: Fuente adaptado de Spectral Geology Workshop, Dr. Sasha Pontual, 2013

En la siguiente Figura 19 se muestran los principales minerales espectrales y sus rasgos de identificación en la región del SWIR (1300-2500 nm).

Figura 19

Firmas espectrales de referencia de minerales de alteración



Nota: Fuente adaptado de Spectral Geology Workshop, Dr. Sasha Pontual, 2013

A continuación, el procedimiento de trabajo con el equipo de espectrometría (TerraSpec 4) para captura los espectros es el siguiente:

Verificación previa en sistema

- Verificar que el código de muestra esté registrado en el software Acquire.
- Confirmar que las muestras estén correctamente etiquetadas y organizadas.

Armado y chequeo del equipo

- Montar el equipo TerraSpec 4, verificando:
 - Conexión del espectrómetro a la laptop.
 - Conexión de la lámpara o cañón de luz.
- Ejecutar el checklist de verificación operativa.

Encendido y estabilización

- Encender el espectrómetro.
- Esperar entre 15 y 30 minutos para que el equipo alcance su temperatura óptima de operación.

Inicio del software

- Encender la laptop.
- Abrir el software RS3 (High Contrast FieldSpec Pro RS3).
- Verificar la correcta comunicación entre el equipo y el software.

Calibración del equipo

- Calibrar utilizando el blanco de referencia (Spectralon):
- Seleccionar Opt (Optimizador).
- Luego WR (White Reference).
- Asegurar que el blanco esté limpio y en buenas condiciones antes de calibrar.

Adquisición de espectros

- Realizar un paneo sistemático sobre la muestra, respetando las zonas marcadas por el geólogo.
- Priorizar lecturas con mejor definición de rasgos espectrales.
- Consideraciones según tipo de muestra:
- Roca:
 - Medir sobre superficies planas y limpias.
 - Evitar zonas rugosas o con sombras.
- Suelos y pulpas:
 - Colocar en superficie uniforme o formar una ruma.
 - Acercar el sensor lo máximo posible sin contaminarlo.
- Se recomienda realizar múltiples lecturas por muestra (≥ 3) y seleccionar o promediar las de mejor calidad.

Registro y almacenamiento

- Guardar cada espectro con su código de muestra correspondiente.
- Verificar el correcto almacenamiento en la ruta definida.
- Mantener consistencia con la base de datos geoquímica.

Procesamiento de datos

- Abrir el software ViewSpec Pro.
- Aplicar Splice Correction para corregir discontinuidades espectrales.
- Exportar los espectros corregidos a la ruta de salida definida.

Control de calidad y respaldo

- Revisar la calidad de los espectros (ruido, coherencia, rasgos de absorción).
- Realizar respaldo de la información en servidores o medios externos.

Envío de espectros corregidos a Ausspec para su análisis.

- Identificación mineralógica
- Resultados interpretados (tabla)

Carga en BD Acquire

- Se importarán los csv a la base de datos
- Se vincularán por su código de muestra a los from to y estarán listos para su descarga.

El desarrollo procedimental e instrumental detallado, que abarca desde la preparación física del testigo de perforación hasta la consolidación de las lecturas validadas dentro de la base de datos, ha sido sistematizado y se presenta formalmente en el Anexo 1: Diagrama de Flujo para la Adquisición y Procesamiento de Datos Espectrales mediante TerraSpec 4.

En la Tabla 8 se presenta la relación de minerales de alteración detectados tras la validación con Ausspec. Esta metodología permite identificar un espectro de hasta 58 minerales distintos, optimizando el análisis mineralógico.

Tabla 8*Lista de minerales identificados por Ausspec*

MINERALES REPORTADOS POR AUSSPEC					
Alunite	Carbonate	Fe chlorite	Mg chlorite	Phengite	Topaz
Amphibole	Celadonite	Fe dolomite	Mg-Fe clorite	Prehnite	Tourmaline
Ankerite	Chalcocite	Goethite	Montmorillonite	Pumpellyite	Turquoise
Antlerite	Chlorite	Gibbsite	Muscovite	Pyrophyllite	Woodhouseite
Beryl	Chrysocolla	Gypsum	NH4 white mica	Rhodochrosite	White mica
Biotite	Diaspore	Halloysite	NH4 mineral	Saponite	Zeolite
Boehmite	Dickite	Hematite	Nontronite	Serpentine	Zoisite
Brochantite	Dolomite	Jarosite	Ottrelite	Siderite	Zunyite
Ca Alunite	Epidote	Kaolinite	Palygorskite	Sudoite	
Calcite	Fe calcite	Malachite	Paragonite	Talc	

Nota: Fuente elaboración propia.

3.9 Procesamiento de datos espectrales

El procesamiento estadístico se realizó para las 44,152 muestras de que pertenecen a diferentes poblaciones. Para este análisis de los datos se utilizó las librerías estadísticas de Python y Orange.

3.9.1 Descripción de la base de datos

Resultados de las muestras analizadas por el equipo de Espectrometría, resultados compilados entregados por Ausspec, para este trabajo se consideraron 69 columnas, entre ellas los datos de muestra, como código de muestra, nombre de sondaje y profundidad a la cual fue tomada la muestra.

Para entender de mejor manera los datos se describe en la Tabla 9 las columnas recibidas por parte de Ausspec, como el grupo de minerales, abundancias y cantidad de datos por cada una de ellas.

Tabla 9*Descripción del tipo de datos para las 69 columnas entregadas por Ausspec*

ID COLUMN	NON-NULL	COUNT	DESCRIPCIÓN
1	SampleID	44152	Muestra
2	HoleID	44152	Collar
3	DepthFrom	44152	Desde
4	DepthTo	44152	Hasta
5	aiMineral1	44020	Mineral 1
6	aiMineral2	33852	Mineral 2
7	aiMineral3	15497	Mineral 3
8	aiMineral4	3926	Mineral 4
9	aiMineral5	527	Mineral 5
10	aiMineral6	55	Mineral 6
11	VNIRMinerals	44152	Mineral de zona de oxd
12	WhiteMica_SC	44152	Abundancia de Mica Blanca
13	Chlorite_SC	44152	Abundancia de Clorita
14	Carbonate_SC	44152	Abundancia de Carbonato
15	Biotite_SC	44152	Abundancia de Biotita
16	Epidote_SC	44152	Abundancia de Epidota
17	Kaolinite_SC	44152	Abundancia de Kaolinita
18	Dickite_SC	44152	Abundancia de Dickite
19	Halloysite_SC	44152	Abundancia de Halloysita
20	Amphibole_SC	44152	Abundancia de Anfíbol
21	Talc_SC	44152	Abundancia de Talco
22	Serpentine_SC	44152	Abundancia de Serpentina
23	Montmor_SC	44152	Abundancia de Montmorillonita
24	Nontronite_SC	44152	Abundancia de Nontronita
25	Saponite_SC	44152	Abundancia de Saponita
26	Zeolite_SC	44152	Abundancia de Zeolita
27	Palygor_SC	44152	Abundancia de Palygorskita
28	Alunite_SC	44152	Abundancia de Alunita
29	CaAlunite_SC	44152	Abundancia de Alunita Calcica
30	Jarosite_SC	44152	Abundancia de Jarosita
31	Gypsum_SC	44152	Abundancia de Yeso
32	Pyrophyllite_SC	44152	Abundancia de Pirofilita
33	Diaspore_SC	44152	Abundancia de Diaspora
34	Topaz_SC	44152	Abundancia de Topacio

ID COLUMN	NON-NULL	COUNT	DESCRIPCIÓN
35	Zunyite_SC	44152	Abundancia de Zunyita
36	Tourm_SC	44152	Abundancia de Turmalina
37	Sudoite_SC	44152	Abundancia de Sudoita
38	Prehnite_SC	44152	Abundancia de Prehnita
39	Pumpell_SC	44152	Abundancia de Pumpell
40	Zoisite_SC	44152	Abundancia de Zoisita
41	Ottrelite_SC	44152	Abundancia de Ottrelita
42	NH4WtMica_SC	44152	Abundancia de Mica NH4
43	NH4Min_SC	44152	Abundancia de Mineral con NH4
44	Malachite_SC	44152	Abundancia de Malaquita
45	Antlerite_SC	44152	Abundancia de Antlerita
46	Azurite_SC	44152	Abundancia de Azurita
47	Chryscll_SC	44152	Abundancia de Criscel
48	Gibbsite_SC	44152	Abundancia de Gibbsita
49	Boehmite_SC	44152	Abundancia de Boehmita
50	Apoph_SC	44152	Abundancia de Apofis
51	Chondrt_SC	44152	Abundancia de Condroide
52	Brucite_SC	44152	Abundancia de Brucita
53	Scorodite_SC	44152	Abundancia de Escorodita
54	Beryl_SC	44152	Abundancia de Berilo
55	Water_silica_SC	44152	Abundancia de Silice
56	Jarosite_vnir	468	Presencia de Jarosita
57	FeCarb_vnir	225	Presencia de Carbonatos de Fe
58	Hem_vnir	1800	Presencia de Hematita
59	Goeth_vnir	2935	Presencia de Gohetita
60	CuMin_vnir	0	Presencia de Minerales de Cu
61	Chl_vnir	2482	Presencia de Clotita
62	Tourm_vnir	27	Presencia de Turmalina
63	Amph_vnir	4	Presencia de Anfíbol
64	Epid_vnir	26	Presencia de Epidota
65	Wav_WtMica	6049	Longitud de onda de Micas
66	Type_WtMica	6049	Tipo de Micas
67	XT_WtMica	3831	Cristalinidad de las Micas
68	Wav_Chlorite	2454	Longitud de onda de la clorita
69	Type_Chlorite	2454	Tipo de Cloria

Nota: Tipo de datos float64(14), int64(44) y object(11)

Desde la fila 4 a la 9 es el resumen de la presencia de minerales de la zona del SWIR (zona del infrarrojo), identificación de las arcillas relacionadas a las alteraciones, siendo el aiMineral1 el que presenta la mayor cantidad de datos, además que el equipo identificó hasta 55 muestras con más de 5 minerales. La fila 10 es la presencia de los minerales de la zona del VNIR (zona del visible) principalmente relacionados a la zona de los óxidos.

Desde la fila 12 hasta la 55, son todos los minerales identificados del SWIR que tienen la abundancia del mineral respectivamente.

Desde la fila 56 hasta la 64, son todos los minerales identificados del VNIR estos no presentan abundancia, solo se indica su presencia. La fila 65 y 66 indica la longitud de onda, tipo y cristalinidad de las micas blancas respectivamente. Por último, la fila 68 y 69 indica la longitud de onda y tipo de las cloritas respectivamente.

El resumen de las columnas más importantes se muestra en la Tabla 10 donde se tiene los resultados de los minerales en el infrarrojo cercano (SWIR) y en el visible (VNIR).

Tabla 10

Tabla con las columnas de los resultados espectrales del SWIR y VNIR.

Sample ID	aiMineral1	aiMineral2	aiMineral3	aiMineral4	aiMineral5	aiMineral6	SWIRMin_:nowt	VNIRMinerals
CTSD00610918	alunite	py rophy llite					alunite+pyrophy llite	goethite+hematite
CTSD00610919	py rophy llite	alunite					pyrophy llite+alunite	goethite
CTSD00610920	alunite	py rophy llite					alunite+pyrophy llite	goethite+hematite
CTSD00610921	alunite	py rophy llite	zunyite				alunite+pyrophy llite+zunyite	goethite+hematite
CTSD00610922	py rophy llite	alunite	zunyite				pyrophy llite+alunite+zunyite	novnir
CTSD00610924	py rophy llite	alunite	zunyite				pyrophy llite+alunite+zunyite	goethite+hematite
CTSD00610925	alunite	py rophy llite					alunite+pyrophy llite	goethite+hematite
CTSD00610926	py rophy llite	alunite	zunyite				pyrophy llite+alunite+zunyite	goethite
CTSD00610927	gy psum	py rophy llite	kaolinite	alunite			gypsum+pyrophy llite+kaolinite+alunite	goethite+hematite
CTSD00610928	alunite	water_silica					alunite+water_silica	goethite+hematite
CTSD00610930	alunite						alunite	goethite+hematite
CTSD00610931	alunite	py rophy llite	topaz				alunite+pyrophy llite+topaz	novnir


Nota: Fuente elaboración propia.

3.9.2 Variables categóricas

Dentro de las variables categóricas se tendrás los minerales identificados en la zona de del SWIR (zona del infrarrojo) y VNIR (zona del visible), la espectrometría puede identificar las mezclas existentes y ordenarlas en función de la abundancia, la Figura 20 muestra la identificación de los minerales en el infrarrojo (a), visible(b) y las mezclas (c), siendo que el equipo puede identificar hasta 6 minerales en un solo punto analizado, y que van disminuyendo en abundancia en orden descendente.

Figura 20

Histograma de cantidad de muestras por minerales del SWIR, VNIR y mezclas



Nota: Fuente elaboración propia

Para realizar un análisis de la abundancia de los minerales de la zona del SWIR se ordenó en función con un conteo de la identificación de los 6 minerales que identifica la espectrometría, como se muestra en la Tabla 11. siendo que el mineral que más abunda es la pyrophyllite y el menos abundante es el scorodite.

Tabla 11

Resultados de las mezclas más abundantes en el rango del SWIR

ID	SWIRMin_nowt	Count
1	pyrophyllite+alunite	5539
2	pyrophyllite	3651
3	alunite	2606
4	white mica	1744
5	alunite+pyrophyllite	1656
6	pyrophyllite+kaolinite	1610
7	pyrophyllite+diaspore+alunite	1356
8	pyrophyllite+diaspore	1265
9	kaolinite+pyrophyllite	796
10	white mica+pyrophyllite	781
11	noswir	691
12	pyrophyllite+alunite+diaspore	691
13	kaolinite	659
14	pyrophyllite+white mica	607
15	white mica+kaolinite	542
16	kaolinite+white mica	536
17	pyrophyllite+kaolinite+alunite	491
18	white mica+chlorite	489
19	diaspore+pyrophyllite	432
20	diaspore+pyrophyllite+alunite	426
21	pyrophyllite+alunite+kaolinite	339
22	pyrophyllite+alunite+zunyite	311
ooo	ooo	ooo

Nota: Fuente elaboración propia

Los resultados finales de Ausspec en el rango SWIR, se clasificaron de forma jerárquica hasta un máximo de seis especies minerales concurrentes por cada muestra analizada. La matriz completa con los conteos absolutos y las frecuencias de las combinaciones minerales emitidas por Ausspec se ha trasladado al Anexo 2: Resultados de Identificación Mineral Automatizada (Ausspec).

De manera complementaria a la caracterización del infrarrojo de onda corta (SWIR), la plataforma Ausspec procesó los registros correspondientes a la región del infrarrojo cercano y visible (VNIR), permitiendo la identificación y cuantificación de especies

minerales asociadas principalmente a óxidos e hidróxidos de hierro (como goethita, hematita y jarosita). La matriz detallada con las frecuencias absolutas y los conteos de distribución mineralógica se muestra en la Tabla 12.

Tabla 12

Resultados obtenidos por espectrometría en el rango del VNIR

VNIRMinerals	Count
novnir	37720
chlorite	2467
goethite	1444
goethite+hematite	1426
jarosite	384
hematite	344
fe carbonate	205
goethite+jarosite	45
hematite+jarosite	29
epidote	26
tourmaline	23
fe carbonate+goethite	20
chlorite+jarosite	10
amphibole	4
chlorite+tourmaline	4
chlorite+hematite	1
Total general	44152

Nota: Fuente elaboración propia

3.9.3 Variables numéricas

En este apartado se analizan las 44 columnas que contienen los datos de variables numéricas de tipo flotante (float) y entero. Estas variables representan los valores analíticos de abundancia relativa ponderada (SC, puntuación espectral o spectral score) calculados para cada una de las especies minerales identificadas en las muestras mediante los rangos del SWIR y VNIR.

La matriz estructurada permite cuantificar de forma matemática la dominancia y coexistencia mineralógica en cada intervalo. Por ejemplo, un valor de 100 denota una respuesta espectral pura u homogénea de dicha fase en la muestra, mientras que valores intermedios (como 45 o 55) reflejan mezclas mineralógicas proporcionales dentro del volumen del testigo de perforación, como se muestra en la Tabla 13.

Tabla 13

Resultados de las abundancias relativas para cada mineral de los rangos del SWIR

SampleID	WhiteMica_SC	Chlorite_SC	Carbonate_SC	Biotite_SC	Epidote_SC	Kaolinite_SC	Dickite_SC	Halloysite_SC	Amphibole_SC
CTSD00603876	0	0	0	0	0	0	0	0	0
CTSD00603877	45	0	0	0	0	30	0	0	0
CTSD00603878	55	0	0	0	0	0	0	0	0
CTSD00603879	80	0	0	0	0	0	0	0	0
CTSD00603881	100	0	0	0	0	0	0	0	0
CTSD00603882	0	0	0	0	0	55	0	0	0
CTSD00603883	0	0	0	0	0	40	0	0	0
CTSD00603884	100	0	0	0	0	0	0	0	0
CTSD00603885	100	0	0	0	0	0	0	0	0
CTSD00603887	90	0	0	0	0	0	0	0	0
CTSD00603888	55	0	0	0	0	45	0	0	0
CTSD00603889	0	0	0	0	0	40	0	0	0
CTSD00603890	0	0	0	0	0	15	0	0	0
CTSD00603891	0	0	0	0	0	10	0	0	0

Nota: Fuente elaboración propia

3.9.3.1 Medidas de tendencias central y dispersión. Se realizado el conteo de datos por cada mineral y calculado 3 mediadas de tendencia, además de los mínimos y máximos como se muestra en la Tabla 14, con esto se busca identificar qué tipo de distribución se presenta para cada mineral, simétrica o asimétrica, con este análisis permitirá excluir los minerales que no presentan representatividad para las predicciones.

Tabla 14

Medidas estadísticas por mineral de los resultados de los rangos del SWIR

ID	MINERAL	COUNT	MEDIA	MEDIANA	DES.STAD	MIN	MAX
1	WhiteMica_SC	10986	13	0	28	0	100
2	Chlorite_SC	4244	1	0	6	0	100
3	Carbonate_SC	1956	1	0	6	0	100
4	Biotite_SC	85	0	0	1	0	50
5	Epidote_SC	236	0	0	3	0	95
6	Kaolinite_SC	13474	11	0	22	0	100
7	Dickite_SC	2266	2	0	12	0	100
8	Halloysite_SC	1	0	0	0	0	75
9	Amphibole_SC	130	0	0	1	0	75
10	Talc_SC	2	0	0	0	0	25
11	Serpentine_SC	0	0	0	0	0	0
12	Montmor_SC	2223	3	0	14	0	100
13	Nontronite_SC	77	0	0	0	0	45
14	Saponite_SC	9	0	0	1	0	100
15	Zeolite_SC	35	0	0	2	0	100
16	Palygor_SC	0	0	0	0	0	0
17	Alunite_SC	18919	16	0	29	0	100
18	CaAlunite_SC	19	0	0	1	0	100
19	Jarosite_SC	206	0	0	2	0	100

ID	MINERAL	COUNT	MEDIA	MEDIANA	DES.STAD	MIN	MAX
20	Gypsum_SC	1651	2	0	10	0	100
21	Pyrophyllite_SC	27375	37	30	37	0	100
22	Diaspore_SC	8304	7	0	17	0	100
23	Topaz_SC	848	0	0	2	0	100
24	Zunyite_SC	2306	1	0	8	0	100
25	Tourm_SC	24	0	0	1	0	55
26	Sudoite_SC	1	0	0	0	0	60
27	Prehnite_SC	0	0	0	0	0	0
28	Pumpell_SC	0	0	0	0	0	0
29	Zoisite_SC	0	0	0	0	0	0
30	Ottrelite_SC	0	0	0	0	0	0
31	NH4WtMica_SC	0	0	0	0	0	0
32	NH4Min_SC	0	0	0	0	0	0
33	Malachite_SC	0	0	0	0	0	0
34	Antlerite_SC	0	0	0	0	0	0
35	Azurite_SC	0	0	0	0	0	0
36	Chryscll_SC	0	0	0	0	0	0
37	Gibbsite_SC	21	0	0	1	0	85
38	Boehmite_SC	0	0	0	0	0	0
39	Apoph_SC	1	0	0	0	0	45
40	Chondrt_SC	0	0	0	0	0	0
41	Brucite_SC	0	0	0	0	0	0
42	Scorodite_SC	41	0	0	3	0	100
43	Beryl_SC	0	0	0	0	0	0
44	Water_silica_SC	1810	2	0	12	0	100

Nota: Fuente elaboración propia


Para un mejor entendimiento de aquí en adelante se omitirá el sufijo _SC que hace referencia al spectral score.

Al analizar la tabla se tiene valores de cero en los máximos, lo que indica que no hay la presencia de los siguientes minerales: Serpentine, Palygor, Prehnite, Pumpell, Zoisite, Ottrelite, NH4WtMica, NH4Min, Malachite, Antlerite, Azurite, Chryscll, Boehmite, Chondrt, Brucite, Beryl.

Para una mejor visualización se plotea los valores de abundancia mayores a cero para cada mineral y ordenados de mayor a menor por cantidades, como se muestra en la Figura 21, damos cuenta que alrededor de 14 minerales son los más abundantes.

Figura 21

Distribución de los datos espectrales (por abundancia de minerales)



Nota: Fuente elaboración propia

Por último, de las 44 variables numéricas iniciales se determinó que aquellas fases minerales que registraron una media analítica igual a cero ($\mu = 0$) carecen de significancia estadística para la segregación espacial de dominios, comportándose como trazas aisladas o ruido instrumental. En consecuencia, se procedió con la remoción definitiva de las siguientes 16 columnas del conjunto de entrada: Biotite, Halloysite, Amphibole, Talc, Nontronite, Saponite, Zeolite, CaAlunite, Jarosite, Topaz, Tourmaline, Sudoite, Gibbsite, Apophyllite y Scorododite. Tras la realización de este proceso de depuración, consolidó la

Tabla 15, la cual detalla el resumen estadístico descriptivo (frecuencia, media, mediana, desviación estándar, valores mínimos y máximos) de los 13 minerales representativos y filtrados que constituirán la matriz definitiva para el modelamiento predictivo.

Tabla 15

Tabla resumen con la eliminación de minerales con media de cero

ID	MINERAL	COUNT	MEDIA	MEDIANA	DES.STAD	MIN	MAX
1	WhiteMica	10986	13	0	28	0	100
2	Chlorite	4244	1	0	6	0	100
3	Carbonate	1956	1	0	6	0	100
4	Epidote	236	0	0	3	0	95
5	Kaolinite	13474	11	0	22	0	100
6	Dickite	2266	2	0	12	0	100
7	Montmor	2223	3	0	14	0	100
8	Alunite	18919	16	0	29	0	100
9	Gypsum	1651	2	0	10	0	100
10	Pyrophyllite	27375	37	30	37	0	100
11	Diaspore	8304	7	0	17	0	100
12	Zunyite	2306	1	0	8	0	100
13	Water_silica	1810	2	0	12	0	100

Nota: Fuente elaboración propia

3.9.3.2 Correlaciones de Pearson (r) y Spearman (p). El coeficiente de correlación de Pearson (r) varía entre -1 y 1. Un valor de 1 indica una relación lineal positiva perfecta, -1 indica una relación lineal negativa perfecta, y 0 indica la ausencia de una relación lineal.

El coeficiente de correlación de Spearman (p) varía entre -1 y 1. Un valor de 1 indica una relación monotónica creciente perfecta, -1 indica una relación monotónica decreciente perfecta, y 0 indica la ausencia de una relación monotónica.

El análisis cruzado de las correlaciones lineales Pearson y de rango Spearman aplicado a los parámetros de intensidad espectral permitirá discriminar entre asociaciones

minerales. Aquellos pares de minerales que exhibieron valores de (r) y (ρ) simultáneamente superiores a 0.65 serán interpretados como ensambles mineralógicos

3.10 Procesamiento de los datos químicos

El procesamiento de datos geoquímicos constituye una etapa neurálgica en la preparación de la matriz analítica multidimensional. El objetivo primordial de esta fase es adecuar la base de datos composicional cruda la cual se compone inicialmente de un volumen masivo de 234,358 muestras y un espacio espectral y analítico de 57 columnas como se muestra en la Tabla 16, y mediante la aplicación de criterios estadísticos que corrijan las inconsistencias operativas inherentes al muestreo multielemental (ejemplo: límites de detección, valores nulos y distribuciones asimétricas). Esta depuración asegura la estabilidad matemática de los algoritmos de aprendizaje automático no supervisado y supervisado que se ejecutarán en las etapas subsecuentes.

Tabla 16

Tabla resumen de los datos químicos

holeid	from	to	Ag_ppm	Al_pct	As_ppm	Au_ppm	Ba_ppm	Be_ppm	Bi_ppm
AK-17-001	0	0.25	5.3	7.8	403	0.084	370	0.5	2
AK-17-001	0.25	0.45	5.3	7.8	403	0.084	370	0.5	2
AK-17-001	0.45	0.5	1.1	9.14	119	0.058	260	0.5	2
AK-17-001	0.5	0.75	1.1	9.14	119	0.058	260	0.5	2
AK-17-001	0.75	0.95	1.1	9.14	119	0.058	260	0.5	2
AK-17-001	0.95	1	1	8.94	128	0.064	250	0.5	2
AK-17-001	1	1-25	1	8.94	128	0.064	250	0.5	2
AK-17-001	1.25	1.5	1	8.94	128	0.064	250	0.5	2
AK-17-001	1.5	1.75	1	8.94	128	0.064	250	0.5	2
AK-17-001	1.75	2	1	8.94	128	0.064	250	0.5	2
AK-17-001	2	2.25	1	8.94	128	0.064	250	0.5	2

Nota: Fuente elaboración propia

3.10.1 Tratamiento de datos faltantes


En bases de datos geológicas extensas procedentes de perforaciones diamantinas y de aire reverso, la presencia de registros faltantes (NaN) es recurrente debido a variaciones en los protocolos analíticos a lo largo del tiempo, la selectividad de ciertos ensayos químicos según la zona mineralizada o limitaciones físicas en la recuperación de los testigos. Para resguardar la robustez del modelamiento predictivo sin introducir sesgos artificiales, se estructuró un protocolo de tratamiento de datos faltantes dividido en dos fases restrictivas:

Filtrado por umbral de completitud:

Se evaluó el nivel de completitud de las 57 variables originales. Con la finalidad de retener únicamente variables con alta representatividad estadística, se fijó un umbral crítico del 80.0% de presencia de datos. Como consecuencia directa de este filtro, se identificaron y eliminaron 14 variables que no alcanzaron la densidad mínima requerida, reduciendo sustancialmente el ruido y la dispersión analítica del dataset general. Las variables excluidas correspondieron a: AuCN_ppm, CuCN_pct, CuR_pct, CuSS_pct, Hg_ppm, Li_ppm, Nb_ppm, Se_ppm, Sn_ppm, Te_ppm, Th_ppm, U_ppm, Y_ppm y Zr_ppm, como se muestra en la Figura 22.

Figura 22

Distribución de los datos químicos




Nota: Fuente elaboración Propia

Imputación de valores restantes:

Para las 34 variables geoquímicas e intervalares finalistas (tales como Ag_ppm, Al_pct, As_ppm, Au_ppm, entre otras), las cuales presentaban niveles de completitud óptimos superiores al 93.9% (a excepción de elementos traza específicos con más del 80.0% de representatividad), se aplicó una técnica de imputación estadística robusta mediana por taladro. Mediante este procedimiento, se logró la remoción absoluta de los registros vacíos, alcanzando un balance final de cero (0) nulos restantes en el dataset consolidado de 234,358 filas y 34 columnas, como se muestra en la Figura 23.

Figura 23

Variables seleccionadas para el entrenamiento y la predicción de dominios de alteración



Nota: Fuente elaboración propia

3.10.2 Detección de valores atípicos

Los datos de leyes geoquímicas y abundancias espectrales en yacimientos hidrotermales de alta sulfuración y sistemas tipo skarn/pórfido suelen exhibir distribuciones fuertemente asimétricas y colas derechas alargadas. Esto se debe a la naturaleza misma

de la mineralización económica. Para evitar que estas anomalías químicas reales sesguen o distorsionen los centroides de los modelos lineales y basados en distancias (como SVM o K-Means), se procedió a la gestión de valores atípicos (outliers).

La metodología aplicada consistió en filtrar solo los elementos con un porcentaje >80% y se optó por una técnica de acotamiento al percentil 99, sustituyendo los valores extremadamente erráticos por dicho límite superior en lugar de eliminarlos. Esto resguarda la integridad espacial y continuidad geoquímica de las trayectorias de los taladros.

3.10.3 Normalización y escalamiento

Debido a que las variables geoquímicas remanentes se encuentran expresadas en diferentes unidades de medida y órdenes de magnitud coexistiendo elementos mayoritarios medidos en porcentaje (Al_pct, Fe_pct, Ca_pct) con elementos traza u oro reportados en partes por millón o partes por billón (Au_ppm, As_ppm, Ba_ppm), la aplicación directa de algoritmos basados en el cálculo de distancias geométricas se vería sesgada de forma severa hacia los elementos con valores absolutos intrínsecamente más altos. Para homogeneizar el peso estadístico de cada variable dentro del espacio n-dimensional, se sometió a las 34 variables a un proceso de escalado y normalización. Se optó por el método de Estandarización (Z-score Scaling), transformando cada observación matemática de manera que su media sea igual a cero ($\mu = 0$) y su desviación estándar sea igual a uno ($\sigma = 1$), mediante la ecuación (7):

$$Z = \frac{x - \mu}{\sigma} \quad (7)$$

3.11 Aprendizaje automático no supervisado

El aprendizaje automático no supervisado agrupa un conjunto de algoritmos diseñados para identificar estructuras subyacentes, patrones ocultos y distribuciones naturales dentro de una base de datos, sin la necesidad de contar con etiquetas previas o una variable objetivo-definida ya definida. En el contexto de esta investigación, este enfoque es fundamental para abordar la complejidad de los datos espectrales, ya que permite que los algoritmos procesen las variables numéricas de manera puramente

estadística, abstrayéndose temporalmente de las interpretaciones previas o visuales tomadas durante el logueo geológico tradicional.

Para el desarrollo de esta fase, la metodología se estructuró en revisar 3 algoritmos complementarios: Análisis de Componentes Principales (PCA), Clúster Jerárquico y K-Means.

3.11.1 Análisis de componentes principales (PCA)

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) es una técnica estadística ampliamente utilizada para la reducción de dimensionalidad en conjuntos de datos multivariados. En el contexto de estudios geoquímicos y espectrales, el PCA permite identificar patrones dominantes en los datos, resaltando las variables más significativas al tiempo que reduce el ruido y la redundancia de la información original (Jolliffe & Cadima, 2016).

Por ejemplo, en estudios de alteración hidrotermal, el PCA puede revelar agrupamientos de firmas espectrales asociadas a minerales específicos como clorita, caolinita, o alunita, permitiendo distinguir dominios de alteración con base en sus características espectrales dominantes. Además, el PCA puede utilizarse como paso previo a técnicas de agrupamiento, como k-means o clustering jerárquico, para mejorar la separación entre clases y reducir la complejidad computacional (Abdi & Williams, 2010).

3.11.2 Clustering jerárquico

Este método funciona agrupando datos que presentan similitud en función de una métrica de distancia (por ejemplo, la euclidiana o la de Manhattan) y un criterio de enlace, como el enlace simple, completo o promedio. A medida que se construye el dendrograma, se van uniendo los objetos más cercanos entre sí hasta formar una jerarquía completa. La profundidad de corte del dendrograma permite definir cuántos clústeres se desean analizar, lo que ofrece una gran flexibilidad para interpretar los resultados de acuerdo con la escala o nivel geológico deseado (Everitt et al., 2011).

En el análisis de alteraciones hidrotermales, el agrupamiento jerárquico permite identificar asociaciones entre muestras espectrales, lo que puede reflejar dominios con

características mineralógicas comunes. Estas agrupaciones pueden servir como una base objetiva para validar o refinar interpretaciones geológicas previas, así como para orientar zonas prioritarias de exploración. Además, combinado con técnicas de reducción de dimensionalidad como PCA, se facilita la visualización y validación de los clústeres encontrados (Jolliffe & Cadima, 2016).

Es una técnica de análisis de datos que busca construir una jerarquía de clusters. Este método no requiere que sepamos de antemano la cantidad de clusters que queremos, y puede ser visualizado mediante un dendrograma, que es una representación gráfica de la jerarquía de clusters,

3.11.3 K-Means

El algoritmo K-Means fue seleccionado para realizar la sectorización no supervisada de los dominios de alteración hidrotermal. El objetivo de este algoritmo es agrupar las muestras espectrales, maximizando la homogeneidad interna de cada grupo y la heterogeneidad entre ellos.

El proceso se define en tres etapas consecutivas:

- **Inicialización:**

Se seleccionan de forma aleatoria (o mediante el método optimizado K-Means++) K centroides iniciales en el espacio multidimensional definido por las variables espectrales normalizadas

- **Asignación:**

Cada muestra del testigo de perforación es asignada al centroide más cercano utilizando el criterio de mínima distancia euclidiana.

- **Actualización:**

Se recalculan las coordenadas de los centroides como el promedio vectorial de todas las muestras asignadas a sus respectivos grupos. Este ciclo iterativo se repite hasta lograr la convergencia (cuando los centroides ya no varían su posición) o hasta alcanzar el límite máximo de iteraciones.

En el contexto de esta investigación, los centroides resultantes representan la composición mineralógica promedio de los ensambles de alteración presentes en el área de estudio.

3.12 Aprendizaje automático supervisado

El aprendizaje automático supervisado comprende un conjunto de algoritmos matemáticos que aprenden una función de mapeo para conectar variables de entrada independientes con una variable de salida conocida y etiquetada.

A diferencia de la fase no supervisada, cuyo fin fue puramente exploratorio y de particionamiento, el enfoque supervisado implementado en esta investigación tiene un carácter estrictamente predictivo y de generalización, orientado a modelar de forma automatizada los dominios de alteración hidrotermal a partir de la firma geoquímica multielemental de las muestras.

El objetivo central de esta etapa es entrenar, calibrar y testear diversos algoritmos de clasificación (K-NN, Máquinas de Vectores de Soporte, Árboles de Decisión, Random Forest y Redes Neuronales) para que descubran las fronteras de decisión geoquímica multidimensionales que separan a cada ensamble de alteración.

Para garantizar la robustez, reproducibilidad y capacidad de generalización de los modelos predictivos evitando el riesgo de sobreajuste o overfitting, el flujo metodológico de esta fase supervisada se estructuró bajo el siguiente protocolo secuencial: Particionamiento ciego de los datos, optimización de hiperparámetros, entrenamiento y testeo de modelos.

Mediante esas fases supervisadas, el modelo que exhiba el mejor balance entre precisión matemática y coherencia con el zonamiento geológico real será seleccionado como el óptimo para la predicción principal, permitiendo vectorizar hacia las zonas de mayor interés económico y exportar datos consistentes para el modelamiento geológico tridimensional.

3.12.1 Preparación de los datos

Una vez se terminó de validar los resultados espectrales de las muestras, se continuo la validación con los minerales que tienen una mayor relación con las unidades de alteración, además de retirar los 13 minerales que no representativos y que no corresponden a los propósitos de la investigación, como (Biotite, Halloysite, Amphibole, Talc, Nontronite...), ya que la información para el entrenamiento de los modelos tiene que ser la más confiable, de esta manera se logró recopilar 44,152 muestras para 221 sondajes, con 13 minerales principales.

Seguidamente se procederá a asignar intervalos que sean representativos para cada dominio de alteración para ello se usó la información de los minerales en cada tramo y los 5 clustering generados, en esta etapa esta selección se realizara en Leapfrog. Para luego definir esta selección como el grupo de Entrenamiento como se aprecia en la Figura 28, esta selección de muestras se separará en dos grupos: uno como data entrenamiento y otro como data de validación, para el análisis en un 80% y 20% respectivamente.

Esta tabla combina con el 20% de muestras se con las muestras químicas, y se usarán los elementos ya filtrados y normalizados (34 elementos) para entrenar los modelos.


Finalmente, se revisarán 04 algoritmos de aprendizaje supervisado, y la diferencia entre ellos depende de la variable, en el caso de variables discretas son de clasificación y variables continuas serán de regresión.

3.12.2 Definición variables y asignación de dominios

La definición de dominios es la parte más importante del presente estudio, para ello se considerará el campo SWIRMin-nowt de la tabla de Aussepc más los clústeres generados en base a los minerales de la Tabla 16, al plotearse los datos en las Figuras 24, 25 y 26 se definen los siguientes dominios:

Figura 24

Asignación de los dominios de alteración (ArgAvd-Fil-Sk)




Nota: Fuente elaboración propia, generado en Leapfrog.

- La alteración argílica avanzada (ArgAvd), está definida por la combinación de pyrophyllite en mayor abundancia + alunite y a su vez por el cluster C4
- La alteración filica (Fil), está definida por la white mica y a su vez por el cluster C4
- La alteración skarn (Sk), está definida por la combinación de chlorite + montmorillonite + white mica + kaolinite y a su vez por el cluster C2.

Figura 25

Asignación de los dominios de alteración (ArgAv y ArgAvd_2)




Nota: Fuente elaboración propia, generado en Leapfrog.

- También tenemos una alteración argílica avanzada 2 (ArgAvd_2), que está definida por la combinación de alunite en mayor abundancia + pyrophyllite y a su vez por el cluster C4 + cluster C1. como se aprecia en la Figura 25.
- Para fines del estudio ambas alteraciones ArgAvd_2 y ArgAvd se considerarán como ArgAvd.
- La alteración propilitica (Pro), está definida por la combinación de la montmorillonite + chlorite y a su vez por la combinación de los cluster C2 + cluster C5, como se aprecia en la Figura 26.

Figura 26

Asignación de los dominios de alteración (Pro)




Nota: Fuente elaboración propia, generado en Leapfrog

- La alteración argílica (Arg), está definida por la combinación de la kaolinite + white mica y por el cluster C3, aprecia en la Figura 25.
- Y la zona de Oxidos (oxd) está definida por la presencia de hematita y el cluster C2, aprecia en la Figura 27.

Como resumen se muestra el análisis de combinación de la columna WIRMin-nowt que tiene las mezclas de minerales espectrales más los 5 Clusters obteniéndose 7 dominios, cuales se visualizan en la Figura 27.

Figura 27

Resumen de los clústeres y la definición de los 6 dominios de alteración



Nota: Fuente elaboración propia

Los 86,538 intervalos seleccionados se distribuyen entre los 6 dominios de la siguiente manera, donde los dominios más abundantes son de ArglAvd y Fil, teniendo los 2 dominios la mayor cantidad de tramos. El resumen se muestra en la Tabla 17.

Tabla 17

Tabla resumen con los dominios seleccionados para el entrenamiento

DOMINIO	INTERVALOS
Arg	978
ArgIAvd	23,308
Fill	28,669
Oxd	3,297
Pro	5050
Sk	25,266
Total general	86,538

Nota: Fuente elaboración propia


De lo revisado anteriormente, existen diversos modelos de machine learning que pueden ser usados enfocados según su objetivo, pero para este trabajo se revisaron 04 algoritmos de aprendizaje supervisado: máquinas de vectores de soporte (SVM), vecinos más cercanos (k-NN), reden neuronales y bosques aleatorios (RF), y el análisis del modelo que replica el logueo lo más fiel posible será detallado en la sección de resultados.

3.12.3 División de datos para entrenamiento y validación

El flujo de trabajo para las predicciones se muestra en la Figura 28, primero la Data de Entrada se divide en 2 grupos Data de Entrenamiento y Data de Testeo, la selección realizada antes seria la Data de Entrenamiento, esta data a su vez de separar en una Data de Entrenamiento 2 y Data de validación, 80% y 20% respectivamente.

Figura 28

Flujo de trabajo para las predicciones en base a los tramos seleccionados



Nota: Fuente elaboración propia

A diferencia de una división puramente aleatoria la cual puede inducir a errores por correlación espacial, este estudio dividió el universo de información analítica en función de la certidumbre interpretativa de los tramos de perforación. El flujo se configuró bajo la siguiente distribución volumétrica:

- **Conjunto de Entrenamiento (Training Dataset):**

Corresponde al subconjunto de muestras químicas cuyos tramos de perforación fueron rigurosamente seleccionados y validados de forma tridimensional en

Leapfrog Geo, asegurando la continuidad de los dominios de alteración hidrotermal. Este bloque suma un total de 86,539 tramos, de los cuales se extrajo el 80% (69,231 muestras) para alimentar y calibrar de forma directa los algoritmos de aprendizaje supervisado.

▪ **Conjunto de Testeo y Validación (Testing Dataset):**


Constituido por el saldo de la población de datos analíticos equivalentes a 147,820 muestras. Este conjunto se reservó estrictamente como una población ciega para evaluar de forma independiente la precisión, robustez y métricas de desempeño final de los modelos entrenados.

La arquitectura de esta distribución numérica y su disposición en una sección transversal conceptual respecto a los sondajes del depósito se encuentra ilustrada en la Figura 29.

De lo indicado anteriormente esta sería la división de la data de entrenamiento y data de testeo

Figura 29

Sección conceptual de los tramos para el entrenamiento y los tramos para testeo



Nota: Fuente elaboración propia

En la Tabla 18 se presenta la base de datos resultante del proceso de integración entre las asignaciones de dominios de alteración hidrotermal y los resultados de análisis geoquímicos obtenidos a partir de los sondeos. Este procedimiento fue realizado en el entorno de Orange Data Mining, como parte del flujo de preprocesamiento de datos previo al modelamiento.

En la tabla se observa la variable MOD_ALT, que representa la clasificación de los dominios de alteración, constituyendo la variable objetivo del modelo supervisado. Asimismo, se incluye el identificador de sondeo (holeid), el cual permite mantener la trazabilidad espacial de las muestras dentro del yacimiento.

Las variables restantes corresponden a concentraciones geoquímicas expresadas en partes por millón (ppm) y porcentaje (%), tales como As, Ba, Be, Bi, Ca, Cd, Cr, Fe, Mn y Co, entre otros. Estas variables representan los atributos predictivos (features) utilizados para entrenar los algoritmos de Machine Learning, permitiendo establecer relaciones entre la composición química y los dominios de alteración definidos.

Tabla 18

Tabla merge con las asignaciones de los dominios de alteración y muestras químicas

	MOD_ALT	holeid	As_ppm	Ba_ppm	Be_ppm	Bi_ppm	Ca_pct	Cd_ppm	Cr_ppm	Fe_pct	Mn_pct	Co_ppm
1	Oxd	AK-17-001	403.0	370.0	0.50	2.0	0.110	0.5	8.0	1.14	0.00210	1.0
2	Oxd	AK-17-001	403.0	370.0	0.50	2.0	0.110	0.5	8.0	1.14	0.00210	1.0
3	Oxd	AK-17-001	119.0	260.0	0.50	2.0	0.100	0.5	5.0	0.46	0.00150	1.0
4	Oxd	AK-17-001	119.0	260.0	0.50	2.0	0.100	0.5	5.0	0.46	0.00150	1.0
5	Oxd	AK-17-001	119.0	260.0	0.50	2.0	0.100	0.5	5.0	0.46	0.00150	1.0
6	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
7	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
8	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
9	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
10	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
11	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
12	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
13	Oxd	AK-17-001	128.0	250.0	0.50	2.0	0.110	0.5	6.0	0.41	0.00210	1.0
14	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
15	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
16	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
17	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
18	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
19	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
20	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
21	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
22	Oxd	AK-17-001	52.0	190.0	0.50	2.0	0.110	0.5	6.0	0.37	0.00210	1.0
23	Oxd	AK-17-001	125.0	140.00	0.50	2.0	0.150	0.5	5.0	0.50	0.00170	1.0

Nota: Fuente elaboración propia y generado en Orange

El proceso de integración de datos garantiza que cada registro contenga simultáneamente la información geoquímica y su respectiva clasificación de alteración, lo cual es fundamental para el entrenamiento de modelos supervisados. Esta estructura de datos permite realizar análisis exploratorios, identificación de patrones y posterior aplicación de algoritmos predictivos orientados a la delimitación de dominios geológicos.


3.12.4 Selección de variables y configuración de hiperparámetros para el entrenamiento

Selección de datos de entrada para Orange

En la Figura 30 muestra el proceso de selección y configuración de variables realizado en el software Orange Data Mining, el cual forma parte del flujo de trabajo de análisis de datos aplicado en esta investigación. En esta etapa, se definieron las variables de entrada (features) y la variable objetivo (target) que serán utilizadas en los modelos de aprendizaje automático. Las variables seleccionadas como features corresponden principalmente a datos geoquímicos (expresados en ppm y porcentaje), los cuales representan la composición química de los diferentes tramos muestreados. Estas variables constituyen la base para el entrenamiento de los algoritmos de Machine Learning, permitiendo identificar patrones y relaciones entre los elementos químicos y los dominios geológicos.

Figura 30

Selección en Orange de las variables de entrada y la variable objetivo



Nota: Fuente elaboración propia

Por otro lado, la variable objetivo se definió como MOD_ALT representa la clasificación de los dominios de alteración hidrotermal, la cual se busca predecir a partir de las variables de entrada. La correcta asignación de esta variable es fundamental, ya que condiciona el desempeño de los modelos supervisados.


Asimismo, se observa que ciertas variables han sido excluidas (ignored), debido a que no aportan información relevante para el modelo, presentan redundancia, o corresponden a identificadores y coordenadas espaciales que podrían introducir sesgos en el análisis. Este proceso de depuración de datos contribuye a mejorar la eficiencia y precisión de los modelos predictivos.

Flujo de trabajo en Orange

En la Figura 31 muestra el flujo de trabajo en Orange Data Mining para el entrenamiento de modelos de Machine Learning. Los datos son preprocesados mediante la selección de variables y posteriormente utilizados para entrenar algoritmos como Random Forest, k-NN, Redes Neuronales y SVM. Finalmente, los modelos son evaluados mediante métricas de desempeño, permitiendo identificar el algoritmo más adecuado para la predicción de dominios de alteración.

Figura 31

Flujo de trabajo en Orange para el entrenamiento de los 04 algoritmos predictivos



Nota: Fuente elaboración propia

3.12.4.1 Hiperparametros para Random Forest. Random Forest construye un conjunto de árboles de decisión. Cada árbol se desarrolla a partir de una muestra de bootstrap de los datos de entrenamiento. Al desarrollar árboles individuales, se extrae un subconjunto arbitrario de atributos (de ahí el término "Random"), del cual se selecciona el mejor atributo para la división. El modelo final se basa en la mayoría de los votos de los árboles desarrollados individualmente en el bosque.

Hiperparametros básicos:

- Número de árboles: especifique cuántos árboles de decisión se incluirán en el bosque.
- Número de árboles considerados en cada división: Especifique cuántos atributos se extraerán arbitrariamente para su consideración en cada nodo. Si no se especifica (opción " Número de atributos... " sin marcar), este número es igual a la raíz cuadrada del número de atributos en los datos.
- Entrenamiento replicable: Fijar la semilla para la generación del árbol, lo que permite la replicabilidad de los resultados.
- Distribución de clases de equilibrio: pesa las clases inversamente proporcionales a sus frecuencias.


Control del crecimiento:

- Limitar la profundidad de árboles individuales: la propuesta original de Breiman es cultivar los árboles sin ninguna poda previa, pero como la poda previa a menudo funciona bastante bien y es más rápida, el usuario puede establecer la profundidad a la que se cultivarán los árboles.
- No dividir subconjuntos más pequeños que: seleccione el subconjunto más pequeño que se pueda dividir.

Estas configuraciones se muestran en la Tabla 19.

Tabla 19

Tabla con los parámetros para el modelo Random Forest

PARÁMETROS DEL MODELO RANDOM FOREST	
	Parámetros del modelo Random Forest ▪ Número de árboles: 10 ▪ Número máximo de características consideradas: 8 ▪ Entrenamiento replicable: Sí ▪ Profundidad máxima del árbol: 4 ▪ Detener la división de nodos con el máximo de instancias: 5

Nota: Fuente elaboración propia y generado en Orange.

3.12.4.2 Hiperparámetros para Knn. El widget de red neuronal utiliza el algoritmo de perceptrón multicapa de sklearn, que puede aprender modelos no lineales, así como lineales.


Hiperparámetros básicos:

- Establezca el número de vecinos más cercanos
- Parámetros de distancia:
 - Euclidiana ("línea recta", distancia entre dos puntos)
 - Manhattan (suma de las diferencias absolutas de todos los atributos)
 - Máxima (mayor de las diferencias absolutas entre atributos)
 - Mahalanobis (distancia entre el punto y la distribución).
- Los pesos que puedes utilizar son:
 - Uniforme: todos los puntos de cada vecindario tienen el mismo peso.
 - Distancia: los vecinos más cercanos a un punto de consulta tienen una mayor influencia que los vecinos más alejados.

Estas configuraciones se muestran en la Tabla 20.

Tabla 20

Tabla con los parámetros para el modelo kNN.

PARÁMETROS DEL MODELO KNN	
	Parámetros del modelo kNN ▪ Número de vecinos: 5 ▪ Métrica: Euclidiana ▪ Ponderación: Por distancias

Nota: Fuente elaboración propia y generado en Orange

3.12.4.3 Hiperparametros para Neural Network. El widget de red neuronal utiliza el algoritmo de perceptrón multicapa de sklearn, que puede aprender modelos no lineales, así como lineales.

Hiperparametros básicos:

- Neuronas por capa oculta: se define como el i-ésimo elemento que representa el número de neuronas en la i-ésima capa oculta. Por ejemplo, una red neuronal con 3 capas se puede definir como 2, 3, 2.
- Función de activación, para la capa oculta se pueden usar:
 - Identidad: activación sin operación, útil para implementar un cuello de botella lineal
 - Logística: la función sigmoidea logística
 - tanh: la función tan hiperbólica
 - ReLu: la función unitaria lineal rectificada
- Solucionador (Solver), para optimización de peso se pueden usar:
 - L-BFGS-B: un optimizador en la familia de métodos cuasi-Newton
 - SGD: descenso de gradiente estocástico
 - Adam: optimizador basado en gradientes estocásticos

- Alfa: parámetro de penalización L2 (término de regularización)
- Iteraciones máximas: número máximo de iteraciones

Los demás parámetros se establecen en los valores predeterminados de sklearn.

Estas configuraciones se muestran en la Tabla 21.

Tabla 21

Tabla con los parámetros para el modelo Neural Network

PARÁMETROS DEL MODELO NEURAL NETWORK	
	Parámetros del modelo Neural Network
	▪ Capas ocultas: 100 ▪ Activación: ReLu ▪ Solucionador: Adam ▪ Alfa: 0,0001 ▪ Máximo de iteraciones: 200 ▪ Entrenamiento replicable: Sí

Nota: Fuente elaboración propia y generado en Orange

3.12.4.4 Hiperparametros para SVM. La máquina de vectores de soporte (SVM) es una técnica de aprendizaje automático que separa el espacio de atributos con un hiperplano, maximizando así el margen entre las instancias de diferentes clases o valores de clase. Esta técnica suele ofrecer resultados predictivos excepcionales. Orange integra una implementación popular de SVM del paquete LIBSVM.

Hiperparametros básicos:

- Tipo de SVM con configuración de error de prueba. El SVM y el v-SVM se basan en diferentes minimizaciones de la función de error. En el lado derecho, puede establecer los límites de error de prueba:

SVM:

- Costo: término de penalización por pérdida y se aplica para tareas de clasificación y regresión.

- ϵ : parámetro del modelo ϵ -SVR, aplicable a tareas de regresión. Define la distancia con respecto a los valores verdaderos dentro de la cual no se aplica ninguna penalización a los valores predichos.


v-SVM:

- Costo: término de penalización por pérdida y se aplica solo a tareas de regresión.
 - ν : parámetro del modelo ν -SVR, aplicable a tareas de clasificación y regresión. Un límite superior para la fracción de errores de entrenamiento y un límite inferior para la fracción de vectores de soporte.
- El kernel es una función que transforma el espacio de atributos en un nuevo espacio de características para ajustarse al hiperplano de margen máximo, lo que permite al algoritmo crear el modelo con kernels lineales, polinomiales, RBF y sigmoideos. Las funciones que especifican el kernel se presentan al seleccionarlás, y las constantes involucradas son:
- γ : para la constante gamma en la función kernel (el valor recomendado es $1/k$, donde k es el número de atributos, pero cómo es posible que no haya un conjunto de entrenamiento dado al widget, el valor predeterminado es 0 y el usuario tiene que configurar esta opción manualmente),
 - c : para la constante c_0 en la función kernel (predeterminado 0), y
 - d : para el grado del núcleo (predeterminado 3).

Estas configuraciones se muestran en la Tabla 22.

Tabla 22

Tabla con los parámetros para el modelo SVM

PARÁMETROS DEL MODELO SVM	
	Parámetros del modelo SVM ▪ Tipo de SVM: SVM, C=1.0, ϵ=0.1 ▪ Núcleo (Kernel): RBF, $\exp(-\text{auto} x-y ^2)$ ▪ Tolerancia numérica: 0.001 ▪ Límite de iteración: 100


Nota: Fuente elaboración propia y generado en Orange

3.12.5 Evaluación de los algoritmos entrenados con la geoquímica

Los algoritmos para evaluar serán de clasificación, una vez finalizado re revisara y compara los parámetros de eficiencia y calidad con el objetivo de optar por el más optimo, para ello haremos uso de la matriz de confusión y el análisis del ROC, para cada dominio. Y esto se aprecia en el flujo de la Figura 32.

Figura 32

Flujo de trabajo para el entrenamiento en Orange, mostrando el test and score, ROC y matriz de confusión



Nota: Fuente elaboración propia

3.12.6 Métricas de evaluación

Para cuantificar el desempeño de los modelos predictivos entrenados con la data química y seleccionar el algoritmo óptimo, se definieron métricas estadísticas basadas en la interpretación de la matriz de confusión y el análisis de curvas operativas del receptor (ROC). Estas métricas permiten evaluar la calidad de la clasificación para cada dominio de alteración mediante los siguientes parámetros fundamentales:

Matriz de confusión:

Es una matriz cuadrada que contrasta los valores reales de campo frente a las clasificaciones predichas por cada algoritmo. A partir de esta matriz se calculan los Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN). Y usando las formulas exactitud (4), sensibilidad (5) y especificidad (6) ya planteadas en el marco teórico:

$$Exactitud = \frac{VP+VN}{VP+VN+FP+FN} \quad (4)$$

$$Precisión = \frac{VP}{VP+FP} \quad (5)$$

$$Exhaustividad = \frac{VP}{VP+FN} \quad (6)$$

Puntuación F1 (F1-Score):

Se define como la media armónica entre la precisión y la exhaustividad. Esta métrica es especialmente crítica en este modelo debido a que balancea de forma robusta la calidad de la predicción en dominios de alteración que posean distribuciones numéricas asimétricas dentro del yacimiento:

$$F1 = 2 \frac{Precisión \times Recall}{Precisión + Recall} \quad (7)$$

Análisis de Curva ROC y Área Bajo la Curva (AUC):

La curva ROC (Receiver Operating Characteristic) representa de forma gráfica la tasa de verdaderos positivos en función de la tasa de falsos positivos a diferentes umbrales de discriminación. El parámetro cuantitativo de selección óptima es el valor del área bajo la curva (AUC); un valor de AUC = 1.0 indica una clasificación perfecta libre de solapamiento entre dominios, mientras que un valor de 0.5 denota un comportamiento equivalente a una clasificación aleatoria.

Capítulo IV. Análisis e interpretación de resultados

4.1 Resultados del análisis exploratorio de datos

El análisis exploratorio de datos (EDA) se ejecutó con el propósito de identificar la distribución espacial, continuidad geométrica y zonación de las variables mineralógicas clave antes de su integración en los modelos predictivos. Este procedimiento permitió validar tridimensionalmente la consistencia geológica para las variables categóricas y numéricas de los datos espectrales.

4.1.1 Variables categóricas


4.1.1.1 Visualización en sección de las variables categóricas. Para un mejor análisis de las variables categóricas se prepararon secciones transversales para la visualización de la zonación mineral de la zona del SWIR y VNIR, en base a las columnas aiMineral1 (arcilla más abundante) y VNIRMinerals (óxidos) y SWIRMin_nowt (mezclas de arcillas), de las Tablas 10, 11 y 12.

Primero se plotea en una sección SW-NE Figura 33 a, donde se muestra el plot de la columna aiMineral1 que solo tiene el mineral más abundante, este plot muestra un patrón o contraste que ayude reconocer dominios de alteración que se pueden modelar, se reconocen niveles de pirofilita - alunita, kaolinita - micas blancas, cloritas y carbonatos, y comparado con el logeo de alteraciones si guardan una relación moderada. Por lo que será usado en los algoritmos predictivos.

Segundo se plotea en una sección SW-NE Figura 33 b, donde se muestra el plot de la columna VNIRMinerals que solo tiene el mineral más abundante de la zona del visible, en este plot se muestra un patrón o contraste para los óxidos (presencia de goethita y hematita), este campo si ayuda a reconocer dominios de alteración a modelar. Por ello debe ser usado en los algoritmos predictivos.

Figura 33

Secciones que muestran los minerales por abundancia de la zona del SWIR y VNIR




Nota: Fuente elaboración propia, Secciones mirando al NW.

Tercero se plotea en una sección SW-NE Figura 34, donde se muestra los compositos de los minerales columna SWIRMin_nowt (mezclas de 1 a 6 minerales), lo que se observa en la figura es que son tantas las combinaciones que no se muestra un patrón o contraste que ayude reconocer dominios de alteración que se puedan modelar, además al comparado con el logueo de alteraciones no guardan relación. Por lo que se queda descartado para ser usado en los algoritmos predictivos.

Figura 34

Secciones que muestran las mezclas de los minerales en de la zona del SWIR



Nota: Fuente elaboración propia, Secciones mirando al NW

4.1.2 Variables numéricas

4.1.2.1 Distribución en planta de los minerales espectrales. En base a los 13 minerales espectrales más importantes de la tabla 15 se definen los ensambles de alteración más importantes de la siguiente manera:

Alteración Argílica Avanzada (Alta sulfuración), los minerales indicadores: Alunita, Pyrophyllite, Dickite, Kaolinite, Diaspore.

La distribución en los mapas de la Figura 35a muestran concentraciones significativas de alunita y pyrophyllite en el centro-sur y este del área, típicamente


asociadas a fluidos hidrotermales ácidos y ricos en SO_2 (White et al., 1995). La kaolinite y dickite aparecen como minerales de transición a temperaturas más bajas dentro del mismo dominio (Rusk et al., 2008). La presencia de diaspore, un mineral de alta temperatura refuerza la hipótesis de un núcleo hidrotermal intensamente acidificado.

Alteración Argílica Intermedia y Fillica, los minerales indicadores: White Mica, Dickite, Kaolinite, Montmorillonite

La distribución en los mapas de la Figura 35b muestran la amplia distribución de white mica (illita-muscovita) sugiere un halo filico extenso en torno al núcleo ácido. La presencia de montmorillonite indica posibles zonas de neutralización secundaria o mezcla de fluidos meteóricos (Berger et al., 2008).

Figura 35a


Ploteo en planta de los minerales para Argílica Avanzada



Nota: Fuente elaboración propia

Figura 35b

Ploteo en planta de los minerales para Argílica Intermedia y Fillica




Nota: Fuente elaboración propia

Alteración Propílica, los minerales indicadores: Chlorite, Carbonate y Goethite

La distribución en los mapas de la Figura 36 muestran la distribución clorita y los carbonatos aparecen en zonas más externas, lo cual es típico de alteración propílica desarrollada en condiciones de mayor neutralidad y menor temperatura (Titley & Beane, 1981). La Goethite, en cambio, domina en superficie y sugiere procesos de oxidación supergénica (Deyell et al., 2005).

Figura 36

Ploteo en planta de los minerales para Argílica / Propílica.



Nota: Fuente elaboración propia

4.1.3. Correlaciones entre variables

4.1.3.1 Pearson (r). Los resultados para los 13 minerales espectrales más abundantes se muestra una asociación moderada positiva se muestra para los minerales Chlorite_SC y Carbonate_SC es la más alta.

Tabla 23

Matriz de Correlación Pearson

WhiteMica_SC	1.000	0.130	0.050	-0.001	-0.072	-0.048	-0.022	-0.260	-0.005	-0.384	-0.187	-0.082	0.002
Chlorite_SC	0.130	1.000	0.305	0.112	-0.053	-0.045	0.271	-0.127	0.010	-0.227	-0.093	-0.041	0.013
Carbonate_SC	0.050	0.305	1.000	0.091	-0.046	-0.029	0.096	-0.080	-0.005	-0.145	-0.059	-0.026	-0.015
Epidote_SC	-0.001	0.112	0.091	1.000	-0.024	-0.013	0.023	-0.036	-0.003	-0.066	-0.027	-0.012	-0.004
Kaolinite_SC	-0.072	-0.053	-0.046	-0.024	1.000	0.068	-0.035	-0.212	-0.029	-0.264	-0.077	-0.061	-0.047
Dickite_SC	-0.048	-0.045	-0.029	-0.013	0.068	1.000	-0.043	-0.088	-0.018	-0.178	-0.068	-0.028	-0.019
Montmor_SC	-0.022	0.271	0.096	0.023	-0.035	-0.043	1.000	-0.119	-0.032	-0.217	-0.089	-0.038	-0.039
Alunite_SC	-0.260	-0.127	-0.080	-0.036	-0.212	-0.088	-0.119	1.000	-0.078	-0.218	-0.096	-0.002	-0.088
Gypsum_SC	-0.005	0.010	-0.005	-0.003	-0.029	-0.018	-0.032	-0.078	1.000	-0.135	-0.058	-0.026	-0.025
Pyrophyllite_SC	-0.384	-0.227	-0.145	-0.066	-0.264	-0.178	-0.217	-0.218	-0.135	1.000	-0.053	-0.049	-0.164
Diaspore_SC	-0.187	-0.093	-0.059	-0.027	-0.077	-0.068	-0.089	-0.096	-0.058	-0.053	1.000	0.007	-0.072
Zunyte_SC	-0.082	-0.041	-0.026	-0.012	-0.061	-0.028	-0.038	-0.002	-0.026	-0.049	0.007	1.000	-0.029
Water_silica_SC	0.002	0.013	-0.015	-0.004	-0.047	-0.019	-0.039	-0.088	-0.025	-0.164	-0.072	-0.029	1.000

Nota: Fuente elaboración propia y generado en Orange

4.1.3.2 Spearman (p). Los resultados para los 13 minerales espectrales más abundantes se muestra una asociación moderada positiva se muestra para los minerales Chlorite_SC y Montmor_SC es la más alta y el grado de asociación moderada negativa se muestra para los grupos de minerales WhiteMica_SC/ Alunite_SC y WhiteMica_SC/ Pyrophyllite_SC.

Tabla 24

Matriz de Correlación Spearman

WhiteMica_SC	1.000	0.336	0.228	0.049	0.040	0.018	0.120	-0.445	0.077	-0.438	-0.240	-0.126	0.095
Chlorite_SC	0.336	1.000	0.534	0.220	0.004	-0.067	0.488	-0.266	0.048	-0.341	-0.150	-0.075	0.069
Carbonate_SC	0.228	0.534	1.000	0.294	-0.025	-0.048	0.254	-0.177	0.016	-0.235	-0.103	-0.051	0.011
Epidote_SC	0.049	0.220	0.294	1.000	-0.014	-0.017	0.072	-0.060	0.013	-0.081	-0.035	-0.017	0.012
Kaolinite_SC	0.040	0.004	-0.025	-0.014	1.000	0.213	0.051	-0.261	0.013	-0.219	-0.034	-0.058	-0.015
Dickite_SC	0.018	-0.067	-0.048	-0.017	0.213	1.000	-0.052	-0.094	-0.001	-0.201	-0.060	-0.036	-0.000
Montmor_SC	0.120	0.488	0.254	0.072	0.051	-0.052	1.000	-0.189	-0.041	-0.252	-0.109	-0.054	-0.041
Alunite_SC	-0.445	-0.266	-0.177	-0.060	-0.261	-0.094	-0.189	1.000	-0.131	0.059	0.053	0.102	-0.116
Gypsum_SC	0.077	0.048	0.016	0.013	0.013	-0.001	-0.041	-0.131	1.000	-0.138	-0.068	-0.039	-0.012
Pyrophyllite_SC	-0.438	-0.341	-0.235	-0.081	-0.219	-0.201	-0.252	0.059	-0.138	1.000	0.080	0.023	-0.165
Diaspore_SC	-0.240	-0.150	-0.103	-0.035	-0.034	-0.060	-0.109	0.053	-0.068	0.080	1.000	0.071	-0.080
Zunyte_SC	-0.126	-0.075	-0.051	-0.017	-0.058	-0.036	-0.054	0.102	-0.039	0.023	0.071	1.000	-0.037
Water_silica_SC	0.095	0.069	0.011	0.012	-0.015	-0.000	-0.041	-0.116	-0.012	-0.165	-0.080	-0.037	1.000

Nota: Fuente elaboración propia y generado en Orange

4.2 Resultados del aprendizaje automático no supervisado

El aprendizaje Automático No Supervisado busca patrones o estructuras inherentes en los datos sin información explícita sobre salidas deseadas, con esto se busca la segmentación de datos que pueda diferenciar dominios de alteración.

Las técnicas para usar de aprendizaje automático no supervisado son agrupamiento (Clustering) y reducción de la dimensionalidad.

El agrupamiento consiste en dividir un conjunto de datos en grupos o clústeres de manera que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos. Métodos como k-means, DBSCAN o hierarchical clustering se utilizan ampliamente para identificar asociaciones entre variables, lo cual es particularmente útil en la clasificación de zonas con firmas geoquímicas similares o tipos de alteración hidrotermal (Jain et al., 1999).

Por otro lado, la reducción de la dimensionalidad permite simplificar los datos sin perder su estructura esencial, facilitando tanto su visualización como su procesamiento posterior. Técnicas como el Análisis de Componentes Principales (PCA) o t-SNE son frecuentemente empleadas para eliminar redundancias y concentrar la variabilidad en un menor número de dimensiones, lo que es clave cuando se trabaja con bases de datos geoquímicas multivariadas (Jolliffe & Cadima, 2016).


La combinación de ambas técnicas es especialmente poderosa: la reducción de dimensionalidad puede utilizarse como paso previo al agrupamiento, mejorando la eficiencia y precisión del modelo al eliminar el "ruido" en los datos. En contextos como la definición de dominios de alteración, estos métodos no supervisados pueden revelar estructuras asociaciones mineralógicas previamente no identificadas.

4.2.1 Análisis de componentes principales

A continuación, en la Figura 37 se muestra el PCA con los 13 minerales espectrales más importantes.

Figura 37

Diagrama PCA mostrando la distribución de los cinco grupos identificados.



Nota: Fuente elaboración propia, generado en Orange

Aunque no están etiquetados, los ejes de la gráfica representan los componentes principales (generalmente el PC1 y PC2, que capturan la mayor parte de la varianza en los datos). Estos ejes son nuevas dimensiones que maximizan la variabilidad de los datos, permitiendo visualizar las relaciones entre los minerales en un espacio de menor dimensión (2D en este caso).

Los puntos de colores dispersos en el gráfico representan las muestras individuales o los datos subyacentes que se están clasificando o analizando. Cada punto es una "observación" de una alteración mineral. Y la dirección y longitud de los vectores indican la contribución de cada mineral a la varianza de los datos en ese componente principal

Los colores de estos puntos (azul, rojo, verde, naranja, amarillo) corresponden a las clases o clústeres (C1 a C5) identificados previamente, probablemente a través de un análisis de clústeres como el que se mostró en el dendrograma (Figura 26). Esto significa que cada color agrupa muestras que son mineralógicamente similares.

Del ploteo de los clustering se pudo identificar las siguientes asociaciones de minerales de alteración:

C1 (Azul Claro, solo Pyrophyllite_SC): Este clúster se sitúa en una región separada, con su vector apuntando hacia él. Sugiere una asociación única con pirofilita, diferenciada de otros grupos.

C2 (Azul/Cian, con Alunite_SC, Zunyite_SC, Diaspore_SC): Estos minerales se agrupan estrechamente en la parte izquierda-central del gráfico, y los puntos azules/cian se concentran alrededor de sus vectores. Esto indica una asociación mineralógica fuerte, típica de alteración argílica avanzada (rica en alunita, zunita, diásporo).

C3 (Verde, con Epidote_SC, Montmor_SC, Chlorite_SC, Carbonate_SC): Estos minerales se ubican en la parte superior derecha, con los puntos verdes concentrados en esa área. Esta asociación es común en alteración propilítica (epidota, clorita, carbonato, montmorillonita).

C4 (Naranja, con Kaolinite_SC, Dickite_SC): Estos dos minerales están en la parte inferior de la gráfica, con los puntos naranjas asociados. Esto representa la alteración argílica intermedia o caolinítica.

C5 (Amarillo, con Gypsum_SC, WhiteMica_SC, Water_silica_SC): Este clúster se extiende en la parte central-inferior y derecha, con puntos amarillos asociados. La presencia de yeso (Gypsum), mica blanca (WhiteMica, posiblemente sericita) y sílice sugiere otro tipo de alteración, posiblemente sericitica o silicificación, con componentes tardíos o de baja temperatura.

En base a la identificación de dominios se procede a generar un intervalo de selección denominado Modelo_Alte en Leapfrog, este a su vez se comparará con la columna Geointerpretacion identificando mejor los contactos en base a la definición de los clustering formados.


4.2.2 Agrupamiento jerárquico (Hierarchical Clustering)

Para la construcción del dendograma se necesita la determinación de la distancia euclidiana, de los 13 minerales espectrales definidos en la Tabla 15 como se vio

anteriormente este valor se representa la diferencia entre dos datos, como se muestra en la Figura 38. donde se aprecia 4 grupos bien marcados.

Figura 38

Análisis Hierarchical Clustering



Nota: Fuente elaboración propia, generado en Orange

En la imagen muestra un dendrograma, un diagrama arborizado que ilustra la disposición de los clústeres generados mediante la agrupación jerárquica. Muestra varios componentes (p. ej., Pirofilita_SC, Alunita_SC, Zunyita_SC) agrupados en clústeres más grandes (C1, C2, C3, C4, C5) según su similitud.

El eje horizontal representa la disimilitud o distancia entre los clústeres. Los componentes o clústeres más cercanos son más similares. Por ejemplo,

C1 contiene solo Pirofilita_SC.

C2 agrupa Alunita_SC, Zunyita_SC y Diáspora_SC, lo que sugiere una gran similitud entre ellos.

C3 incluyen Epidota_SC, Montmor_SC, Clorita_SC y Carbonato_SC, el grupo

C4 contiene Caolinita_SC y Dickita_SC y el grupo

C5 incluye Yeso_SC, Mica Blanca_SC y Agua_Sílice_SC.


4.2.3 Agrupamiento mediante K-Means

En este caso se grupa los datos en conjuntos homogéneos según ciertos criterios de similitud. Para la investigación se ejecutó el algoritmo K-Means y se realizó un Clustering a 5 dominios, este número de cluster ($k=5$) fue definido en base a las agrupaciones mineralógicas que se generaron en el dendrograma.

Para una mejor visualización de los datos se preparó la Figura 39 que es una sección SW-NE donde se muestran en perfil la ocurrencia de los cluster del 1 al 5 (C1 a C5) y la Figura 40 una vista en 3D de las perforaciones de la unidad, donde la traza de las perforaciones está codificada por color según el clúster mineralógico al que pertenece cluster del 1 al 5 (C1 a C5).

Figura 39

Visualización en sección SW-NE de los 05 clustering



Nota: Fuente elaboración propia

C1 (Azul): Corresponde a otro tipo de alteración (asociado a Alunita, Zunita, Diasporo, indicando alteración argílica avanzada).

C2 (Rojo): Indica un tercer tipo de alteración (asociado a Epidota, Montmorillonita, Clorita, Carbonato, sugiriendo alteración propilítica).

C3 (Verde): Indica un tercer tipo de alteración (asociado a Alunita y Oxidos, sugiriendo la zona de óxidos).

C4 (Naranja): Denota un cuarto tipo de alteración (asociado a Mica Blanca, Yeso y Silice, indicando alteración filica).

C5 (Amarillo): Representa un quinto tipo de alteración.

Una distribución espacial de los Clústeres en el Leapfrog como se muestra en la figura 26 donde se tiene los siguientes dominios:

Dominio de C1 (Azul): El clúster C1 (azul) parece ser el más extendido y dominante en el volumen perforado, especialmente en las partes más bajas y centrales de la visualización, así como en muchas de las perforaciones individuales. Esto podría indicar una alteración regional o de fondo.


Dominio de C2 (Rojo): El clúster C2 (rojo), asociado a la alteración argílica avanzada, se observa concentrado en ciertas áreas, especialmente en la parte central-derecha del gráfico y en porciones específicas de algunas perforaciones. Su presencia en agrupaciones discretas puede ser muy relevante para la exploración, ya que este tipo de alteración suele estar directamente ligada a mineralizaciones de alta sulfuración (como algunos depósitos de oro y cobre).

Dominio de C3 (Verde): El clúster C3 (verde), asociado a la alteración propilítica, también se distribuye en varias perforaciones, a menudo intercalado con el azul. La propilítica es común en la periferia de muchos sistemas de alteración hidrotermal.

Dominio de C4 (Naranja) y C5 (Amarillo): Estos clústeres se presentan en segmentos más dispersos o menos dominantes en comparación con C1 y C2, pero su presencia es crucial para delinear la zonación de alteración. El amarillo (C5) parece ser bastante común también, a menudo superpuesto o mezclado con los otros clústeres.

Figura 40

Visualización en de 3D de la distribución de los 05 clustering



Nota: Fuente elaboración propia

Similitud entre muestras:

Muestras de colores similares están agrupadas, indicando que tienen características mineralógicas similares.

Asociaciones de minerales:

Los minerales cuyos vectores apuntan en direcciones similares o están cerca de un clúster específico tienden a ocurrir juntos en esas muestras.

Separación de tipos de alteración:

Los diferentes clústeres de colores representan distintos tipos de alteración mineralógica, o "dominios geológicos", que son distintivos en su composición mineral. Por ejemplo, se pueden identificar claramente las zonas de alteración argílica avanzada (C2), propilítica (C3) y argílica (C4).

4.3 Resultados del aprendizaje automático supervisado

Los resultados para las 69,231 muestras seleccionadas para el entrenamiento.

4.3.1 Resultados del rendimiento del entrenamiento de los modelos

Desempeño de los 04 algoritmos entrenados:

Tabla 25

Tabla de evaluación de parámetros de calidad


PROMEDIO DE RENDIMIENTO POR MODELO			
Model	AUC	Prec	Recall
SVM	0.585	0.340	0.285
Random Forest	0.990	0.993	0.993
Neural Network	0.998	0.969	0.969
kNN	0.999	0.981	0.981

Nota: Fuente elaboración propia y generado en Orange

Para una mejor visualización y validación de los 4 algoritmos de clasificación se ejecuta la predicción para el total de muestras químicas para luego generar una sección a lo largo de la orientación de los mimos, mostrando resultados parecidos, como se muestra en la Figura 41.

Figura 41

Sección mostrando los resultados de los 4 algoritmos usados para las predicciones de los dominios de alteración



Nota: Fuente elaboración propia

4.3.2 Resultados de la matriz de confusión por modelo

La matriz de confusión e el primer análisis para evaluar el desempeño de los algoritmos, en la Figura 42 se muestra los resultados en porcentaje comparando los acierto y fallos de los dominios para cada uno de los modelos.

Figura 42

Matriz de confusión del testeo para los 4 modelos

KNN									
Actual	Predicted							Σ	
	Arg	ArgIAvd	Fill	Oxd	PTE	Pro	Sk		
	Arg	97.5 %	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %		199
	ArgIAvd	1.5 %	97.4 %	1.3 %	2.0 %	0.0 %	0.0 %		4575
	Fill	0.5 %	2.2 %	97.6 %	0.8 %	0.0 %	0.0 %		5804
	Oxd	0.0 %	0.1 %	0.1 %	97.3 %	0.1 %	0.0 %		660
	PTE	0.5 %	0.0 %	0.0 %	0.0 %	99.4 %	0.0 %		945
	Pro	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %	100.0 %		4
	Sk	0.0 %	0.2 %	1.0 %	0.0 %	0.5 %	0.0 %		5120
Σ		201	4600	5803	665	944	1	5093	17307
Neuronal Network									
Actual	Predicted							Σ	
	Arg	ArgIAvd	Fill	Oxd	PTE	Pro	Sk		
	Arg	98.5 %	0.1 %	0.0 %	0.0 %	0.0 %	0.0 %		199
	ArgIAvd	0.0 %	95.9 %	2.7 %	3.0 %	0.0 %	0.0 %		4575
	Fill	0.0 %	3.7 %	95.9 %	0.1 %	1.0 %	0.0 %		5804
	Oxd	0.0 %	0.1 %	0.1 %	96.9 %	0.0 %	0.0 %		660
	PTE	0.0 %	0.0 %	0.1 %	0.0 %	96.9 %	0.0 %		945
	Pro	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %	100.0 %		4
	Sk	1.5 %	0.1 %	1.2 %	0.0 %	2.1 %	0.0 %		5120
Σ		197	4583	5798	673	953	4	5099	17307
Random Forest									
Actual	Predicted							Σ	
	Arg	ArgIAvd	Fill	Oxd	PTE	Pro	Sk		
	Arg	100.0 %	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %		199
	ArgIAvd	0.0 %	99.2 %	0.7 %	0.3 %	0.0 %	0.0 %		4575
	Fill	0.0 %	0.7 %	98.7 %	0.0 %	0.0 %	0.4 %		5804
	Oxd	0.0 %	0.1 %	0.1 %	99.7 %	0.0 %	0.0 %		660
	PTE	0.0 %	0.0 %	0.0 %	0.0 %	99.9 %	0.0 %		945
	Pro	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %	100.0 %		4
	Sk	0.0 %	0.0 %	0.5 %	0.0 %	0.1 %	0.0 %		5120
Σ		198	4567	5830	653	945	3	5111	17307
SVM									
Actual	Predicted							Σ	
	Arg	ArgIAvd	Fill	Oxd	PTE	Pro	Sk		
	Arg	26.3 %	0.0 %	5.4 %	0.0 %	0.0 %	0.0 %		199
	ArgIAvd	12.0 %	31.3 %	24.1 %	68.5 %	15.9 %	0.0 %		4575
	Fill	15.2 %	20.1 %	43.8 %	17.0 %	26.1 %	0.0 %		5804
	Oxd	0.0 %	5.3 %	0.2 %	14.1 %	0.0 %	0.0 %		660
	PTE	0.0 %	0.8 %	0.6 %	0.0 %	13.8 %	0.0 %		945
	Pro	0.0 %	0.0 %	0.0 %	0.0 %	0.0 %	42.9 %		4
	Sk	46.5 %	42.5 %	25.9 %	0.4 %	44.2 %	57.1 %		5120
Σ		217	4675	2552	2848	1924	7	5084	17307
a). Los modelos muestran una buena presión, coincidencias mayores al 96%, siendo el Randon Forest de mejor y por lo contrario el modelo SVM se tiene las más bajas métricas de testeo									

Nota: Fuente elaboración propia

El Random Forest, al ser un método de conjunto que combina múltiples árboles de decisión, demostró una robustez excepcional y una alta capacidad de generalización, lo que se tradujo en una precisión consistentemente elevada en casi todas las categorías. Esto puede atribuirse a su capacidad para reducir el sobreajuste y manejar la complejidad de los datos de manera efectiva (Breiman, 2001).

Por otro lado, el bajo rendimiento del modelo SVM en este contexto sugiere que los datos podrían no ser linealmente separables o que los hiperparámetros del SVM no fueron optimizados adecuadamente para capturar las relaciones subyacentes. La elección de un kernel inapropiado o valores subóptimos para parámetros como C (costo) o gamma podrían explicar la baja precisión observada (Cortes & Vapnik, 1995). En futuras investigaciones, sería beneficioso explorar diferentes tipos de kernels y realizar una búsqueda exhaustiva de hiperparámetros para mejorar su desempeño.

Las Redes Neuronales y KNN, a pesar de no alcanzar los niveles de precisión del Random Forest, ofrecieron resultados satisfactorios. Las Redes Neuronales, con su capacidad para aprender patrones complejos y no lineales, son a menudo potentes clasificadores, aunque su rendimiento puede ser sensible a la arquitectura de la red y al proceso de entrenamiento (Goodfellow et al., 2016). KNN, un algoritmo simple basado en la distancia demostró ser sorprendentemente efectivo, lo que indica que la estructura de los datos presenta clusters bien definidos.


4.3.3 Curvas ROC y evaluación del rendimiento


Durante el análisis de distintos modelos de clasificación aplicados a la identificación de tipos de alteración hidrotermal, se observaron diferencias significativas en el desempeño de los algoritmos evaluados.

En términos generales, los modelos Random Forest y las Redes Neuronales demostraron ser los más efectivos, al presentar curvas ROC que se aproximan al punto ideal Figura 43, lo cual evidencia una alta capacidad para discriminar adecuadamente entre zonas alteradas y no alteradas (Breiman, 2001; LeCun et al., 2015).

Figura 43

Resultados de ROC del testeo para los 4 modelos y por cada dominio





Nota: Fuente elaboración propia

Por ejemplo, en alteraciones como la argílica, argílica avanzada, fílica, y propilítica, ambos modelos alcanzaron valores de AUC cercanos a 1. Esto significa que fueron muy precisos tanto para identificar correctamente las zonas alteradas como para evitar falsos positivos. k-NN, por su parte, mostró un rendimiento aceptable: en algunos casos se acercó bastante a los mejores modelos, aunque fue más sensible al ruido o a las zonas con menor separación entre clases.

En contraste, SVM tuvo un comportamiento más débil en casi todas las categorías. Sus curvas ROC mostraron una menor capacidad para separar adecuadamente los dominios, lo que podría deberse a la naturaleza no lineal y compleja de los datos.

En resumen, cuando se trata de predecir dominios de alteración a partir de geoquímica multivariada, los modelos basados en árboles como Random Forest y las redes neuronales son claramente los más confiables. No solo se adaptan mejor a los patrones complejos presentes en los datos, sino que también ofrecen un equilibrio sólido entre sensibilidad y especificidad.

4.3.4 Comparación de desempeño de los algoritmos para los ensambles

Los resultados de las pruebas a los cuatro modelos de categorización para los parámetros de exactitud, sensibilidad y especificidad se muestran en la Tabla 23.

Los resultados de los 04 algoritmos usados para la predicción vectores de soporte (SVM), vecinos más cercanos (k-NN), Neural Network (TREE) y bosques aleatorios (RF), muestran una gran similitud, todo guardan coherencia además que algunos son más continuos en algunos sectores, por lo que la calificación del más óptimo no solo es a partir de los parámetros de calidad del algoritmo, sino también de una validación visual como se aprecia en la Tabla 26.

Tabla 26

Métricas de desempeño obtenidas durante la fase de validación de los cuatro modelos predictivos

Dominio ArgI				Dominio ArgIAvd			
Model	AUC	Prec	Recall	Model	AUC	Prec	Recall
SVM	0.981	0.258	0.279	SVM	0.734	0.320	0.317
Random Forest	1.000	1.000	0.995	Random Forest	1.000	0.994	0.990
Neural Network	1.000	0.980	0.955	Neural Network	0.997	0.962	0.961
kNN	1.000	0.995	0.985	kNN	0.998	0.974	0.980

Dominio Oxd				Dominio Pro			
Model	AUC	Prec	Recall	Model	AUC	Prec	Recall
SVM	0.909	0.135	0.608	SVM	1.000	0.444	1.000
Random Forest	1.000	0.998	0.987	Random Forest	1.000	1.000	1.000
Neural Network	1.000	0.986	0.978	Neural Network	1.000	1.000	1.000
kNN	0.998	0.982	0.969	kNN	1.000	1.000	0.750

Dominio Fill				Dominio Sk			
Model	AUC	Prec	Recall	Model	AUC	Prec	Recall
SVM	0.469	0.425	0.193	SVM	0.525	0.299	0.298
Random Forest	1.000	0.987	0.995	Random Forest	1.000	0.999	0.994
Neural Network	0.995	0.956	0.962	Neural Network	0.999	0.988	0.979
kNN	0.999	0.974	0.977	kNN	1.000	0.993	0.986

Nota: Fuente elaboración propia y generado en Orange

Las tablas muestran los resultados de las métricas para evaluar los modelos por dominio donde se tienen buenos resultados para Random Forest, para todos los modelos, además se muestra métricas muy bajas para el modelo de SVM.

La tabla de métricas de evaluación permite comparar el rendimiento de los modelos aplicados al reconocimiento de dominios de alteración hidrotermal. En términos generales, Random Forest se posiciona como el modelo más sólido y consistente, alcanzando valores cercanos a 1 en todas las métricas (AUC, precisión, recall y especificidad), tanto en el promedio general como en cada dominio evaluado.

Los modelos de redes neuronales y k-NN también mostraron un rendimiento destacado, con diferencias mínimas respecto a Random Forest. En dominios como Pro y Sk, estos modelos lograron métricas que rozan la perfección, lo que refuerza su valor como alternativas viables en contextos donde se busca alta precisión y sensibilidad.

En contraste, el modelo SVM presentó limitaciones notables. Sus valores de AUC y recall fueron significativamente más bajos, especialmente en los dominios Fill y Sk, lo que sugiere una baja capacidad para identificar correctamente las zonas alteradas. Esta


baja sensibilidad podría deberse a la naturaleza no lineal y compleja de los datos geoquímicos, que el modelo SVM no logra modelar adecuadamente con su enfoque más rígido. Estos resultados coinciden con trabajos previos en geociencias, como el de Rodríguez-Galiano et al. (2015), quienes demostraron la eficacia de Random Forest en la predicción de zonas mineralizadas. De forma similar, investigaciones como la de Pour y Hashim (2014) evidencian las limitaciones de SVM en contextos con alta complejidad geoquímica. Asimismo, el uso exitoso de redes neuronales en estudios como el de Pourghasemi et al. (2020) respalda el buen desempeño observado en este trabajo.

4.4 Clasificación de los minerales de alteración

De lo revisado con los diferentes algoritmos de predicción el modelo Random Forest predice de manera eficiente el resto de los sondajes que cuentan con información espectral, como se muestra en la Figura 44 se llega a validar la coherencia que existe entre los dominios de alteración de sondajes que caen en la misma línea de sección.

Figura 44

Sección parte superior e inferior.



Nota: Sección superior mostrando el logueo original junto a su modelo en leapfrog y en la parte inferior el modelamiento a partir de la predicción Random Forest.

En resumen, el modelo Random Forest está siendo efectivo en la tarea de predicción en el contexto de tu estudio, particularmente en relación con la información espectral y la distribución de alteraciones en sondajes. La validación visual y la coherencia observada refuerzan la utilidad del modelo en este contexto específico.

Este proceso de clasificación puede ser fundamental en la exploración geológica y la identificación de nuevas áreas potenciales para la extracción de recursos minerales, además de ser usado en la definición de dominios a modelar en 3D para operaciones mineras en etapa de proyecto y en producción, como se ha visto la utilización de algoritmos de aprendizaje automático, como Random Forest, puede facilitar la automatización de este proceso y mejorar la eficiencia en la identificación de patrones en grandes conjuntos de datos.

Al realizar una comparación entre el método actual de modelamiento el cual parte de la interpretación del logueo del geólogo, del cual se obtiene un modelamiento limitado por los contactos litológicos a su vez que no todos los dominios guardan continuidad y coherencia entre ellos como se ve la Figurar 44b, en comparación con el modelo generado por Random Forest el cual en la misma sección muestra una coherencia entre los dominios a su vez que los limites son más continuos.


4.5 Sobreajuste y desempeño de los modelos

El análisis del sobreajuste y desempeño de los algoritmos frente al incremento del volumen de datos se realizó mediante la construcción de curvas de aprendizaje para cada uno de los cuatro modelos evaluados (Random Forest, SVM, Redes Neuronales y KNN) como se aprecia en la Figura 45.

Estas gráficas contrastan la métrica de exactitud (Accuracy) en el conjunto de entrenamiento frente al rendimiento obtenido en el conjunto de validación ciega, permitiendo diagnosticar el grado de sobreajuste (overfitting) y la capacidad de generalización espacial del sistema.

Figura 45

Curva de aprendizaje para los 4 modelos



Nota: Fuente elaboración propia

La interpretación analítica de los resultados ilustrados en la Figura 47 expone las siguientes líneas:

Random Forest

Entrenamiento: casi perfecto (accuracy ~1.0).

Validación: ~0.73–0.78, con ligera caída en los últimos tamaños.

Interpretación: presenta sobreajuste, el modelo memoriza el entrenamiento.

SVM

Entrenamiento: más bajo que Random Forest (~0.91–0.95).

Validación: ~0.70–0.73, estable en tamaños grandes.

Red Neuronal

Entrenamiento: casi perfecto (~0.99).

Validación: muy baja (0.55–0.67), con gran brecha respecto al entrenamiento.

Interpretación: El modelo está en sobreajuste fuerte.

KNN

Entrenamiento: casi perfecto (~0.99).

Validación: muy baja (0.60–0.67), bastante por debajo del entrenamiento.

Interpretación: Presenta sobreajuste.

Si bien los modelos SVM y Random Forest presentan el menor sobreajuste comparado al Red Neuronal y KNN, es el Random Forest que presenta mejores resultados de precisión en la validación, posiblemente la fluctuación de precisión entre las diferentes iteraciones de muestras se deba a que tenemos algunas clases con pocas poblaciones, como es el caso del dominio argílico y propilitico.

4.6 Modelamiento 3D de los dominios de alteración

Para el modelamiento dinámico en 3D se usará el Leapfrog, partiendo de los tramos predichos por el algoritmo Random Forest, para ello se seguirá los pasos siguientes:

- **Predicciones del algoritmo Random Forest:**

El algoritmo Random Forest ha sido utilizado para predecir características geológicas o tipos de mineralización en un área específica, estas predicciones se han aplicado a diferentes tramos de interés.

- **Datos de entrada para leapfrog:**

Los resultados del Random Forest se utilizan como datos de entrada para el software Leapfrog, estos resultados pueden considerarse como indicadores de la probabilidad de presencia de ciertos tipos de alteración o mineralización.

- **Modelado Implícito en Leapfrog:**

Leapfrog es conocido por su capacidad para realizar modelado geológico implícito en 3D. Utiliza datos de entrada, como datos estructurales, geofísicos y de muestreo de superficie, para generar un modelo tridimensional de la geología subyacente. En este caso, las predicciones del Random Forest se incorporan como una capa adicional de información.

- **Ajuste y validación:**

Se pueden realizar ajustes y validaciones en el modelo generado por Leapfrog para garantizar que coincida con las observaciones de campo y otros datos geológicos disponibles. Esto puede incluir la comparación con otros modelos generados con anteriores procedimientos.

- **Generación de modelos 3D detallados:**

Leapfrog permite la creación de modelos geológicos 3D detallados, incluyendo la representación de la distribución espacial de las diferentes unidades geológicas y sus propiedades. La información del Random Forest puede influir en la distribución de estas unidades.

- **Análisis y visualización:**

Los resultados del modelado en 3D se utilizan para realizar análisis geológicos detallados. Esto puede incluir la identificación de zonas potencialmente ricas en minerales, la planificación de perforaciones y la evaluación de estimación de las geometrías de las estructuras geológicas.


- **Iteración y mejora continua:**

El modelo puede ser iterado y mejorado continuamente a medida que se obtienen más datos. La retroalimentación del modelado y las observaciones adicionales en el terreno pueden alimentar futuras predicciones del Random Forest y mejorar la precisión del modelo geológico.

Esta integración de técnicas de aprendizaje automático con software de modelado geológico proporciona una metodología poderosa para la exploración y evaluación de recursos minerales, permitiendo una comprensión más completa de la geología como se aprecia en la Figura 46.

Figura 46

Modelamiento dinámico en leapfrog usando la predicción de tramos Random Forest



Nota: Fuente elaboración propia

4.7 Zonamiento hidrotermal y vectorización hacia mineralización

El área de estudio corresponde a un sistema hidrotermal complejo, caracterizado por una evolución de varios eventos de alteración asociados a un cuerpo intrusivo en profundidad.

La zonificación de minerales espectrales y el modelamiento de dominios de alteración revelan un sistema clásico de tipo epitermal de alta sulfuración con transiciones hacia ambientes tipo pórfido y skarn, lo cual corrobora la geología local.

Este contexto geológico es coherente con modelos ampliamente documentados en cinturones volcánico-intrusivos del tipo Andino o Circumpacífico (Sillitoe, 2010; Corbett & Leach, 1998).

El uso de datos espectrales permitió identificar la distribución espacial de minerales claves como alunita, pirofilita, caolinita, dickita, yeso, micas blancas, clorita, montmorillonita, goethita y sílice hidratada.

Estos minerales fueron interpretados en el contexto de alteraciones hidrotermales típicas, clasificadas en cuatro dominios principales:

Alteración avanzada argílica (Alunita, Pyrophyllite, Kaolinite, Dickite).

Ubicada predominantemente en los sectores centro-sur y este del modelo. Representa el núcleo de un sistema ácido, con alta actividad de fluidos magmáticos condensados ricos en SO₂ (White et al., 1995; Hedenquist & Lowenstern, 1994).

Alteración filica (White Mica, Montmorillonite, Dickite).

Rodea a la zona acidificada, actuando como halo intermedio. Indica condiciones más neutras, donde los fluidos han perdido acidez o se han mezclado con aguas meteóricas.

Alteración propílica (Chlorite, Carbonates, Goethite).

Domina las zonas externas del sistema. Se asocia con fluidos fríos y alcalinos, típicos de zonas distales en sistemas pórfido o transicionales (Titley & Beane, 1981).

Alteración supergena y oxidación (Water_silica, Goethite).

Identificada en superficie y cerca de la zona de lixiviación. Sugiere un ambiente oxidante, posiblemente vinculado a procesos de enriquecimiento secundario o meteorización avanzada (Deyell et al., 2005).


Los mapas espectrales presentados revelan que estos dominios no se distribuyen al azar, sino que se alinean siguiendo orientaciones estructurales dominantes NE–SW y NW–SE, lo que también evidencia un fuerte control estructural en la distribución de la alteración.

Generación de secciones transversales

Las secciones geológicas A–A' y B–B' de la Figura 47 ilustran la geometría tridimensional de los dominios de alteración, reforzando la zonificación observada en superficie.

Figura 47

Secciones transversales que muestran la zonación de los minerales de alteración dentro de los dominios de alteración predichos



Nota: Fuente elaboración propia

En particular, se observa un núcleo profundo intrusivo asociado a alteración potásica y cuerpos skárnicos, lo cual sugiere una fuente magmática proximal.

Superposición vertical de dominios: desde potásico en profundidad, pasando por propílico, fílico y finalmente avanzado argílico hacia la superficie, replicando el modelo clásico de zonificación vertical en sistemas pórfidos-epitermales (Lowell & Guilbert, 1970).

Las zonas de alunita y formación de yeso se encuentran fuertemente asociadas a estructuras permeables, lo que sugiere migración ascendente de fluidos ácidos, con condensación y precipitación mineral a medida que disminuye la presión y temperatura.

Estas observaciones permiten inferir que los minerales espectrales mapeados no son solo marcadores químicos, sino verdaderos vectores geológicos que reflejan procesos hidrotermales y estructurales persistentes en el tiempo.

Implicancias exploratorias y geometalúrgicas

El modelamiento en conjunto de datos espectrales, estructurales y litológicos facilita la demarcación de dominios de alteración, optimizando los siguientes aspectos críticos:

- **Respuesta geometalúrgica:**

Facilita la diferenciación entre dominios (ej. argílico vs. fílico) que impactan directamente en la eficiencia de los procesos de beneficio mineral.

- **Guías de Exploración:**

La identificación de estructuras asociadas a paragénesis de alunita-yeso permite definir controles de mineralización y priorizar objetivos de perforación.

- **Confiabilidad en la estimación:**

El uso de dominios de alteración como dominios de estimación reduce el sesgo en el modelo de bloques, permitiendo una representación más fiel de la continuidad del recurso.

4.8 Limitaciones del estudio

A pesar de la alta predictibilidad y solidez estadística demostrada por los modelos de aprendizaje supervisado aplicados al yacimiento, se identificaron factores intrínsecos a los datos y a las tecnologías utilizadas que delimitan el alcance del presente estudio. Estas limitaciones deben considerarse para la interpretaciones y futuras optimizaciones del flujo:

- **Efecto del desbalance de clases y representatividad muestral:**

La población de datos presenta una distribución asimétrica en la abundancia de los dominios de alteración. Especies minerales dominantes y continuas en el depósito (como la pirofilita o la alunita) cuentan con una representatividad muestral masiva, lo que optimiza su entrenamiento. No obstante, alteraciones no prioritarias en la exploración y que tienen un menor tamaño de muestra, lo que induce a un sesgo latente que restringe la sensibilidad (Recall) del clasificador en dichas fases minoritarias.

- **Limitaciones intrínsecas de la espectrometría de reflectancia (TerraSpec/ASD):**

La captura espectral mediante el equipo TerraSpec 4 se restringe a las respuestas de reflectancia en las regiones del visible e infrarrojo (VNIR-SWIR). Bajo este principio físico, el sistema es incapaz de detectar de forma directa especies minerales que carecen de rasgos activos de absorción en estas longitudes de onda (tales como el cuarzo, sulfuros primarios como la calcopirita o pirita, y feldespatos). Aquí la dificultad de definir zonas potásicas o zonas de enriquecimiento.

- **Efecto de enmascaramiento y solapamiento espectral:**

En intervalos con mezclas mineralógicas complejas (Ausspec ha detectado hasta 6 minerales a partir de un espectro), las fases de alta reflectancia y absorción profunda tienden a enmascarar la firma espectral de minerales con menor cristalinidad o abundancia relativa. Este solapamiento físico en las bandas de absorción (enlaces Al-OH y Fe-OH) limita la capacidad de discriminación del algoritmo de Ausspec, trasladando dicha incertidumbre analítica como ruido de entrada a los modelos predictivos.

- **Dependencia del etiquetado y sesgo de la base de datos de entrenamiento:**

La precisión final de los clasificadores supervisados se encuentra condicionada por la calidad del etiquetado inicial realizado en Leapfrog. Cualquier selección inadecuada o de no continuidad geológica seleccionada durante la interpretación de los tramos de control se transfiere directamente al nodo de entrenamiento, afectando la capacidad de generalización del modelo al ser evaluado en poblaciones ciegas de la base de datos química general.

Conclusiones

La imprecisión en la delimitación de los contornos de alteración hidrotermal se resolvió mediante un control de calidad geoestadístico riguroso, estableciendo un umbral máximo de coincidencia espacial entre los tramos de perforación y los contactos finales generados en Leapfrog (Back Flagging) superior al 90%. La aplicación de este criterio permitió elevar la exactitud predictiva (Accuracy) del modelo a un rango de entre el 90% y 95%, garantizando la estabilidad global de la matriz 3D y reduciendo la variabilidad espacial en los contornos del modelo de bloques.

Para abordar la complejidad multivariada del yacimiento, se estandarizó e integró la base de datos de reflectancia espectral SWIR–VNIR (capturada mediante equipos TerraSpec) con los registros geoquímicos de perforación. Mediante la aplicación del Análisis de Componentes Principales (PCA), se logró condensar la información capturando más del 80% de la varianza acumulada en un reducido número de factores. Este procedimiento eliminó el ruido multivariado y automatizó la vinculación directa de las anomalías espectrales con la geometría 3D del modelo geológico.

La correlación analítica entre la mineralogía de alteración identificada por espectrometría y los principales elementos geoquímicos del sistema (Au, Cu, As, S) permitió delimitar de manera precisa los dominios geológicos principales del yacimiento. Esta zonación cuantitativa redujo significativamente la varianza intra-dominio, disminuyendo la incertidumbre espacial asociada a la distribución de alteración y optimizando la confiabilidad en la estimación de recursos minerales.

Evaluando distintas arquitecturas de aprendizaje automático (Support Vector Machines, k-Nearest Neighbors y Redes Neuronales), el algoritmo Random Forest (RF) demostró el desempeño predictivo más elevado y estable frente al ruido de las perforaciones. El modelo Random Forest (RF) alcanzó una precisión global (Accuracy) superior al 90%, con un indicador de sobreajuste (overfitting) promedio controlado de 0.77,

consolidándose como la herramienta más robusta para la clasificación automatizada de dominios mineralógicos de alteración.

Recomendaciones

Ampliar la base de datos geológicos y espectrales: La efectividad de los modelos de Machine Learning depende en gran medida de la calidad y cantidad de datos disponibles. Se recomienda consolidar bases de datos más robustas y diversificadas para mejorar la precisión de las predicciones.

Explorar la combinación de modelos híbridos: La integración de diferentes algoritmos, como redes neuronales y árboles de decisión, podría optimizar aún más la segmentación de dominios geológicos y mejorar la confiabilidad de los resultados.

Validar los modelos en distintos contextos geológicos: Para asegurar la aplicabilidad generalizada de los resultados, se recomienda probar los modelos en diferentes tipos de yacimientos y formaciones geológicas.

Capacitar a profesionales en el uso de Machine Learning: La adopción de estas tecnologías en la exploración minera requiere una mayor formación en técnicas de análisis de datos y modelado predictivo, por lo que se sugiere la implementación de programas de capacitación especializados.

Fomentar la colaboración entre instituciones académicas e industriales: El desarrollo de proyectos conjuntos permitirá un mejor acceso a datos, tecnologías y metodologías innovadoras, favoreciendo la aplicación práctica de Machine Learning en la exploración mineral.

Con base en estas conclusiones y recomendaciones, se espera que la presente investigación sirva como punto de partida para futuras mejoras en la aplicación de inteligencia artificial en geociencias, optimizando la identificación de recursos minerales y mejorando la eficiencia en la toma de decisiones dentro de la industria minera.

Referencias bibliográficas

- Abdi, H., & Williams, L. J. (2010). *Principal component analysis*. Wiley Interdisciplinary Reviews: Computational Statistics, 2(4), 433–459.
- Berger, B. R., Ayuso, R. A., Wynn, J. C., & Seal, R. R. (2008). *Preliminary Model of Porphyry Copper Deposits*. U.S. Geological Survey (USGS) Open-File Report 2008-1321.
- Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.
- Carranza, E. J. M. (2008). *Geochemical anomaly and mineral prospectivity mapping in GIS*. Elsevier Science.
- Carranza, E. J. M., & Laborte, A. G. (2015). *Data-driven predictive mapping of mineral prospectivity using Random Forest and k-nearest neighbor algorithms*. Natural Resources Research, 24(2), 137–152.
- Carrillo, J., et al. (2019). *Modelamiento de variables geometalúrgicas basado en ciencia de datos utilizando interpretación geológica, análisis químico y mineralógico de sondajes* (Tesis de Titulación profesional). Facultad de Ingeniería Geológica, Minera y Metalúrgica, Universidad Nacional de Ingeniería, Lima, Perú.
- Cate, A., et al. (2018a). *Machine learning as a tool for geologists*. Geochemistry: Exploration, Environment, Analysis, 18(4), 411–424.
- Cate, A., et al. (2018b). *Classification of lithostratigraphic and alteration units from drillhole lithogeochemical data using machine learning: A case study from the Lalor volcanogenic massive sulphide deposit, Snow Lake, Manitoba, Canada*. Journal of Geochemical Exploration, 188, 321–339.
- Corbett, G. J., & Leach, T. M. (1998). *Southwest Pacific Rim gold-copper systems: Structure, alteration, and mineralization*. Society of Economic Geologists (SEG) Special Publication, 6, 1–238.
- Cracknell, M. J., & Reading, A. M. (2014). *Geological mapping using remote sensing data: A comparison of five machine learning algorithms, their response to variations in*


- training data and the use of spectral indices*. International Journal of Remote Sensing, 35(12), 4644–4679.
- Demšar, J., Curk, T., Erjavec, A., Gorup, C., Hočevár, T., Milutinovič, M., Možina, M., Polajnar, M., Toplak, M., Šarič, A., Štajdohar, M., Umek, L., Žagar, L., Žbontar, J., Žitnik, M., & Zupan, B. (2013). *Orange: Data mining toolbox in Python*. Journal of Machine Learning Research, 14(1), 2349–2353.
- Deyell, C. L., Dipple, G. M., & Hamilton, J. (2005). *Hydrothermal alteration and mineralization in porphyry systems*. Economic Geology, 100(5), 967–982.
- Dramsch, J. S. (2020). *70 Years of Machine Learning in Geoscience in Review*. Advances in Geophysics, 61, 1–55.
- Hedenquist, J. W., Arribas, A., & Reynolds, T. J. (2000). *Evolution of an intrusion-centered hydrothermal system: Far Southeast–Lepanto porphyry and epithermal Cu-Au deposits, Philippines*. Economic Geology, 95(2), 427–464.
- Hill, J., et al. (2014). *Using geochemical proxies to model nuggety gold deposits: An example from Sunrise Dam*. Ore Geology Reviews, 56, 210–222.
- Jain, A. K., Murty, M. N., & Flynn, P. J. (1999). *Data clustering: A review*. ACM Computing Surveys, 31(3), 264–323.
- Jolliffe, I. T., & Cadima, J. (2016). *Principal component analysis: a review and recent developments*. Philosophical Transactions of the Royal Society A, 374(2065), 20150202.
- Lowell, J. D., & Guilbert, J. M. (1970). *Lateral and vertical alteration-mineralization zoning in porphyry ore deposits*. Economic Geology, 65(4), 373–408.
- Pontual, S. (2013). *Spectral Geology Workshop*. AusSpec International Ltd.
- Pontual, S., Merry, N., & Gamson, P. (2012). *Spectral interpretation field manual*. AusSpec International Ltd.
- Richards, J. P. (2011). *High-sulfidation epithermal deposits*. Economic Geology, 106(5), 769–784.

- Rusk, B. G., Reed, M. H., & Dilles, J. H. (2008). *Fluid inclusion evidence for magmatic–hydrothermal fluid evolution in the porphyry copper–molybdenum deposit*. *Geology*, 36(11), 863–866.
- Sillitoe, R. H. (1995). *Exploration of porphyry copper lithocaps*. *Economic Geology*, 90(4), 1013–1046.
- Sillitoe, R. H. (2010). *Porphyry copper systems*. *Economic Geology*, 105(1), 3–41.
- Sillitoe, R. H., & Hedenquist, J. W. (2003). *Linkages between volcanotectonic settings, ore–fluid compositions, and epithermal precious metal deposits*. *Society of Economic Geologists Special Publication*, 10, 315–343.
- Sun, T., et al. (2019). *GIS-based mineral prospectivity mapping using machine learning methods: A case study from Tongling ore district, eastern China*. *Ore Geology Reviews*, 109, 26–41.
- Titley, S. R., & Beane, R. E. (1981). *Porphyry copper deposits: Part II. Hydrothermal alteration and mineralization*. *Economic Geology 75th Anniversary Volume*, 214–269.
- Van der Meer, F. D., et al. (2012). *Multi- and hyperspectral geologic remote sensing: A review*. *International Journal of Applied Earth Observation and Geoinformation*, 14(1), 112–128.
- White, N. C., Hedenquist, J. W., & Dilles, J. H. (1995). *Epithermal gold deposits: Styles, characteristics, and exploration*. *Society of Economic Geologists (SEG) Newsletter*, 23, 1–9.
- Zhang, S. H., et al. (2019). *Development and future prospects of quantitative mineral assessment in China*. *Ore Geology Reviews*, 111, 102987.

Anexos

	Pág.
Anexo 1: Diagrama de Flujo para la Adquisición y Procesamiento de Datos Espectrales mediante TerraSpec 4	1
Anexo 2: Resultados de Identificación Mineral Automatizada (Ausspec)	2
Anexo 3: Graficas de plantas y secciones mostrando la abundancia de los minerales para el SWIR y VNIIR.....	3
Anexo 4: Graficas de los dominios de Alteración para el Algoritmo Árbol de Decisión (Tree)	10

Anexo 1: Diagrama de Flujo para la Adquisición y Procesamiento de Datos Espectrales mediante TerraSpec 4



Fuente: Adaptado de los procedimientos de Buenaventura (2020)

Anexo 2: Resultados de Identificación Mineral Automatizada (Ausspec)

aiMineral1	Conteo	aiMineral2	Conteo	aiMineral3	Conteo	aiMineral4	Conteo	aiMineral5	Conteo	aiMineral6	Conteo
pyrophyllite	18,383	pyrophyllite	6,666	pyrophyllite	1,879	pyrophyllite	414	pyrophyllite	32	pyrophyllite	1
alunite	5,767	alunite	8,374	alunite	4,058	alunite	678	alunite	40	alunite	2
white mica	5,759	white mica	3,574	white mica	1,199	white mica	378	white mica	55	white mica	20
kaolinite	4,327	kaolinite	5,577	kaolinite	2,760	kaolinite	731	kaolinite	74	kaolinite	5
diaspore	2,995	diaspore	4,088	diaspore	1,130	diaspore	84	diaspore	7		
montmorillonite	1,841	montmorillonite	282	montmorillonite	73	montmorillonite	21	montmorillonite	4	montmorillonite	2
water_silica	1,331	water_silica	411	water_silica	57	water_silica	10	water_silica	1		
dickite	1,172	dickite	702	dickite	319	dickite	64	dickite	8	dickite	1
gypsum	642	gypsum	550	gypsum	313	gypsum	126	gypsum	18	gypsum	2
noswir	559										
zunyte	386	zunyte	825	zunyte	728	zunyte	289	zunyte	74	zunyte	4
carbonate	303	carbonate	606	carbonate	668	carbonate	325	carbonate	54		
chlorite	227	chlorite	1,697	chlorite	1,689	chlorite	521	chlorite	97	chlorite	13
epidote	132	epidote	80	epidote	16	epidote	4	epidote	4		
scorodite	41										
err_noise	30										
zeolite	26	zeolite	6	zeolite	2	zeolite	1				
jarosite	20	jarosite	84	jarosite	78	jarosite	23	jarosite	1		
topaz	18	topaz	205	topaz	365	topaz	202	topaz	53	topaz	5
amphibole	14	amphibole	40	amphibole	59	amphibole	16	amphibole	1		
caalunite	8	caalunite	9	caalunite	2						
gibbsite	8	gibbsite	13								
biotite	7	biotite	17	biotite	39	biotite	20	biotite	2		
err_problem	6										
woodhouseite	4	woodhouseite	11	woodhouseite	8	woodhouseite	5				
saponite	3	saponite	6								
spectralon	3										
tourmaline	3	tourmaline	11	tourmaline	9			tourmaline	1		
cellulose	1										
err_dark	1										
halloysite	1										
nontronite	1	nontronite	17	nontronite	44	nontronite	14	nontronite	1		
sudoite	1										

Tabla A-2: Distribución de frecuencias y conteos para las especies minerales identificadas por Ausspec, distribuidas jerárquicamente desde la primera hasta la sexta opción mineralógica según su predominancia en el espectro SWIR (1300-2500 nm)

Fuente: Elaboración propia